Conception d'un modèle prédictif basé sur l'intélligence artifficielle pour la prévision des pluies dans les stations de Kandi et Parakou au Bénin

BODJRENOU Marcellin Vignon & AKODOHOU Ginette Sènami

Table of contents

1 Introduction Générale **3**

2 Prétraitement et comparaison des méthodes d'imputation des valeurs manquantes **3**
2.1 Introduction . . . 3
2.2 Aperçu général des données reçues . . . 3
2.2.1 Informations générales . . . 4
2.2.2 Stations présentes dans les données . . . 5
2.3 Création des jeux de données pour le projet . . . 5
2.3.1 Création des variables année, mois et jour de Kandi et de Parakou . . . 6
2.3.2 Création des variables Pression, température, vitesse de vent, humidité et pluviométrie . . . 6
2.3.3 Dimensions des datasets . . . 8
2.4 Prétraitement des données . . . 8
2.4.1 Valeurs manquantes . . . 8
2.4.2 Visualisation des valeurs manquantes . . . 9
2.4.3 Suppression des lignes très incomplètes . . . 10
2.4.4 Méthodes d'imputation . . . 11
2.4.5 Protocole expérimental . . . 11
2.4.6 Résultats . . . 11
2.4.7 Représentation graphique des erreurs . . . 13
2.5 Conclusion . . . 14

3 Analyse exploratoire des données météorologiques **15**
3.1 Introduction . . . 15
3.2 Analyse des données météorologiques . . . 15
3.2.1 Description des données . . . 15
3.2.2 Distribution de la pluie . . . 16
3.2.3 Variation de la pluie au fil du mois . . . 16
3.2.4 Corrélation entre les variables climatiques . . . 18
3.2.5 Observation des valeurs extrême . . . 20

3.2.6 Stationnarité de la pluie . . . 20
3.3 Conclusion . . . 21

4 Comparaison et choix des modèles pour la prévision pluviométrique 21
4.1 Introduction . . . 21
4.2 Utilisation des modèles . . . 21
4.2.1 Modèle ARIMA . . . 21
4.2.2 Modèle SARIMA . . . 24
4.2.3 Modèle SARIMAX . . . 26
4.2.4 Modèle Prophet . . . 28
4.2.5 Modèle XGBoost . . . 30
4.3 Conclusion . . . 32

5 Conclusion générale 33

1 Introduction Générale

La météorologie occupe une grande importance dans plusieurs domaines de la vie quotidienne notamment l'agriculture et les transports. Grâce aux stations, une grande quantité de données tel que la température, l'humidité, la pression atmosphériques et le vent est collecté chaque jour.

Cependant, l'analyse de ces données afin de prévoies les précipitations demeurent une tâche complexe en raison des variations climatiques. Face à ces difficultés, les techniques d'intelligence artificielle et d'apprentissage automatique offrent aujourd'hui des solutions efficaces pour améliorer la prédiction des pluies.

Dans le cas de ce stage, notre projet consiste à analyser les données météorologiques des stations de Parakou et de Kandi, de 2015 à 2025, et à développer un modèle intelligent capable de prédire la pluie à partir des variables climatiques. Pour la réalisation de notre projet, le langage Python sera utilisé afin d'analyser les données et de développer un modèle prédictif.

2 Prétraitement et comparaison des méthodes d'imputation des valeurs manquantes

2.1 Introduction

Dans le cadre de cette étude portant sur l'analyse et la prévision des données météorologiques des stations de Kandi et de Parakou sur la période 2015-2025, une étape importante de prétraitement des données a été réalisée.

L'objectif de ce travail est :

- de créer des jeux de données spécifiques à chaque station ;
- d'analyser les valeurs manquantes ;
- de comparer plusieurs méthodes d'imputation ;
- de sélectionner la méthode la plus performante.

2.2 Aperçu général des données reçues

	Name	Geogr1	Geogr2	Year	Eg el abbreviation	\
0	KANDI_AEROPORT	2.9333	11.1333	2015	PSTAD	
1	KANDI_AEROPORT	2.9333	11.1333	2015	PSTAD	
2	KANDI_AEROPORT	2.9333	11.1333	2015	PSTAD	
3	KANDI_AEROPORT	2.9333	11.1333	2015	PSTAD	
4	KANDI_AEROPORT	2.9333	11.1333	2015	PSTAD	

	Name.1	Description	Month	Time	01	...	22	23	\
0	Pression Station Moy	hPa	1	06:00	979.9	...	979.6	978.7	
1	Pression Station Moy	hPa	2	06:00	977.7	...	977.4	979.5	
2	Pression Station Moy	hPa	3	06:00	978.6	...	974.8	974.3	
3	Pression Station Moy	hPa	4	06:00	978.5	...	975.9	975.9	
4	Pression Station Moy	hPa	5	06:00	973.9	...	977.8	976.9	

```
      24     25     26     27     28     29     30     31
0  977.0  976.4  977.9  978.3  978.1  977.9  978.3  978.3
1  979.2  976.8  976.5  978.2  978.4    NaN    NaN    NaN
2  974.1  975.4  977.9  978.5  978.1  976.5  976.2  977.1
3  975.9  977.5  977.2  977.1  976.2  976.0  974.7    NaN
4  977.9  977.0  975.7  976.2  976.6  975.5  976.4  976.2

[5 rows x 40 columns]
```

2.2.1 Informations générales

```
<class 'pandas.DataFrame'>
RangeIndex: 1577 entries, 0 to 1576
Data columns (total 40 columns):
 #   Column              Non-Null Count  Dtype
---  ------              --------------  -----
 0   Name                1577 non-null   str
 1   Geogr1              1577 non-null   float64
 2   Geogr2              1577 non-null   float64
 3   Year                1577 non-null   int64
 4   Eg el abbreviation  1577 non-null   str
 5   Name.1              1577 non-null   str
 6   Description         1577 non-null   str
 7   Month               1577 non-null   int64
 8   Time                1577 non-null   str
 9   01                  1576 non-null   float64
 10  02                  1575 non-null   float64
 11  03                  1574 non-null   float64
 12  04                  1576 non-null   float64
 13  05                  1575 non-null   float64
 14  06                  1576 non-null   float64
 15  07                  1576 non-null   float64
 16  08                  1576 non-null   float64
 17  09                  1576 non-null   float64
 18  10                  1576 non-null   float64
 19  11                  1576 non-null   float64
 20  12                  1577 non-null   float64
 21  13                  1575 non-null   float64
 22  14                  1576 non-null   float64
 23  15                  1577 non-null   float64
 24  16                  1577 non-null   float64
 25  17                  1576 non-null   float64
 26  18                  1577 non-null   float64
 27  19                  1577 non-null   float64
 28  20                  1577 non-null   float64
```

```
 29  21                  1577 non-null   float64
 30  22                  1574 non-null   float64
 31  23                  1574 non-null   float64
 32  24                  1576 non-null   float64
 33  25                  1576 non-null   float64
 34  26                  1576 non-null   float64
 35  27                  1571 non-null   float64
 36  28                  1576 non-null   float64
 37  29                  1480 non-null   float64
 38  30                  1435 non-null   float64
 39  31                  906 non-null    float64
dtypes: float64(33), int64(2), str(5)
memory usage: 492.9 KB
```

```
Index(['Name', 'Geogr1', 'Geogr2', 'Year', 'Eg el abbreviation', 'Name.1',
       'Description', 'Month', 'Time', '01', '02', '03', '04', '05', '06',
       '07', '08', '09', '10', '11', '12', '13', '14', '15', '16', '17', '18',
       '19', '20', '21', '22', '23', '24', '25', '26', '27', '28', '29', '30',
       '31'],
      dtype='str')
```

2.2.2 Stations présentes dans les données

```
<StringArray>
['KANDI_AEROPORT', 'PARAKOU_AEROPORT']
Length: 2, dtype: str
```

On a les données de deux stations : celle de Kandi et de Parakou. ### Les types de donné reçu

```
<StringArray>
['Pression Station Moy',           'Pluie jour',      'Température max',
      'Température min',         'Humidité moy',       'Vit moy vent10']
Length: 6, dtype: str
<StringArray>
['hPa', 'mm', '°C', '%', 'm/s']
Length: 5, dtype: str
```

On a reçu less données de la pression (en hPa), de la pluie par jour (en mm), de la température maximale et minimale (en °C), de l'humidité (en %) et de la vitesse du vent (en m/s).

2.3 Création des jeux de données pour le projet

Les données fournies constituent un dataframe dans lequel chaque ligne représente une information précise (pression, température, humidité, etc.) des 31 jours d'un mois pour une année donnée.

2.3.1 Création des variables année, mois et jour de Kandi et de Parakou

Kandi

	Lieu	annee	mois	jour
0	KANDI_AEROPORT	2015	1	1
1	KANDI_AEROPORT	2015	1	2
2	KANDI_AEROPORT	2015	1	3
3	KANDI_AEROPORT	2015	1	4
4	KANDI_AEROPORT	2015	1	5
...	...	...	...	...
4013	KANDI_AEROPORT	2025	12	27
4014	KANDI_AEROPORT	2025	12	28
4015	KANDI_AEROPORT	2025	12	29
4016	KANDI_AEROPORT	2025	12	30
4017	KANDI_AEROPORT	2025	12	31

Parakou

	Lieu	annee	mois	jour
0	PARAKOU_AEROPORT	2015	1	1
1	PARAKOU_AEROPORT	2015	1	2
2	PARAKOU_AEROPORT	2015	1	3
3	PARAKOU_AEROPORT	2015	1	4
4	PARAKOU_AEROPORT	2015	1	5
...	...	...	...	...
4013	PARAKOU_AEROPORT	2025	12	27
4014	PARAKOU_AEROPORT	2025	12	28
4015	PARAKOU_AEROPORT	2025	12	29
4016	PARAKOU_AEROPORT	2025	12	30
4017	PARAKOU_AEROPORT	2025	12	31

2.3.2 Création des variables Pression, température, vitesse de vent, humidité et pluviométrie

Station de Kandi

```
                Lieu  annee  mois  jour  Pression  Temperature_Max  \
0     KANDI_AEROPORT   2015     1     1     979.9             32.0
1     KANDI_AEROPORT   2015     1     2     981.4             30.3
2     KANDI_AEROPORT   2015     1     3     982.8             29.2
3     KANDI_AEROPORT   2015     1     4     983.8             29.0
4     KANDI_AEROPORT   2015     1     5     982.7             29.5
...              ...    ...   ...   ...       ...              ...
```

```
4013  KANDI_AEROPORT   2025    12    27     976.9             37.4
4014  KANDI_AEROPORT   2025    12    28     977.5             36.9
4015  KANDI_AEROPORT   2025    12    29     978.2             37.5
4016  KANDI_AEROPORT   2025    12    30     978.9             37.7
4017  KANDI_AEROPORT   2025    12    31     978.4             37.3

      Temperature_Min  Humidite  Vitesse_Vent  Pluviometrie
0                13.4      32.0           2.4           0.0
1                17.4      26.0           2.3           0.0
2                17.7      20.0           3.5           0.0
3                15.8      20.0           2.8           0.0
4                13.5      29.0           3.0           0.0
...               ...       ...           ...           ...
4013             20.4      28.0           1.4           0.0
4014             19.7      27.0           2.0           0.0
4015             19.8      31.0           1.5           0.0
4016             20.0      32.0           1.9           0.0
4017             19.7      30.0           2.1           0.0

[4018 rows x 10 columns]
```

Station de Parakou

```
                 Lieu  annee  mois  jour  Pression  Temperature_Max  \
0     PARAKOU_AEROPORT   2015     1     1     967.5             34.6
1     PARAKOU_AEROPORT   2015     1     2     968.6             32.6
2     PARAKOU_AEROPORT   2015     1     3     969.9             32.5
3     PARAKOU_AEROPORT   2015     1     4     970.8             32.5
4     PARAKOU_AEROPORT   2015     1     5     969.9             31.9
...                ...    ...   ...   ...       ...              ...
4013  PARAKOU_AEROPORT   2025    12    27     966.0             36.0
4014  PARAKOU_AEROPORT   2025    12    28     966.3             37.2
4015  PARAKOU_AEROPORT   2025    12    29     967.2             36.0
4016  PARAKOU_AEROPORT   2025    12    30     968.0             36.3
4017  PARAKOU_AEROPORT   2025    12    31     967.2             37.2

      Temperature_Min  Humidite  Vitesse_Vent  Pluviometrie
0                19.2      23.0           3.6           0.0
1                18.5      24.0           4.3           0.0
2                18.9      20.0           4.9           0.0
3                16.5      23.0           5.0           0.0
4                15.9      23.0           5.1           0.0
...               ...       ...           ...           ...
4013             22.3      61.0           1.6           0.0
4014             22.2      56.0           2.3           0.0
```

```
4015            21.2      64.0          2.1          0.0
4016            22.7      65.0          2.3          0.0
4017            23.1      55.0          2.4          0.0

[4018 rows x 10 columns]
```

Notre jeux de données contient sur une ligne, la pression, la température maximale et minimale, l'humidité, la vitesse du vent et la quantité de pluie d'un jour précis.

2.3.3 Dimensions des datasets

```
Dimension Kandi : (4018, 10)
Dimension Parakou : (4018, 10)
```

2.4 Prétraitement des données

2.4.1 Valeurs manquantes

** Station Kandi **

```
Pression        1.642608
Humidite        0.124440
Vitesse_Vent    0.771528
Pluviometrie    0.024888
dtype: float64
```

** Station Parakou **

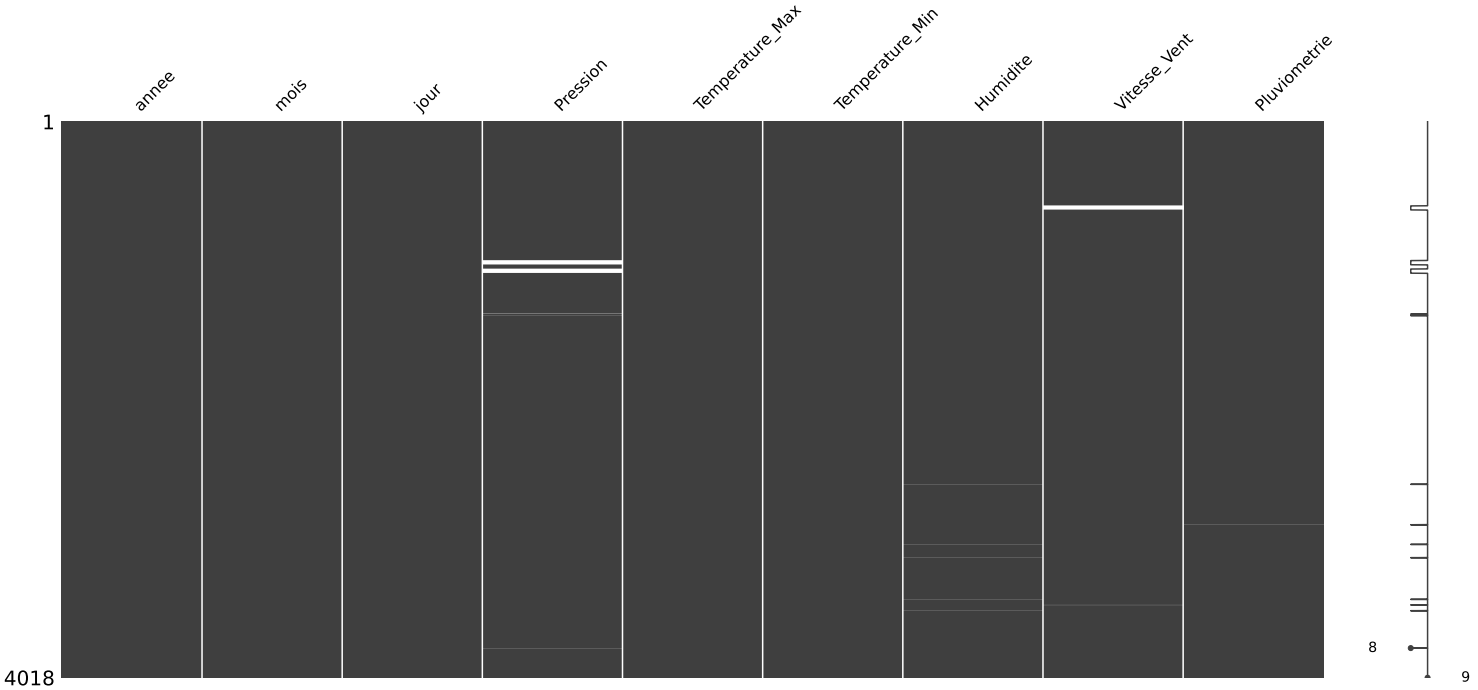
```
Pression           1.791936
Temperature_Max    0.622200
Temperature_Min    0.099552
Humidite           0.895968
Vitesse_Vent       0.099552
dtype: float64
```

On constate que la pression est la variable qui contient plus de valeurs manquantes dans les deux stations.

2.4.2 Visualisation des valeurs manquantes

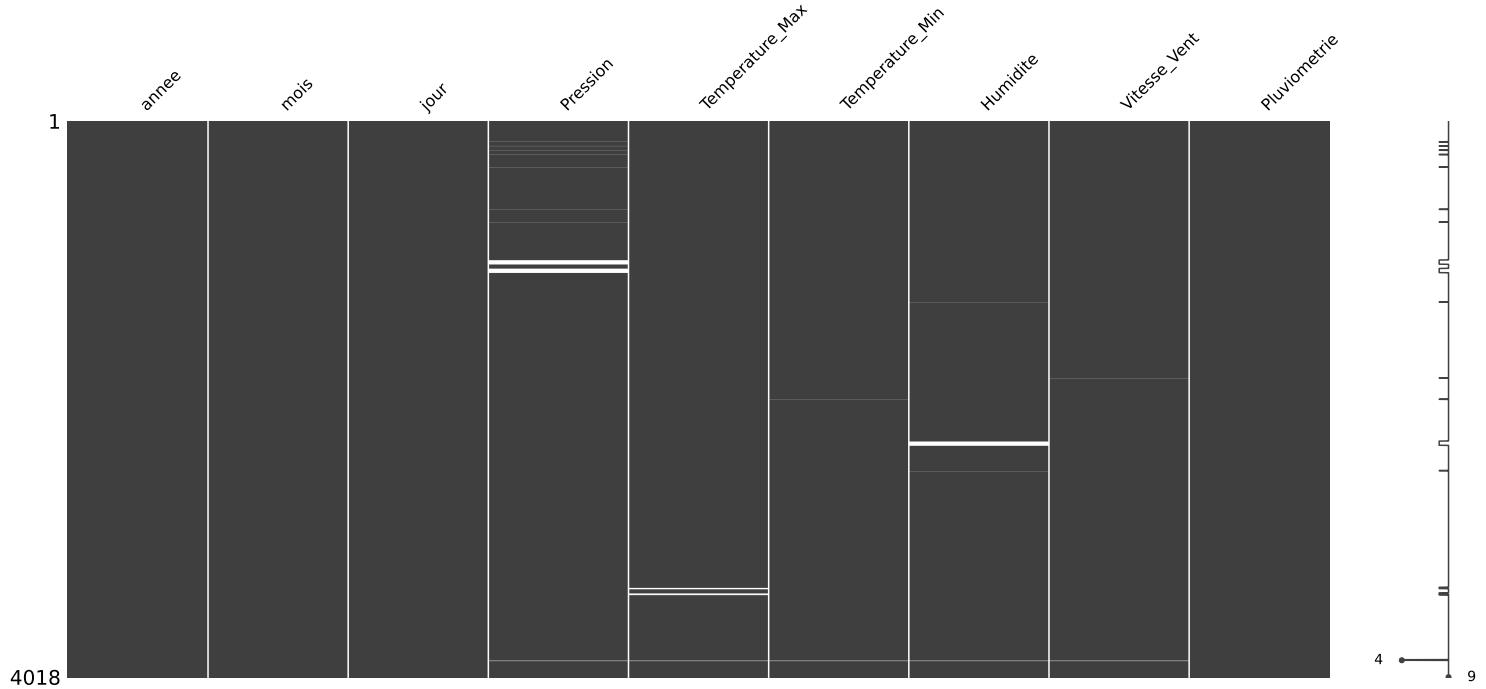
** Station Kandi **

```
<Figure size 3000x2400 with 0 Axes>
```



** Station Parakou **

```
<Figure size 1000x800 with 0 Axes>
```



2.4.3 Suppression des lignes très incomplètes

```
                Lieu  annee  mois  jour  Pression  Temperature_Max  \
3891  PARAKOU_AEROPORT   2025     8    27       NaN              NaN
3894  PARAKOU_AEROPORT   2025     8    30       NaN              NaN
3895  PARAKOU_AEROPORT   2025     8    31       NaN              NaN

      Temperature_Min  Humidite  Vitesse_Vent  Pluviometrie
3891              NaN       NaN           NaN           0.0
3894              NaN       NaN           NaN           0.0
3895              NaN       NaN           NaN           0.0
               Lieu  annee  mois  jour  Pression  Temperature_Max  \
2912  KANDI_AEROPORT   2022    12    22     980.1             30.0

      Temperature_Min  Humidite  Vitesse_Vent  Pluviometrie
2912             17.5      36.0           3.1           NaN
```

Certaines observations de Parakou présentent un taux très élevé de valeurs manquantes. Ces lignes ont été supprimées afin de garantir la qualité des données et de limiter l'introduction d'erreurs liées aux méthodes d'imputation.

Par ailleurs, une observation de Kandi contenant uniquement une valeur manquante pour la pluviométrie a également été supprimée compte tenu de son caractère isolé et de son impact négligeable sur l'ensemble des données.

2.4.4 Méthodes d'imputation

Plusieurs méthodes d'imputation ont été étudiées :

- moyenne historique ;
- médiane historique ;
- interpolation linéaire ;
- moyenne globale ;
- médiane globale.

** Moyenne historique et médiane historique **

Ces deux méthodes consistent à remplacer une valeur manquante respectivement par la moyenne et la médiane des valeurs observées des années précédentes, pour le même jour et le même mois.

** Interpolation linéaire **

Cette méthode consiste à remplacer une valeur manquante en utilisant la valeur précédente et la valeur suivante. Par exemple, en observant la pression du jour précédent et celle du jour suivant, il est possible d'estimer la pression du jour concerné.

** Moyenne globale et médiane globale **

Ces méthodes consistent à remplacer une valeur manquante respectivement par la moyenne et la médiane générales.

2.4.5 Protocole expérimental

Afin de comparer les différentes méthodes d'imputation, certaines valeurs connues ont été supprimées artificiellement dans les données.

Les valeurs supprimées ont ensuite été reconstruites par chaque méthode d'imputation.

Les performances ont été évaluées à l'aide des métriques :

- $MAE = \frac{1}{n} \sum_{i=1}^{n} |x_{i,pred} - x_{i,vrai}|$
- $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_{i,pred} - x_{i,vrai})^2}$.

2.4.6 Résultats

Voilà le score MAE et RMSE des variables qui contient des valeurs manquantes dans les deux stations, pour chaque méthode d'imputation.

** Station Kandi **

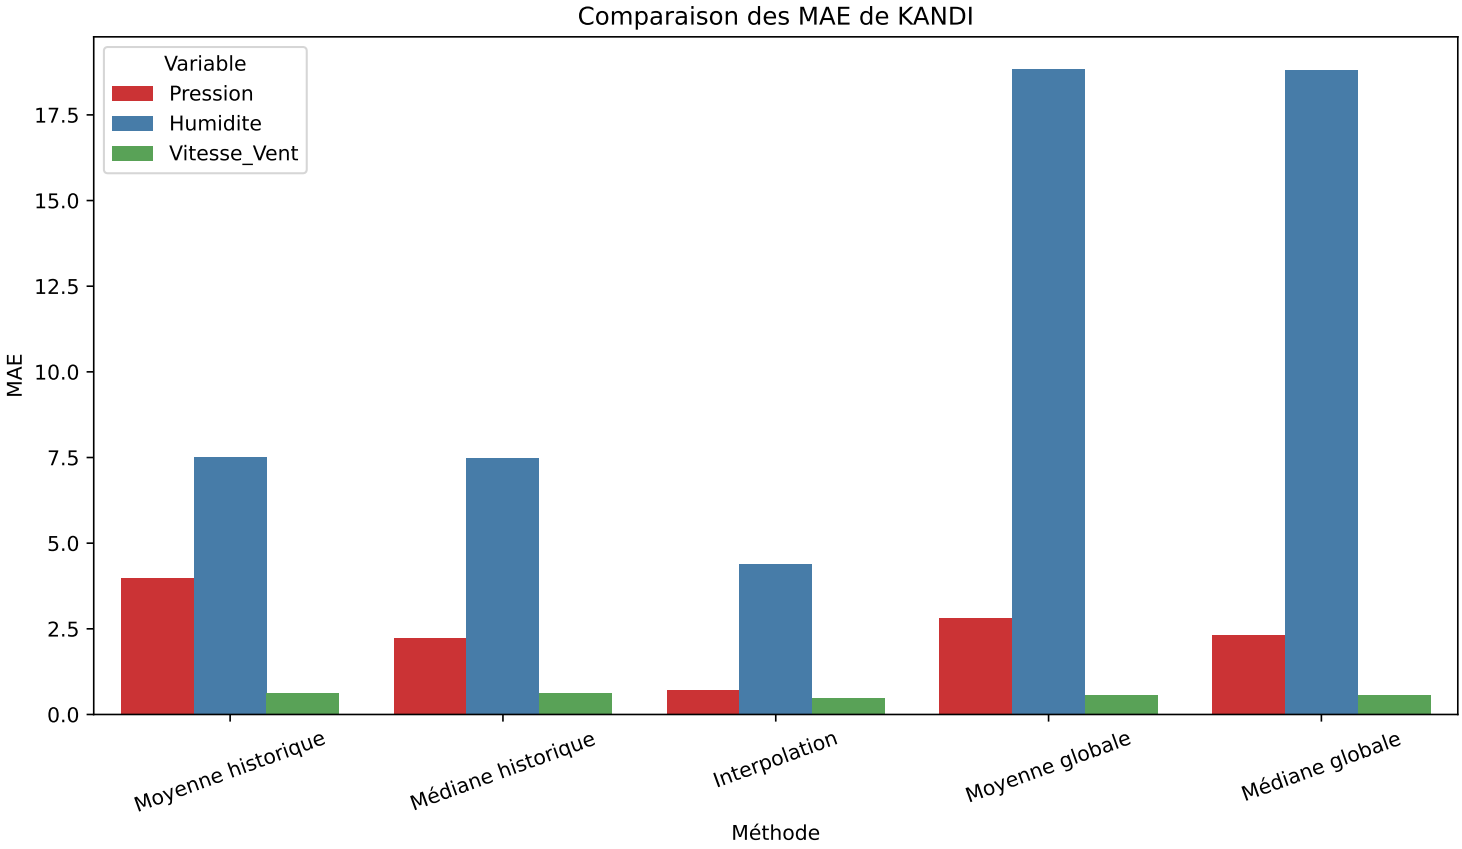
	Variable	Méthode	MAE	RMSE
0	Pression	Moyenne historique	3.983393	6.825533
1	Pression	Médiane historique	2.236250	5.611945
2	Pression	Interpolation	0.707833	1.804480
3	Pression	Moyenne globale	2.813529	5.436928
4	Pression	Médiane globale	2.309000	5.378150
5	Humidite	Moyenne historique	7.518853	10.074710
6	Humidite	Médiane historique	7.490000	10.068515
7	Humidite	Interpolation	4.405000	6.464239
8	Humidite	Moyenne globale	18.836105	21.255002
9	Humidite	Médiane globale	18.820000	21.244764
10	Vitesse_Vent	Moyenne historique	0.616307	0.839723
11	Vitesse_Vent	Médiane historique	0.634500	0.866357
12	Vitesse_Vent	Interpolation	0.470000	0.618708
13	Vitesse_Vent	Moyenne globale	0.572254	0.780300
14	Vitesse_Vent	Médiane globale	0.573000	0.785557

** Station Parakou **

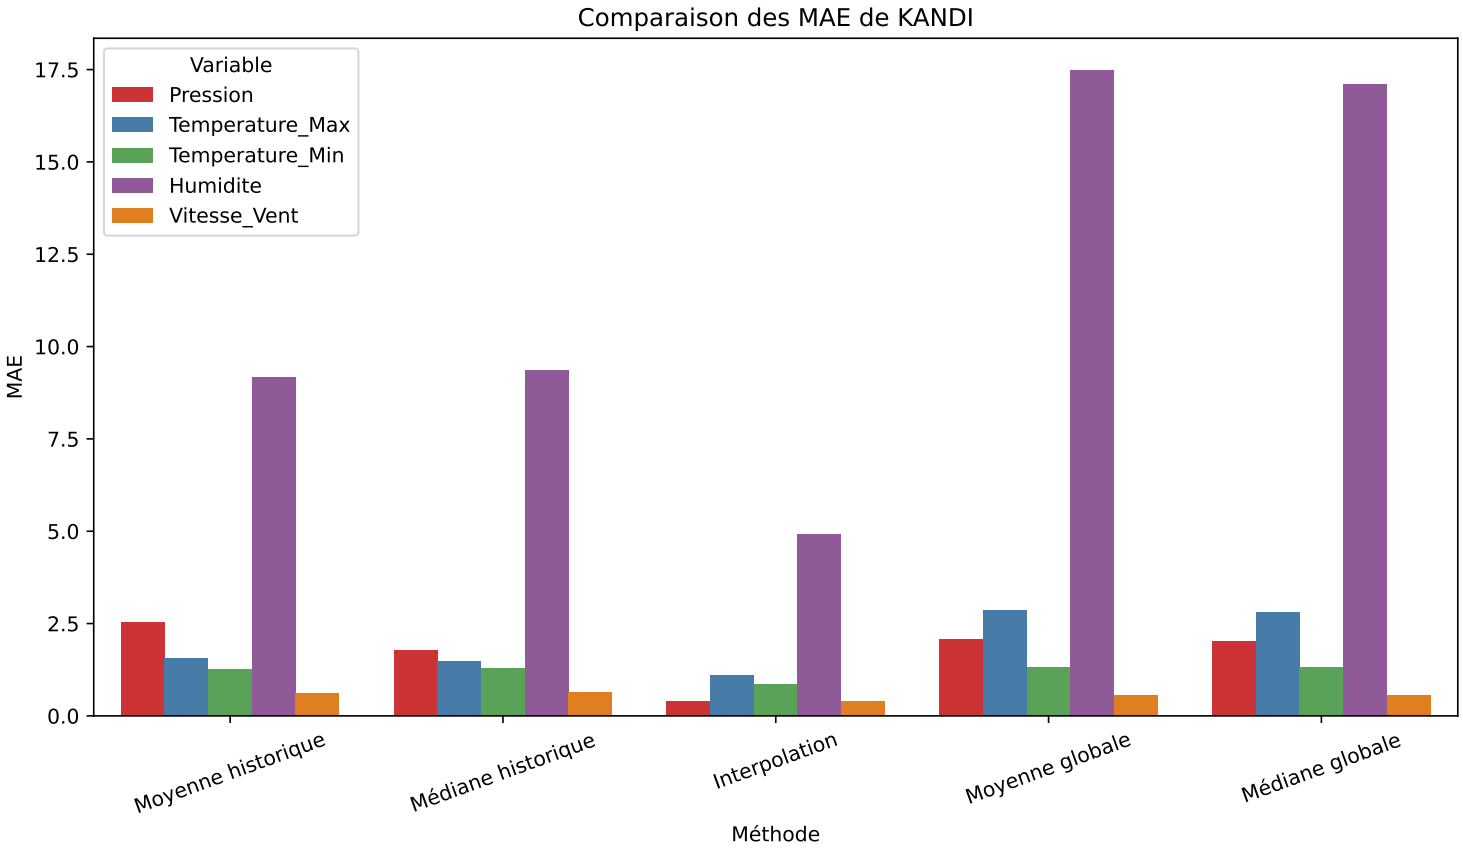
	Variable	Méthode	MAE	RMSE
0	Pression	Moyenne historique	2.538769	6.741995
1	Pression	Médiane historique	1.785000	6.121136
2	Pression	Interpolation	0.396000	0.527926
3	Pression	Moyenne globale	2.075019	6.050059
4	Pression	Médiane globale	2.010000	6.086050
5	Temperature_Max	Moyenne historique	1.560396	1.984032
6	Temperature_Max	Médiane historique	1.463750	1.896808
7	Temperature_Max	Interpolation	1.106833	1.550974
8	Temperature_Max	Moyenne globale	2.844814	3.255498
9	Temperature_Max	Médiane globale	2.813000	3.241157
10	Temperature_Min	Moyenne historique	1.248569	1.610092
11	Temperature_Min	Médiane historique	1.282875	1.651182
12	Temperature_Min	Interpolation	0.855000	1.166598
13	Temperature_Min	Moyenne globale	1.317245	1.673103
14	Temperature_Min	Médiane globale	1.316000	1.672782
15	Humidite	Moyenne historique	9.173177	13.232393
16	Humidite	Médiane historique	9.355000	13.759270
17	Humidite	Interpolation	4.918333	6.776532
18	Humidite	Moyenne globale	17.474566	20.693217
19	Humidite	Médiane globale	17.090000	22.188961
20	Vitesse_Vent	Moyenne historique	0.622360	0.794235
21	Vitesse_Vent	Médiane historique	0.628250	0.802749
22	Vitesse_Vent	Interpolation	0.403000	0.541951
23	Vitesse_Vent	Moyenne globale	0.564437	0.707587
24	Vitesse_Vent	Médiane globale	0.552000	0.701142

2.4.7 Représentation graphique des erreurs

** Station de Kandi **



** Station de Parakou **



2.5 Conclusion

Les résultats obtenus montrent que l'interpolation linéaire fournit les meilleures performances sur la majorité des variables météorologiques étudiées.

Cette méthode présente les plus faibles valeurs de MAE et de RMSE pour les stations de Kandi et de Parakou.

Les méthodes basées sur les moyennes et médianes globales présentent des performances moins satisfaisantes, ce qui montre qu'elles ne prennent pas suffisamment en compte la dynamique temporelle des données climatiques.

Cette étude a permis de structurer les données météorologiques, d'analyser les valeurs manquantes et de comparer plusieurs méthodes d'imputation.

l'interpolation linéaire sera utilisée dans la suite du projet pour le prétraitement des données avant l'analyse exploratoire et la modélisation prédictive.

3 Analyse exploratoire des données météorologiques

3.1 Introduction

Dans le cadre de ce mini-rapport, nous allons effectuer une analyse exploratoire sur nos données météorologiques des stations de Kandi et de Parakou de 2015 à 2025, déjà traitées. L'objectif de cette analyse est de mieux comprendre les tendances et les relations entre les différentes variables météorologiques, afin de déterminer les anomalies et les modèles qui pourraient être utilisés dans la prévision pluviométrique. Nous allons utiliser des techniques de visualisation et des statistiques pour explorer les données et en tirer des conclusions significatives.

3.2 Analyse des données météorologiques

3.2.1 Description des données

Voilà, de façon générale, la description de nos données météorologiques.

Variables	Moyenne K	Moyenne P	Mediane K	Mediane P	Ecart-type K	Ecart-type P
Pression	979.018608	967.354620	977.8	966.8	6.780869	5.214019
Temperature Maximal	34.837590	33.244558	34.7	33.6	3.673417	3.420010
Temperature Minimal	22.258601	22.029116	22.5	22.0	3.668614	1.785151
Humidite	55.986931	62.520922	56.0	69.0	21.219201	20.174645
Pluie	3.108514	3.315318	0.0	0.0	9.673875	10.228387

Avec ce tableau, nous pouvons observer les moyennes, les médianes et les écarts-types des deux stations pour la pression, la température maximale et minimale, l'humidité ainsi que la pluviométrie.

Premièrement, nous pouvons constater qu'il y a globalement plus de pluie à Parakou qu'à Kandi de 2015 à 2025. De plus, il fait plus chaud à Kandi qu'à Parakou. En effet, la pression, la température (surtout minimale) et l'humidité sont plus stables à Parakou qu'à Kandi. Par contre, la pluviométrie est moins stable à Parakou qu'à Kandi. Ce qui n'est pas normal, et cela suggère que la pluie dépend de phénomènes climatiques plus complexes et non uniquement de la stabilité des variables étudiées.

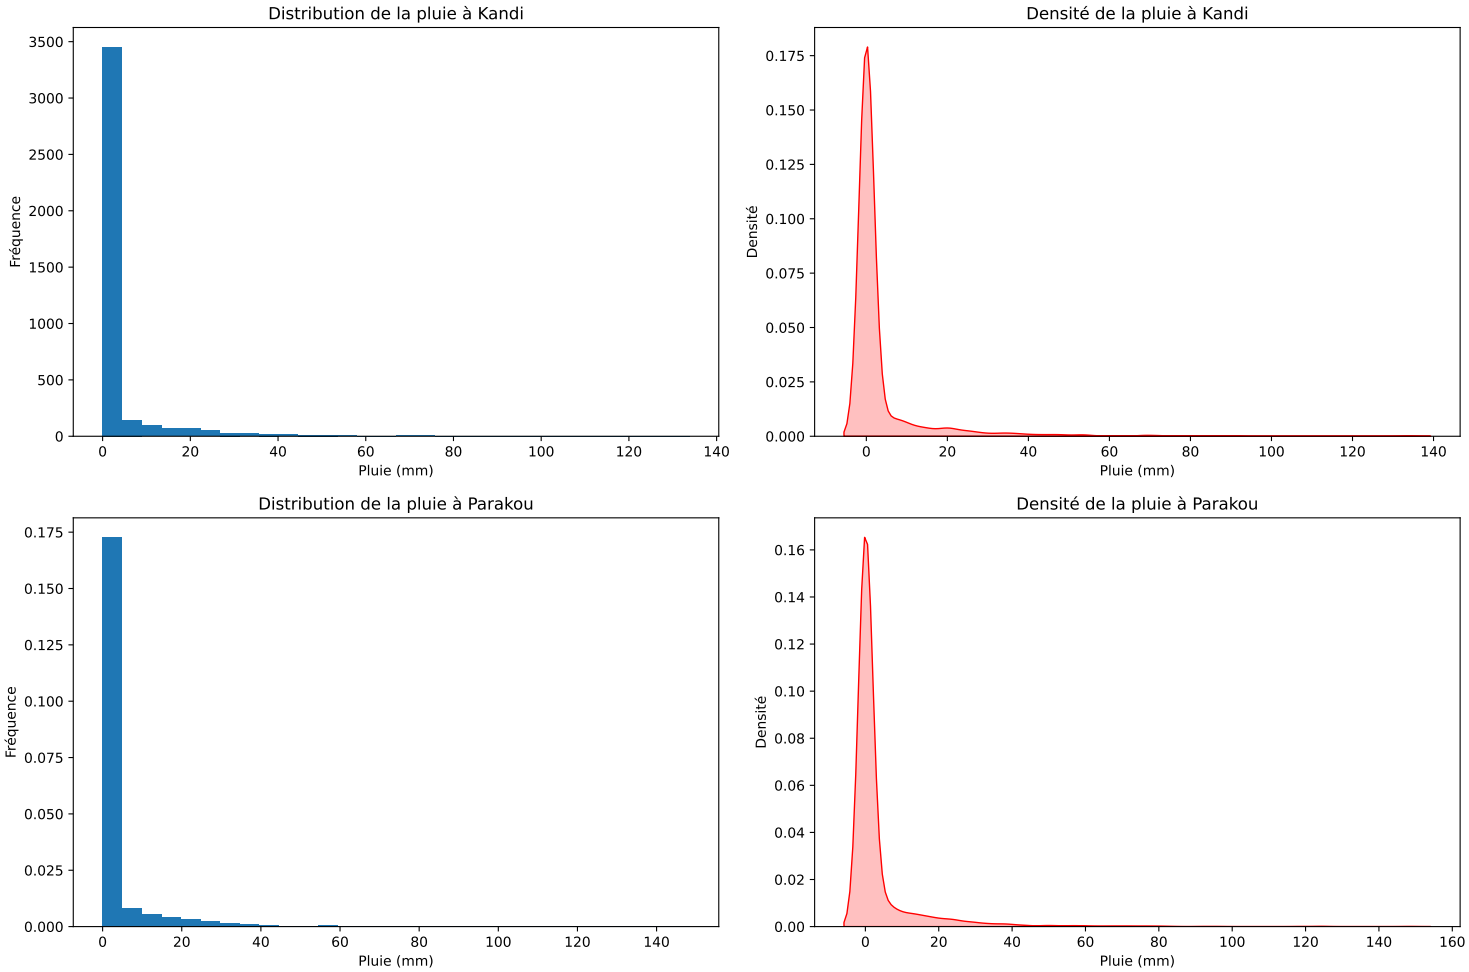
De plus, on constate que la moyenne des pluies est supérieure à la médiane, aussi bien pour Kandi que pour Parakou. Il y a donc de grandes valeurs extrêmes pour la pluie, ce qui prouve l'existence de fortes pluies rares et imprévues. Enfin, Parakou est globalement plus humide que Kandi de 2015 à 2025.

Dans la suite, nous allons approfondir notre analyse pour mieux comprendre ces phénomènes.

** NB : ** **K** signifie Kandi et **P** signifie Parakou

3.2.2 Distribution de la pluie

Dans cette section, nous allons analyser la distribution de la pluie à Kandi et à Parakou. Nous allons utiliser des histogrammes et des courbes de densité pour visualiser la distribution de la pluviométrie dans les deux stations. Cela nous permettra de mieux comprendre les tendances et les variations de la pluie dans ces deux régions.



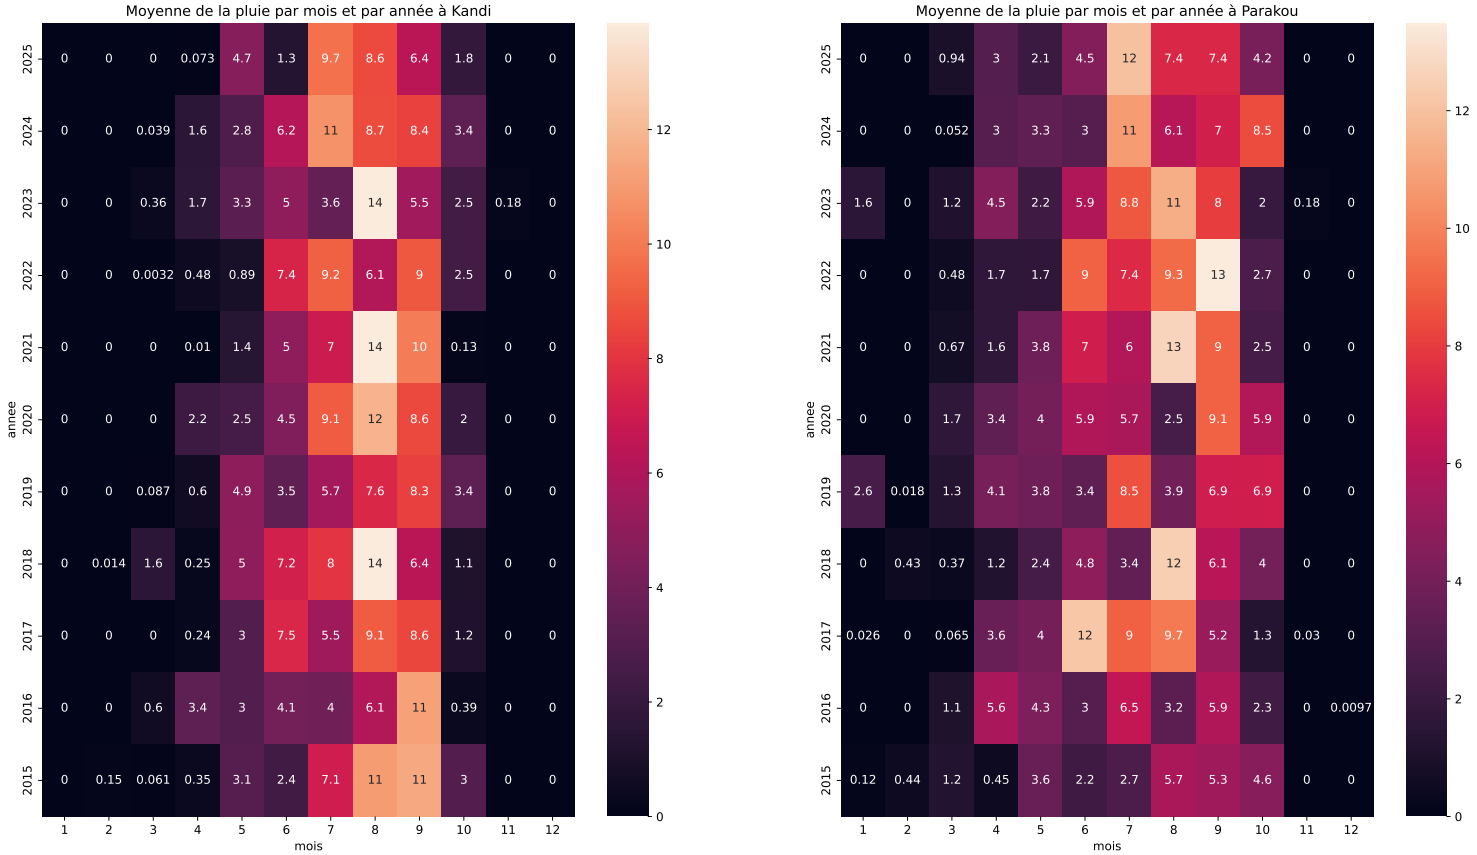
D'abord, on constate que les deux stations ont une distribution de la pluie très similaire. De plus, il semble qu'il ne pleut pas souvent dans les stations. Ce qui est normal, car les fortes pluies sont généralement rares, ce qui explique la grande différence entre la moyenne et la médiane.

En effet, la distribution de la pluie à Parakou est plus étalée que celle de Kandi, ce qui suggère que les fortes pluies sont plus fréquentes à Parakou qu'à Kandi. Enfin, on constate que la distribution de la pluie à Kandi est plus concentrée autour de zéro que celle de Parakou, ce qui suggère que les jours sans pluie sont plus fréquents à Kandi qu'à Parakou.

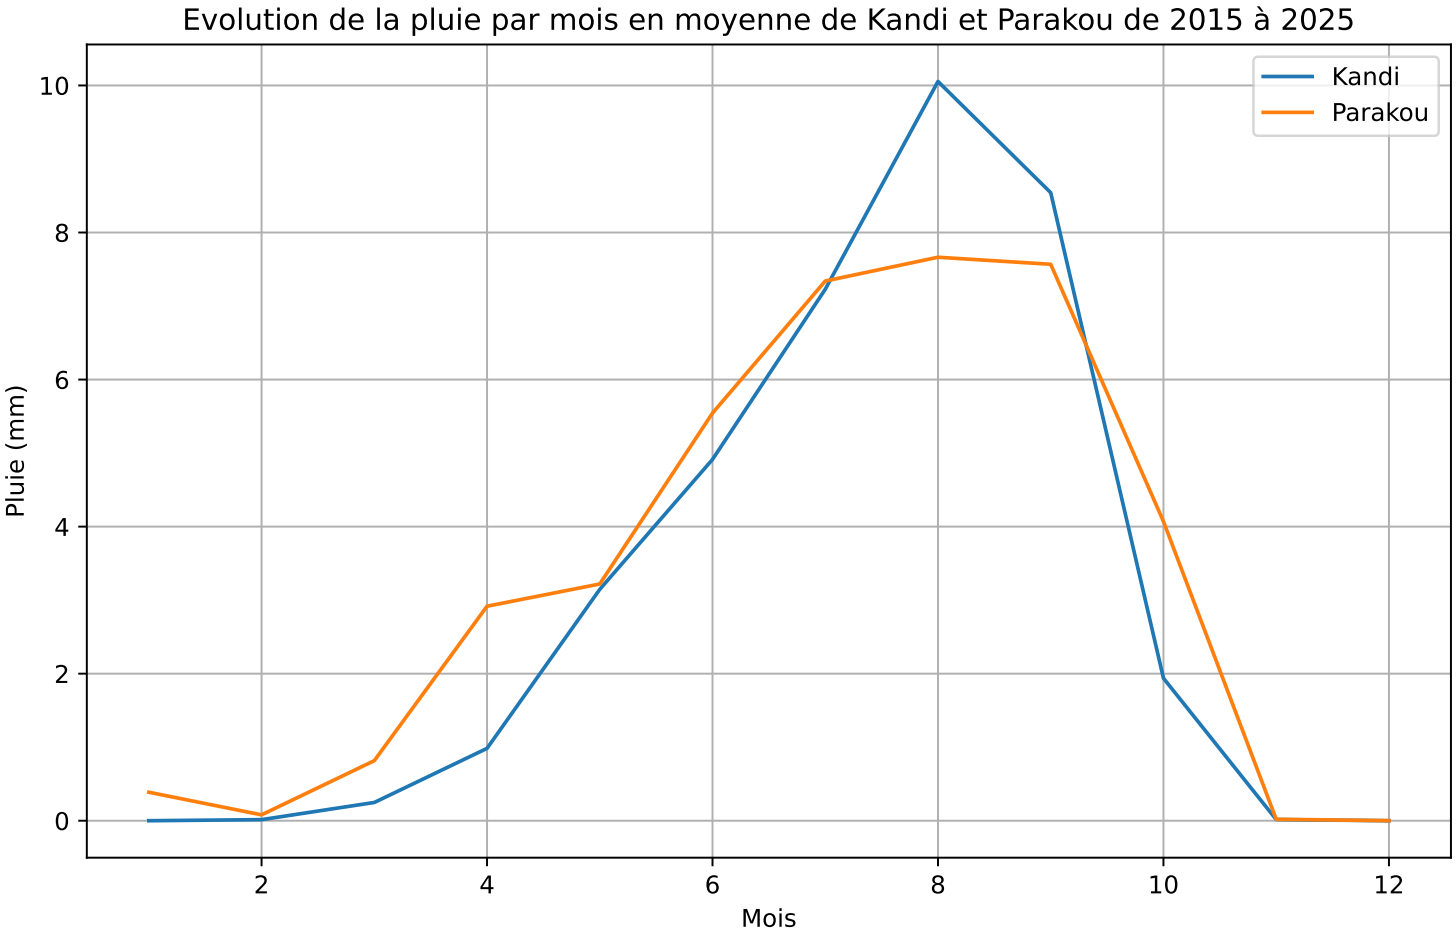
3.2.3 Variation de la pluie au fil du mois

Cette section consiste à déterminer en détail la relation entre la pluie et les mois dans les deux stations. Nous allons utiliser des graphiques de type heatmap pour visualiser la moyenne de la pluviométrie pour chaque mois de chaque

année dans les deux stations. Cela nous permettra de mieux comprendre les tendances saisonnières de la pluie dans ces deux régions.

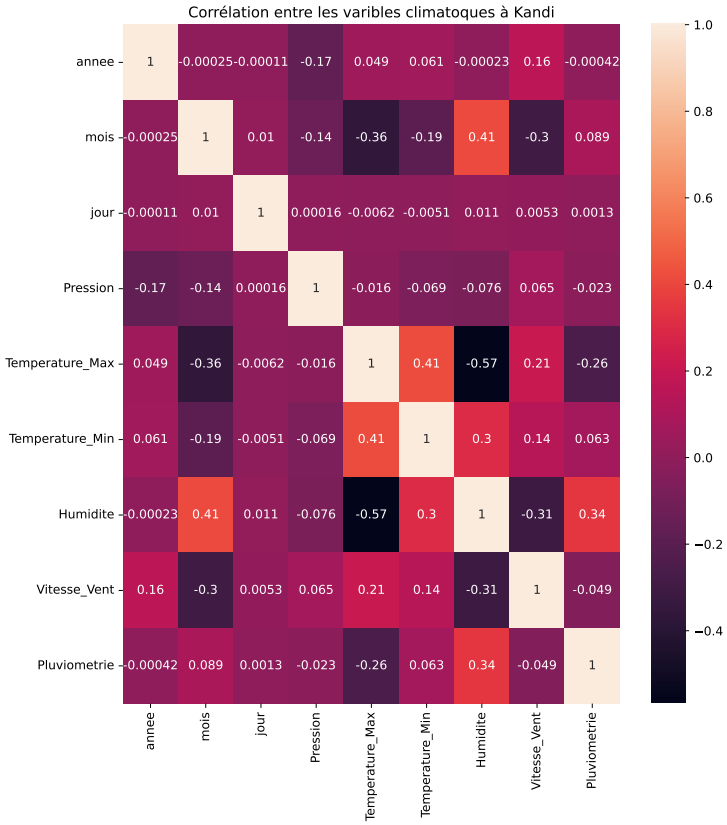


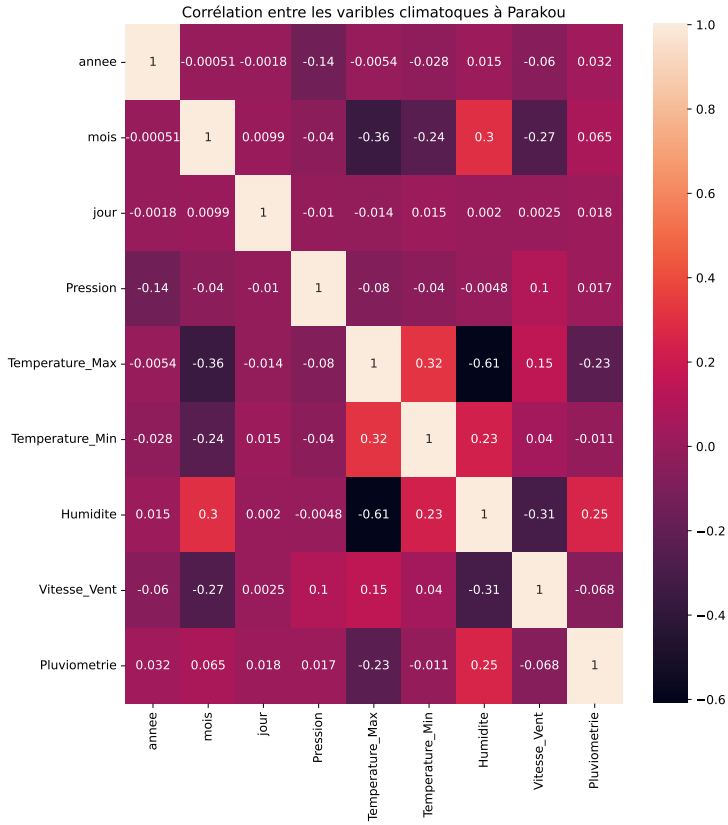
On constate que dans les deux stations, la pluie est plus abondante entre le mois mai et le mois octobre. Ce qui correspond à la saison des pluies dans les deux régions. De plus, les mois de juillet, aoûte et septembre sont les plus pluvieux dans une année des deux stations. En effet, en Janvier et decembre à Kandi, il n'a eu jamais de pluis. Les fortes pluies ont souvent eu lieu dans le mois de aoûte. Le graphe ci-dessous nous confirme bien que le mois d'aoûte est le mois le plus pluvieux dans les deux stations, surtout à Kandi.



3.2.4 Corrélation entre les variables climatiques

Dans cette section, nous allons analyser la corrélation entre les différentes variables climatiques dans les deux stations. Nous allons utiliser des matrices de corrélation et des graphiques de dispersion pour visualiser les relations entre les variables telles que la pression, la température maximale et minimale, l'humidité et la pluviométrie. Cela nous permettra de mieux comprendre comment ces variables interagissent entre elles et comment elles peuvent influencer la pluie dans ces deux régions.



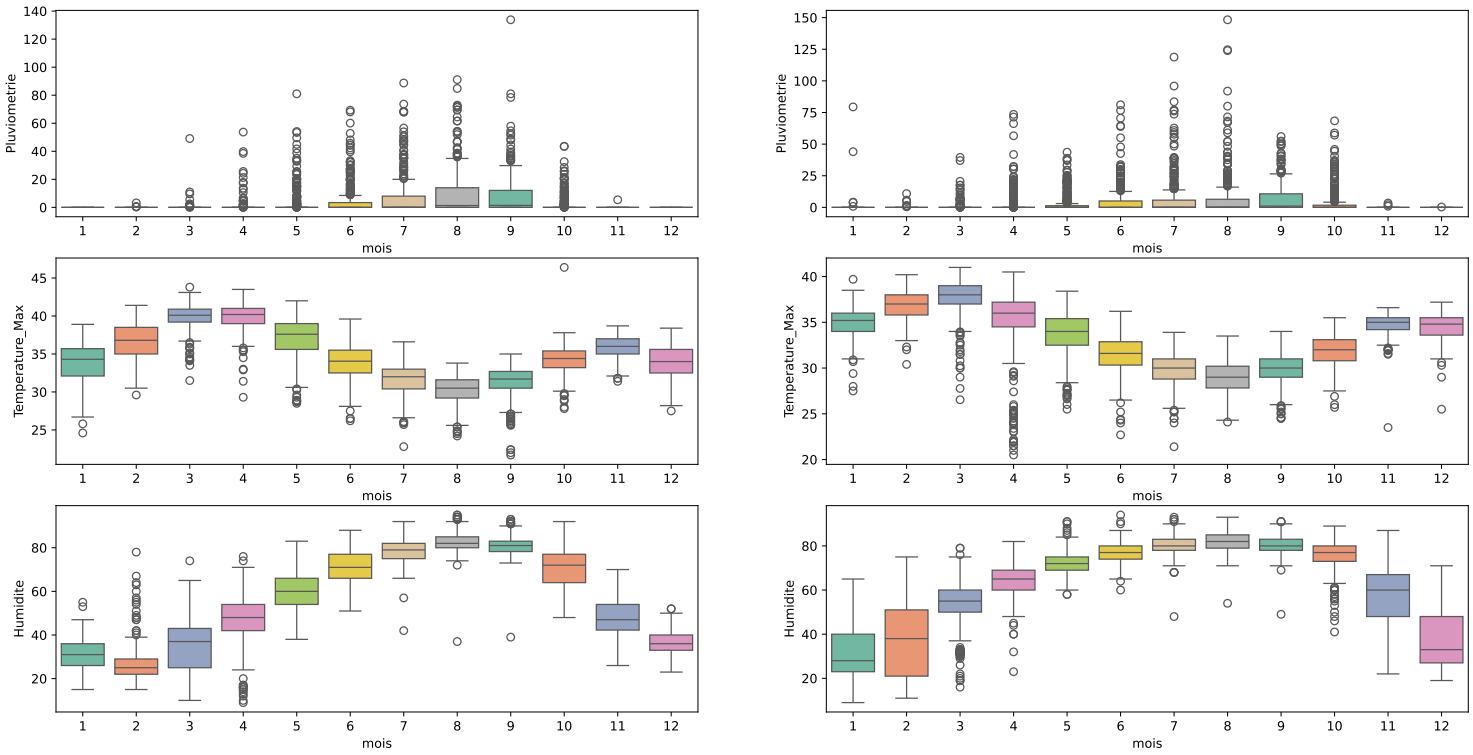


On constate que la pluviométrie est positivement corrélée avec l'humidité dans les deux stations. Ce qui montre que les jours les plus humides sont généralement ceux où il y a plus de pluie.

De plus, la pluviométrie est négativement corrélée avec la pression dans les deux stations. Ce qui suggère que les jours de forte pluie sont généralement associés à une pression atmosphérique plus basse.

Enfin, la température maximale est négativement corrélée avec la pluviométrie dans les deux stations. Ce qui suggère que les jours les plus froids sont généralement ceux où il y a plus de pluie. Ce qui est normal, car lorsqu'il pleut, la température est souvent plus basse.

3.2.5 Observation des valeurs extrême



On constate une nouvelle fois que les mois de juillet, août et septembre sont les plus pluvieux dans les deux stations. À cette période, la température maximale diminue et l'humidité augmente.

Ce qui confirme que les jours les plus froids et les plus humides sont généralement ceux où il y a le plus de pluie.

De plus, les événements de fortes pluies sont plus fréquents à Parakou qu'à Kandi, et ces fortes pluies sont plus fréquentes durant les mois de juillet, août et septembre que durant les autres mois de l'année.

3.2.6 Stationnarité de la pluie

Dans cette section, nous allons vérifier la stationnarité de la pluviométrie dans les deux stations. Voici un tableau récapitulatif des tests de stationnarité pour la pluviométrie à Kandi et à Parakou.

	Kandi	Parakou
ADF	-5.284479	-6.512807e+00
P-value	0.000006	1.089743e-08

Dans les deux stations, la p-value est inférieure à 0,05. Et donc, la pluviométrie est stationnaire dans les deux stations. Ce qui suggère que les propriétés statistiques de la pluviométrie ne changent pas énormément au fil du temps dans les deux stations. Par conséquent, nous pouvons utiliser des modèles de séries temporelles, surtout le modèle ARIMA, pour prévoir la pluviométrie dans les deux stations.

3.3 Conclusion

Dans ce mini-rapport, nous avons effectué une analyse exploratoire des données météorologiques des stations de Kandi et de Parakou de 2015 à 2025. Nous avons observé que la pluviométrie est plus abondante à Parakou qu'à Kandi, et que les mois de juillet, août et septembre sont les plus pluvieux dans une année des deux stations. De plus, nous avons constaté que la pluviométrie est positivement corrélée avec l'humidité et négativement corrélée avec la pression et la température maximale dans les deux stations. Enfin, nous avons vérifié que la pluviométrie est stationnaire dans les deux stations, ce qui suggère que nous pouvons utiliser des modèles de séries temporelles pour prévoir la pluviométrie dans ces deux régions.

4 Comparaison et choix des modèles pour la prévision pluviométrique

4.1 Introduction

Ce mini rapport consiste à comparer les modèles ARIMA, SARIMA, SARIMAX, Prophet et XGBoost pour la prévision pluviométrique. Nous allons utiliser les données de précipitations journalières pour évaluer les performances de chaque modèle et déterminer lequel est le plus adapté pour la prévision à long terme. Ces modèles seront comparés en utilisant des graphes et les deux métriques utilisées dans la partie prétraitement pour la comparaison des méthodes d'imputation : le RMSE et le MAE. Tous ces modèles seront entraînés sur les données de 2015 à 2023 et testés sur les données de 2024 à 2025.

4.2 Utilisation des modèles

4.2.1 Modèle ARIMA

4.2.1.1 Définition

Un modèle ARIMA (AutoRagressive Integrated Moving Average) est un modèle de séries temporelles qui décrit une variable observée comme une combinaison linéaire de ses valeurs passées, de ses erreurs passées et d'un éventuel processus de différenciation visant à assurer la stationnarité de la série, afin de réaliser des prévisions futures. Dans notre cas, le modèle ARIMA part du principe que la pluie d'aujourd'hui dépend de la pluie des jours précédents, ainsi que des erreurs de prévision passées. Il contient trois paramètres : p (ordre de l'auto-régression), d (degré de différenciation) et q (ordre de la moyenne mobile). On note souvent ce modèle ARIMA(p,d,q) pour indiquer les valeurs de ces paramètres.

Le paramètre p représente le nombre de termes d'auto-régression dans le modèle. Il indique combien de valeurs passées de la série temporelle sont utilisées pour prédire la valeur actuelle. Par exemple, si p=2, cela signifie que les deux dernières valeurs de la série temporelle sont utilisées pour faire la prévision.

Le problème avec ARIMA est qu'il impose que la série temporelle soit stationnaire, c'est-à-dire que ses propriétés statistiques ne changent pas au fil du temps. Le paramètre d représente le nombre de différenciations nécessaires pour rendre la série temporelle stationnaire. Par exemple, si d=1, cela signifie que nous devons différencier la série temporelle une fois pour la rendre stationnaire. Mais dans notre cas, la série temporelle de précipitations est stationnaire, donc d=0.

Le paramètre q indique combien de termes de moyenne mobile sont inclus dans le modèle. Il représente le nombre de valeurs passées des erreurs de prévision qui sont utilisées pour prédire la valeur actuelle. Par exemple, si q=1, cela signifie que l'erreur de prévision du jour précédent est utilisée pour faire la prévision du jour actuel.

Dans ce cas, le modèle ARIMA peut être représenté par l'équation suivante :

$Y_t = \alpha_1 Y_{t-1} + \alpha_2 Y_{t-2} + \epsilon_t + \beta_1 \epsilon_{t-1} + c$ (En supposant p=2, d=0 et q=1)

avec :

- Y_t : la valeur de la série temporelle à l'instant t
- α_1 et α_2 : les coefficients d'auto-régression
- ϵ_t : l'erreur de prévision à l'instant t
- β_1 : le coefficient de la moyenne mobile
- c : une constante

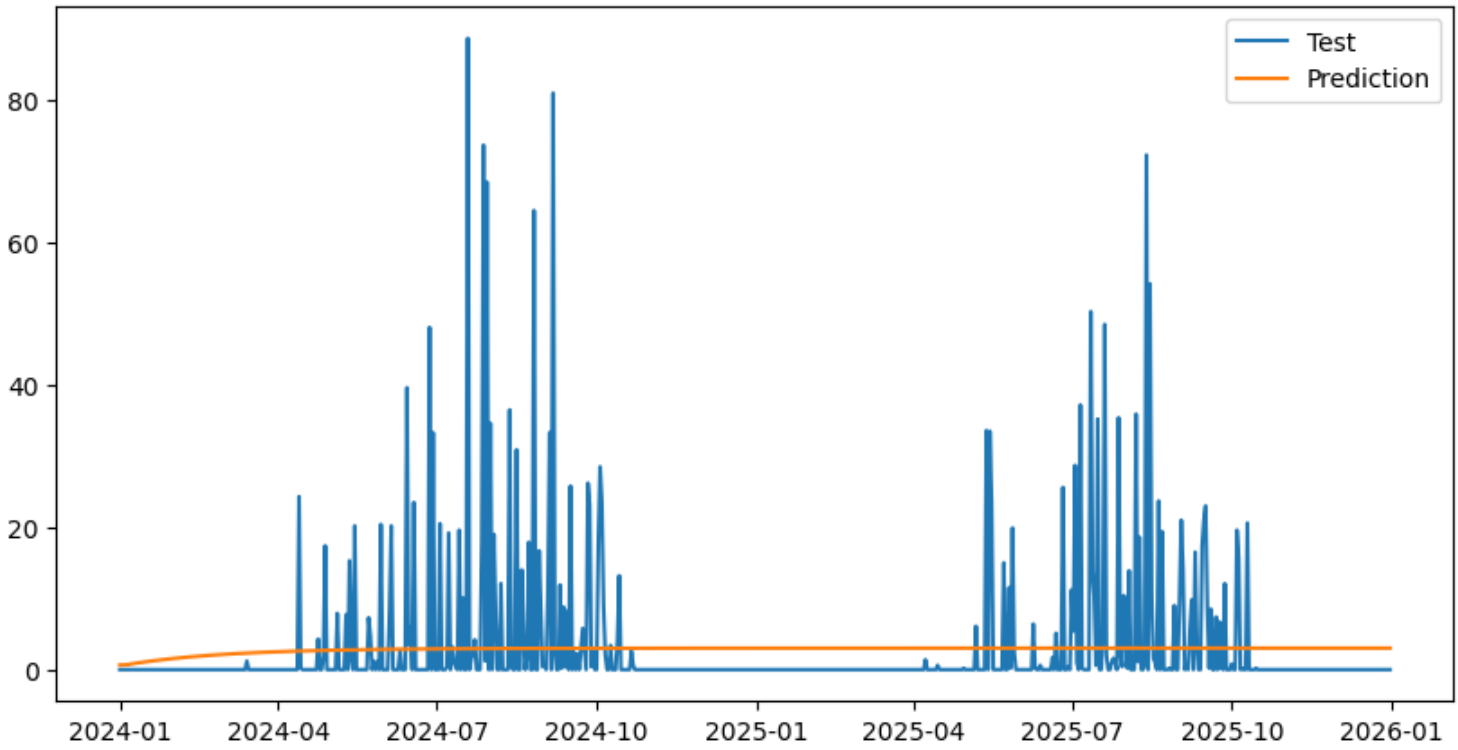
4.2.1.2 Résultats du modèle ARIMA

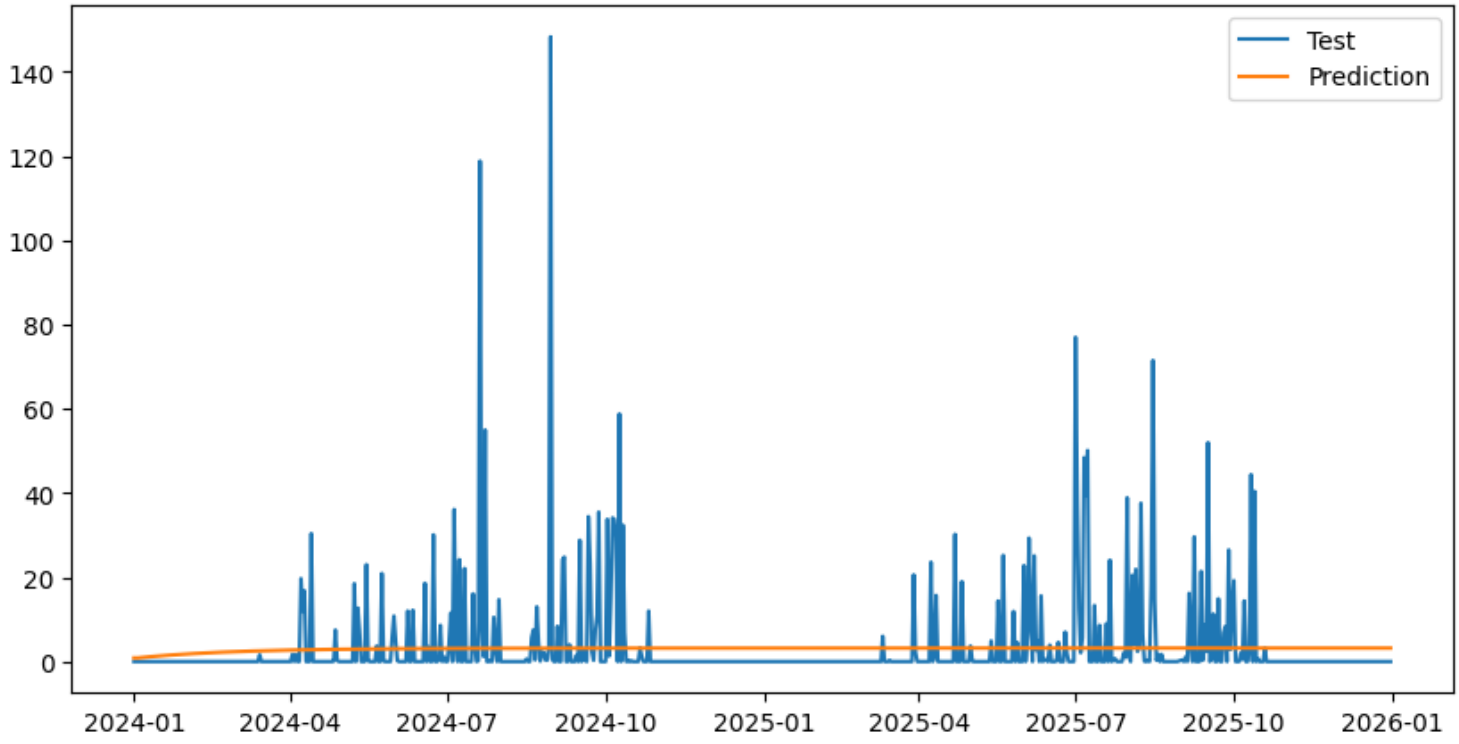
Après avoir ajusté le modèle ARIMA à nos données de précipitations, nous avons obtenu les résultats suivants :

Tableau des résultats du modèle ARIMA

Station	MAE	RMSE
Kandi	4.890643	9.851040
Parakou	5.270873	11.345777

Graphes des résultats du modèle ARIMA





On constate que le modèle ARIMA est plus performant à Kandi qu'à Parakou. Cela suggère que le modèle ARIMA est plus adapté pour la prévision des précipitations à Kandi qu'à Parakou. Cependant, les performances du modèle

ARIMA ne sont pas très satisfaisantes.

D'après les graphes précédents, on constate que dans la station Kandi, le modèle ARIMA arrive bien à prédire dans les mois de Janvier, Février, Mars, Avril, Mai, Novembre et de Décembre mais n'arrive pas à prédire dans les autres mois. Dans la station Parakou, le modèle ARIMA arrive bien à prédire dans les mois de Janvier, Février, Mars, Avril, Novembre et de Décembre mais n'arrive pas à prédire dans les autres mois. Et donc, le modèle n'est pas performant dans les mois de saison pluvieuse. Cela peut être dû au fait que le modèle ARIMA ne tient pas compte des composantes saisonnières. C'est pourquoi nous allons maintenant explorer le modèle SARIMA, qui prend en compte les composantes saisonnières de la série temporelle.

4.2.2 Modèle SARIMA

4.2.2.1 Définition

Un modèle SARIMA (Seasonal AutoRegressive Integrated Moving Average) est une extension du modèle ARIMA qui prend en compte les composantes saisonnières d'une série temporelle. Il inclut des termes supplémentaires pour modéliser les effets saisonniers, tels que les variations périodiques qui se produisent à des intervalles réguliers (par exemple, les précipitations qui varient selon les saisons). Le modèle SARIMA est défini par sept paramètres : p, d, q, P, D, Q et m. Les paramètres p, d et q sont les mêmes que ceux du modèle ARIMA, tandis que les paramètres P, D et Q représentent les composantes saisonnières du modèle. Le paramètre m indique la périodicité de la saisonnalité (par exemple, m=12 pour des données mensuelles avec une saisonnalité annuelle).

Pour notre cas, le modèle SARIMA peut être représenté par l'équation suivante :

$Y_t = \alpha_1 Y_{t-1} + \alpha_2 Y_{t-2} + \epsilon_t + \beta_1 \epsilon_{t-1} + \gamma_1 Y_{t-m} + \delta_1 \epsilon_{t-m} + c$ (En supposant p=2, d=0, q=1, P=1, D=0, Q=1 et m=7)

avec :

- Y_t : la valeur de la série temporelle à l'instant t
- α_1 et α_2 : les coefficients d'auto-régression
- ϵ_t : l'erreur de prévision à l'instant t
- β_1 : le coefficient de la moyenne mobile
- γ_1 : le coefficient d'auto-régression saisonnière
- δ_1 : le coefficient de la moyenne mobile saisonnière
- c : une constante

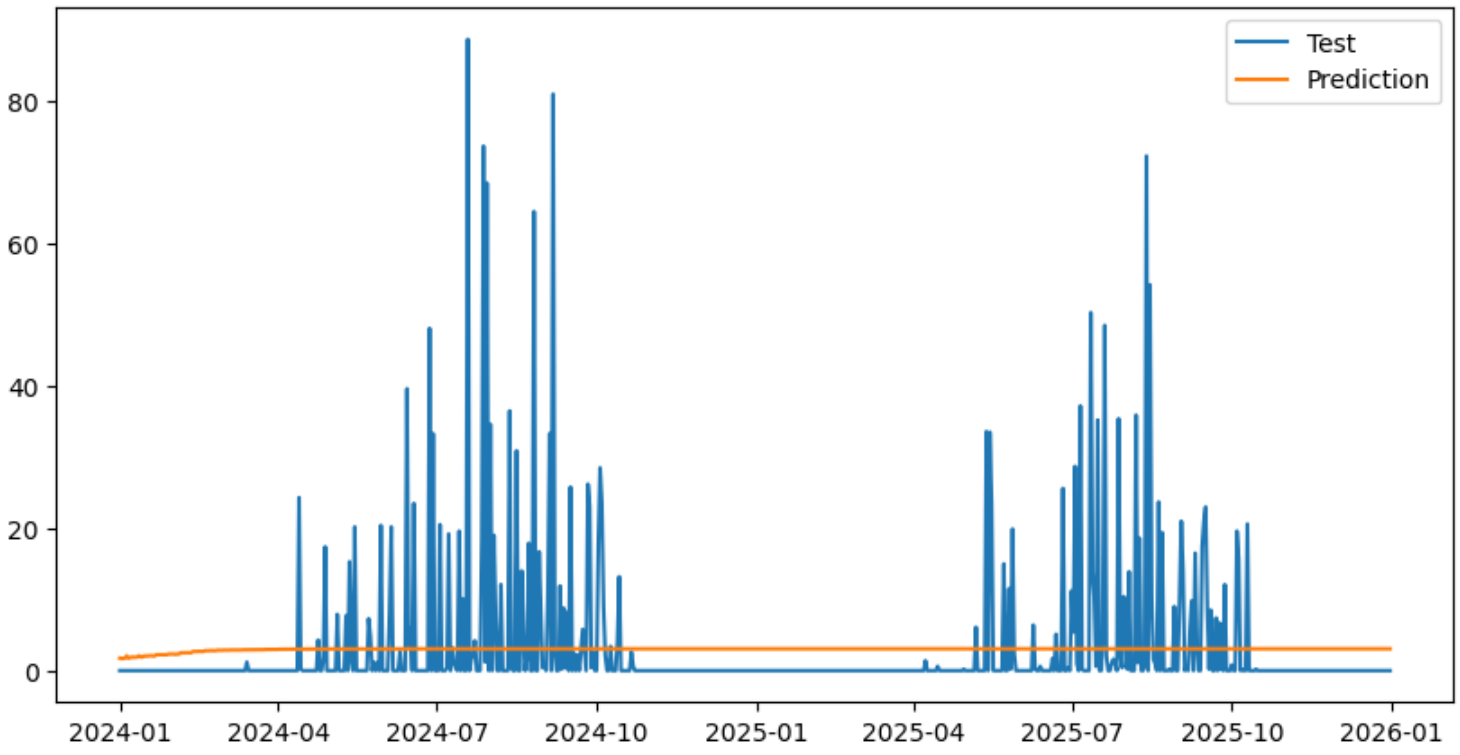
4.2.2.2 Résultats du modèle SARIMA

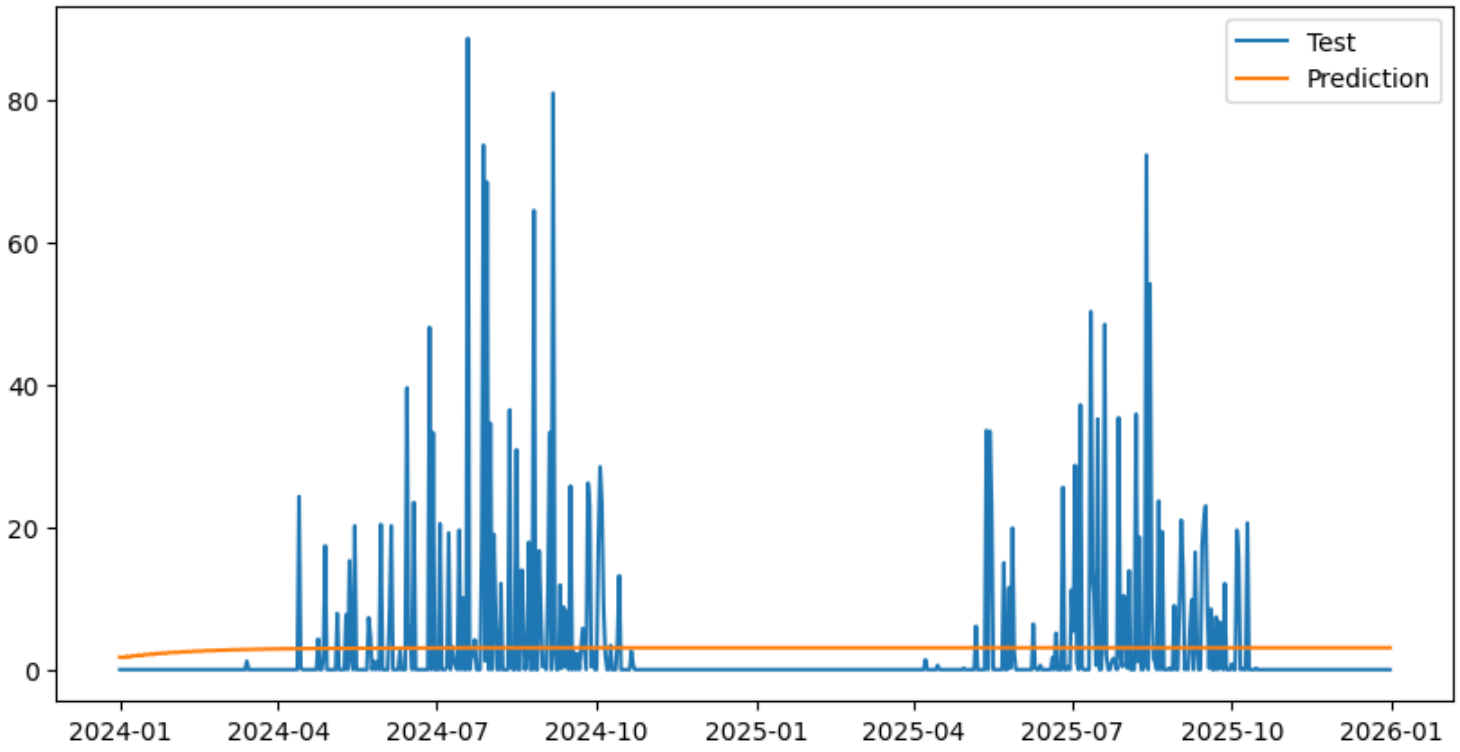
Après avoir ajusté le modèle SARIMA à nos données de précipitations avec m=7, nous avons obtenu les résultats suivants :

Tableau des résultats du modèle SARIMA

Station	MAE	RMSE
Kandi	5.036159	9.865430
Parakou	5.425908	11.360692

Graphes des résultats du modèle SARIMA





Bien que SARIMA prenne en compte une composante saisonnière, les résultats obtenus ne montrent pas d'amélioration par rapport à ARIMA. Cela peut indiquer que la saisonnalité hebdomadaire (m=7) n'est pas suffisamment marquée dans les données étudiées.

La question qui se pose est de savoir si l'ajout de variables exogènes (variables explicatives) dans le modèle SARIMA peut améliorer les performances du modèle. C'est pourquoi nous allons maintenant explorer le modèle SARIMAX, qui permet d'inclure des variables exogènes dans la modélisation.

4.2.3 Modèle SARIMAX

4.2.3.1 Définition

Un modèle SARIMAX (Seasonal AutoRegressive Integrated Moving Average with eXogenous regressors) est une extension du modèle SARIMA qui permet d'inclure des variables exogènes (variables explicatives) dans la modélisation. Dans notre cas, les variables explicatives seront la température maximale du jour precédent, la température minimale du jour précédent, l'humidité du jour précédent, la pression du jour précédent et la vitesse du vent du jour précédent. Le modèle SARIMAX est défini par les mêmes paramètres que le modèle SARIMA (p, d, q, P, D, Q et m), mais il inclut seulement des coefficients pour les variables exogènes.

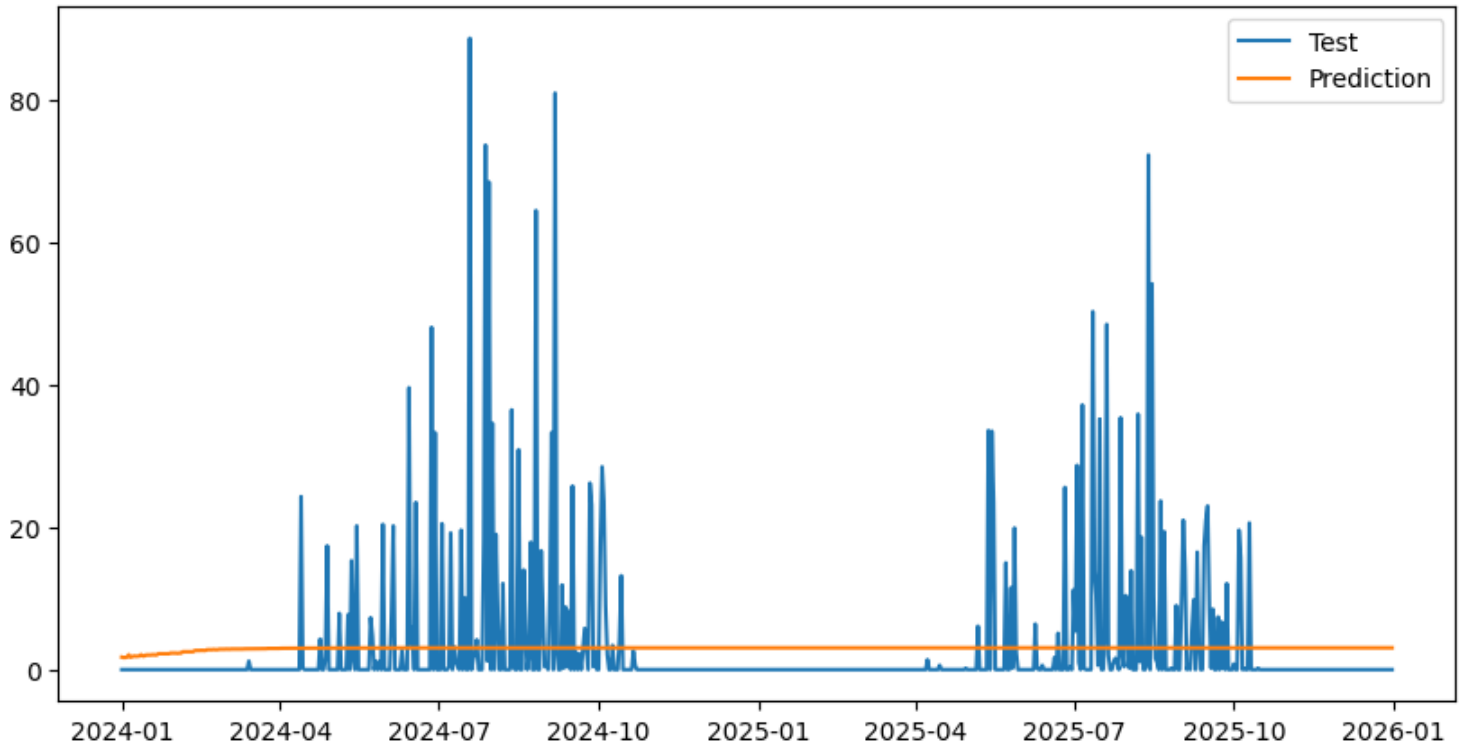
4.2.3.2 Résultats du modèle SARIMAX

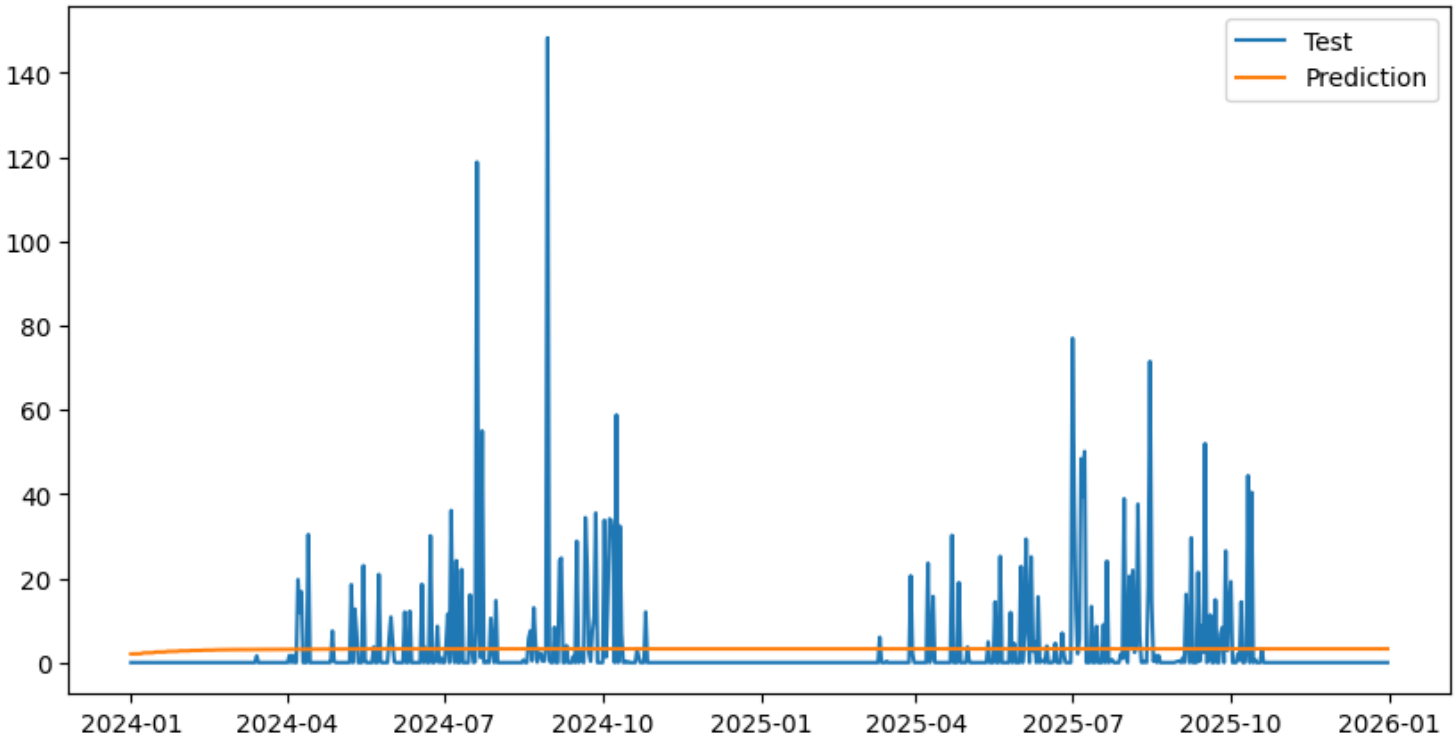
Après avoir ajusté le modèle SARIMAX à nos données de précipitations avec m=7, nous avons obtenu les résultats suivants :

Tableau des résultats du modèle SARIMAX

Station	MAE	RMSE
Kandi	5.032446	9.865653
Parakou	5.426609	11.360670

Graphes des résultats du modèle SARIMAX





Apparemment, l'ajout des variables exogènes n'a pas amélioré les performances du modèle SARIMA. Cela peut être dû à plusieurs facteurs, tels que la qualité des données exogènes, la relation entre les variables exogènes et la variable cible (précipitations), ou encore la complexité du modèle. Il est possible que les variables exogènes utilisées ne soient pas suffisamment informatives pour améliorer les prévisions de précipitations, ou que le modèle SARIMAX ne soit pas le meilleur choix pour capturer les relations entre les variables. C'est pourquoi nous allons maintenant explorer le modèle Prophet.

4.2.4 Modèle Prophet

4.2.4.1 Définition

Le modèle Prophet est un modèle de prévision de séries temporelles développé par Facebook. Il est conçu pour être facile à utiliser et à interpréter, tout en étant capable de gérer des données avec des tendances non linéaires, des saisonnalités multiples et des jours fériés. Le modèle Prophet décompose une série temporelle en trois composantes principales : la tendance, la saisonnalité et les jours fériés. La tendance capture les changements à long terme dans la série temporelle, la saisonnalité capture les variations périodiques (par exemple, les précipitations qui varient selon les saisons), et les jours fériés capturent les effets spécifiques liés à des dates particulières. Le modèle Prophet utilise une approche de régression pour modéliser ces composantes, ce qui permet de faire des prévisions futures en extrapolant les tendances et les saisonnalités identifiées dans les données historiques. Le modèle Prophet est particulièrement efficace pour les séries temporelles avec des tendances non linéaires et des saisonnalités multiples, ce qui en fait un choix populaire pour la prévision de données telles que les précipitations.

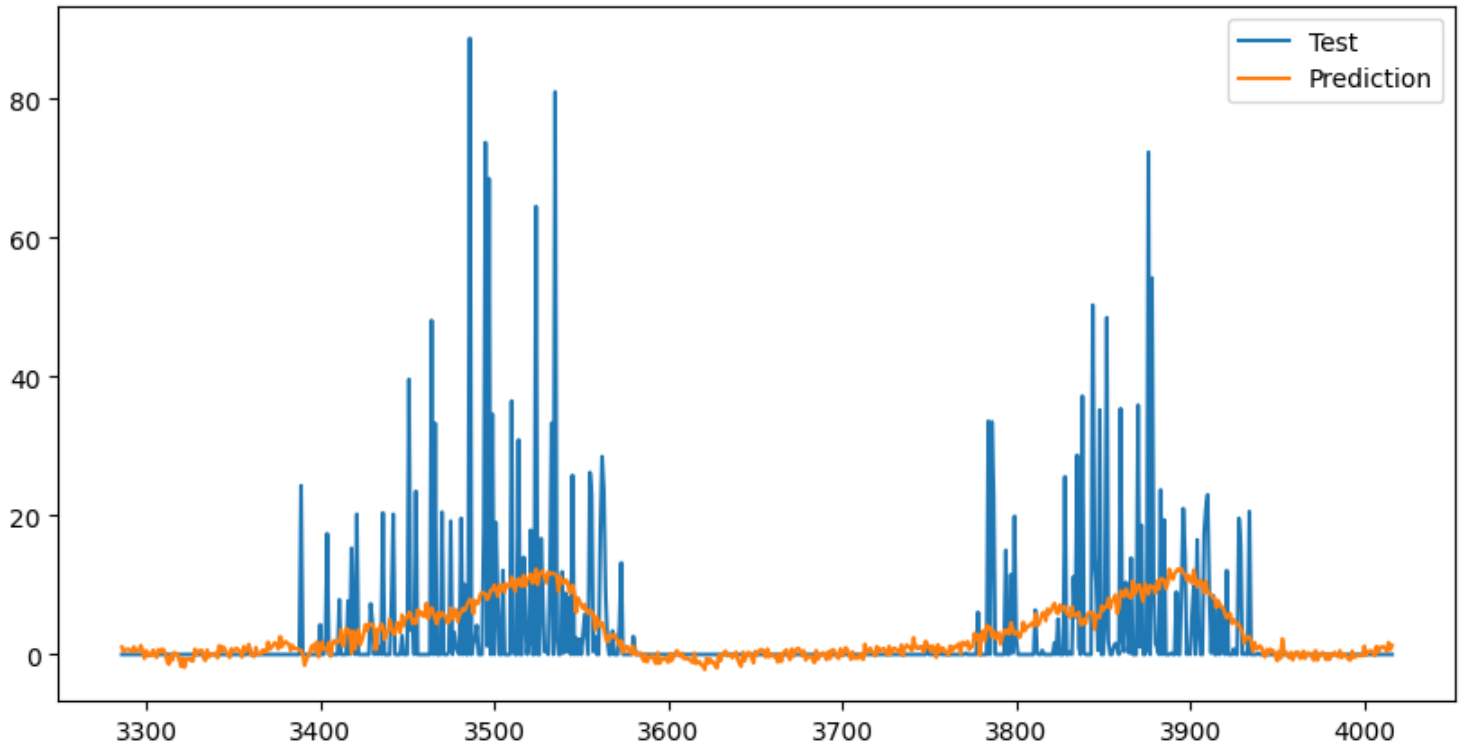
4.2.4.2 Résultats du modèle Prophet

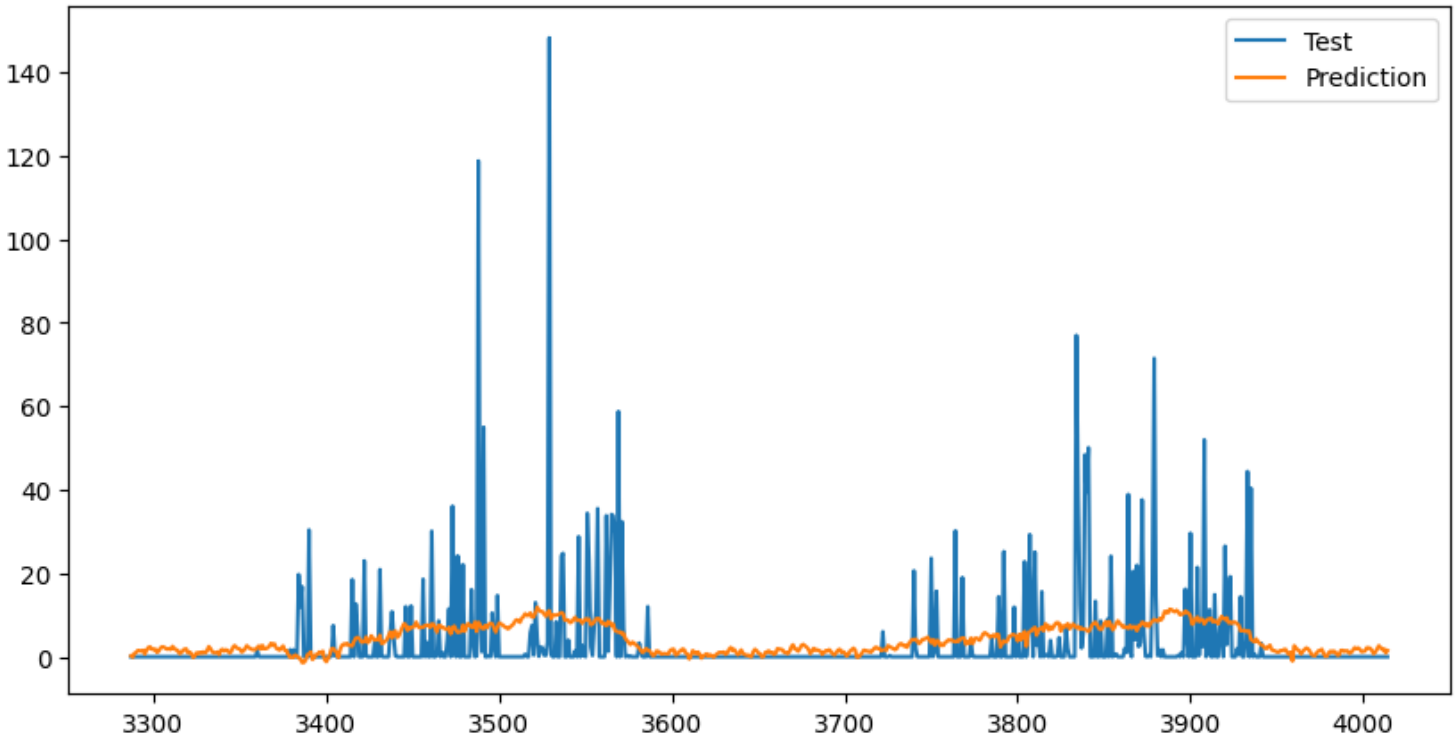
Après avoir ajusté le modèle Prophet à nos données de précipitations, nous avons obtenu les résultats suivants :

Tableau des résultats du modèle Prophet

Station	MAE	RMSE
Kandi	4.310590	9.199159
Parakou	5.436776	10.935978

Graphes des résultats du modèle Prophet





On constate que le modèle Prophet est plus performant que les modèles ARIMA, SARIMA et SARIMAX, surtout à Kandi et corrige partiellement les erreurs des autres modèles dans les mois de saisons de pluviométrie. Cela suggère que le modèle Prophet est plus adapté pour la prévision des précipitations à Kandi et à Parakou que les autres modèles. Le modèle Prophet est capable de capturer les tendances non linéaires et les saisonnalités multiples présentes dans les données de précipitations, ce qui peut expliquer ses meilleures performances par rapport aux modèles ARIMA, SARIMA et SARIMAX. Cependant, nous allons maintenant explorer le modèle XGBoost.

4.2.5 Modèle XGBoost

4.2.5.1 Description du modèle XGBoost

Le model XGBoost (eXtreme Gradient Boosting) est un algorithme de machine learning basé sur un ensemble d'arbres de décision construits séquentiellement. Chaque nouvel arbre cherche à corriger les erreurs commises par les arbres précédents. Pour la prévision pluviométrique, le modèle utilise des variables explicatives telles que les valeurs retardées de la pluie, les moyennes mobiles et les variables météorologiques afin de prédire les précipitations futures. Le modèle XGBoost est particulièrement efficace pour capturer les relations non linéaires et les interactions complexes entre les variables, ce qui peut être bénéfique pour la prévision des précipitations, qui sont souvent influencées par de nombreux facteurs météorologiques. De plus, XGBoost intègre des mécanismes de régularisation pour éviter le surapprentissage, ce qui peut améliorer la généralisation du modèle sur de nouvelles données.

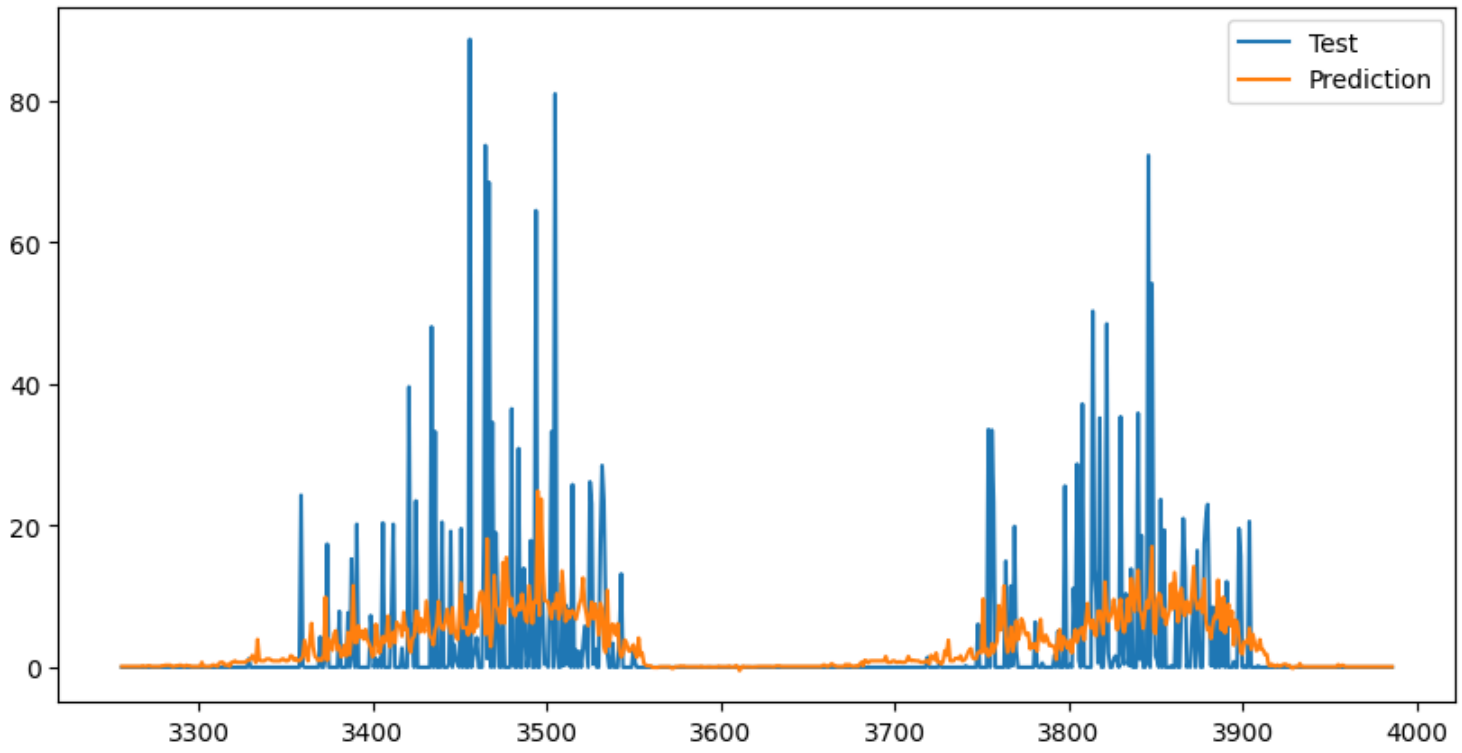
4.2.5.2 Résultats du modèle XGBoost

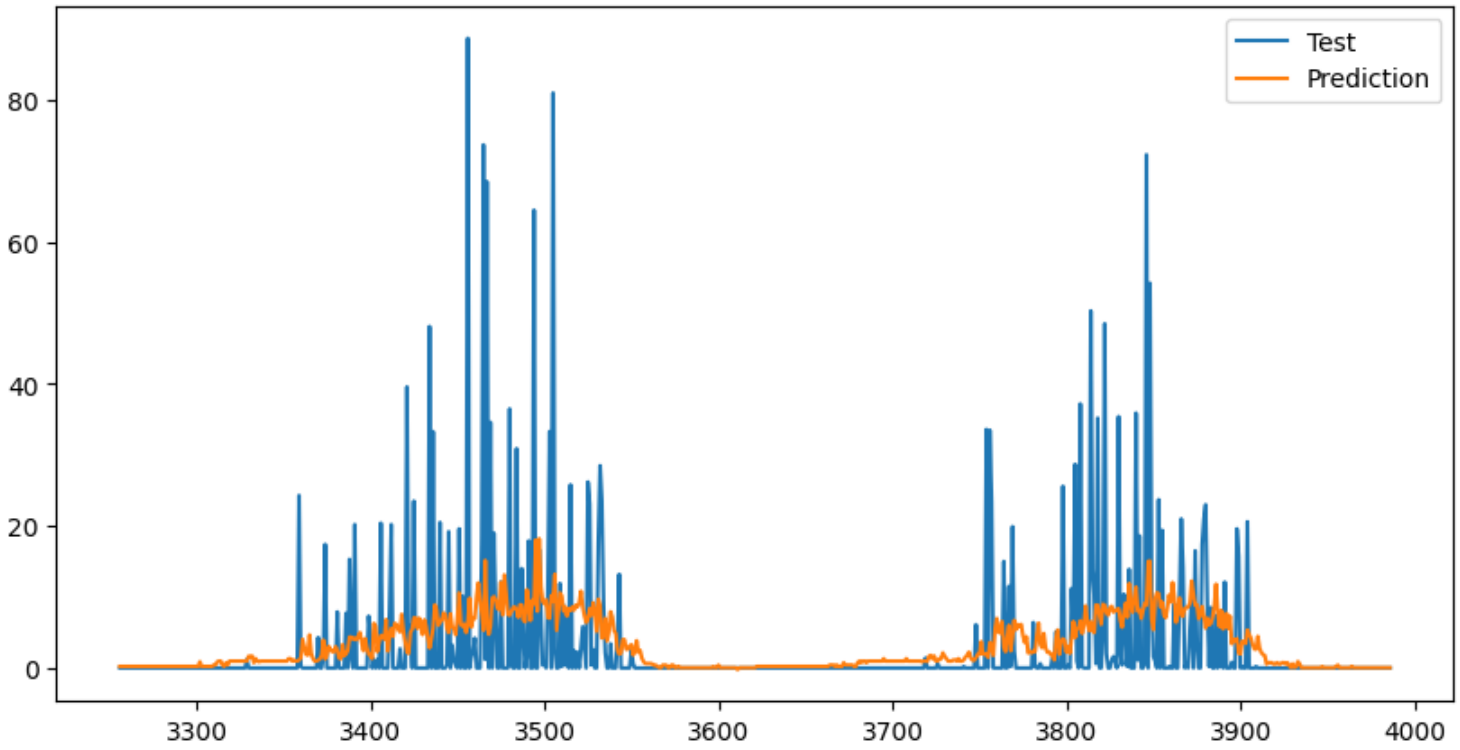
Les hyperparamètres du modèle XGBoost ont été optimisés à l'aide de la validation croisée temporelle (TimeSeriesSplit) combinée à une recherche par grille (GridSearchCV), permettant d'identifier la combinaison de paramètres minimisant l'erreur de prévision. Nous avons obtenu les résultats suivants :

Tableau des résultats du modèle XGBoost

Station	MAE	RMSE
Kandi	4.363779	9.385307
Parakou	5.059537	11.089638

Graphes des résultats du modèle XGBoost





XGBoost a montré des performances comparables à celles du modèle Prophet, avec une légère amélioration à Parakou. Cela suggère que le modèle XGBoost est également adapté pour la prévision des précipitations à Kandi et à Parakou. Le modèle XGBoost est capable de capturer les tendances non linéaires et les interactions complexes entre les variables, ce qui peut expliquer ses bonnes performances par rapport aux autres modèles.

4.3 Conclusion

Voilà un tableau récapitulatif des performances de tous les modèles à Kandi et à Parakou :

_____KANDI_____

Model	MAE	RMSE
Prophet	4.310590	9.199159
XGBoost	4.363779	9.385307
ARIMA	4.890643	9.851040
SARIMAX	5.032446	9.865653
SARIMA	5.036159	9.865430

_____PARAKOU_____

Model	MAE	RMSE
XGBoost	5.059537	11.089638
ARIMA	5.270873	11.345777
SARIMA	5.425908	11.360692
SARIMAX	5.426609	11.360670
Prophet	5.436776	10.935978

Les résultats montrent qu'aucun modèle n'est systématiquement supérieur sur toutes les stations. À Kandi, Prophet présente les meilleures performances en termes de MAE et de RMSE, tandis qu'à Parakou XGBoost obtient le meilleur compromis entre précision et capacité de généralisation. Mais pour un bon résultat au niveau des mois de saison pluvieuse, le mieux est d'utiliser le modèle XGBoost dans les deux stations.

Etant donné que les modèles Prophet et XGBoost ont montré des performances comparables, le choix entre les deux peut dépendre de facteurs tels que la facilité d'interprétation du modèle, la disponibilité des données exogènes et les ressources informatiques disponibles pour l'entraînement du modèle. En conclusion, le modèle XGBoost semble être le plus adapté pour la prévision des précipitations à Kandi et à Parakou, en particulier pendant les mois de saison pluvieuse, grâce à sa capacité à capturer les relations non linéaires et les interactions complexes entre les variables météorologiques.

La performance de XGBoost nous encouragent à explorer d'autres modèles de Machine Learning, tels que LightGBM, CatBoost Extra Trees, Random Forest etc… pour voir si on peut faire mieux que XGBoost. Mais on peut aussi faire du stacking pour combiner les prévisions de plusieurs modèles afin d'améliorer la précision globale des prévisions. Par exemple, on pourrait combiner les prévisions de Prophet et XGBoost en utilisant une technique de stacking, où les prévisions de chaque modèle sont utilisées comme entrées pour un modèle de méta-apprentissage (par exemple, une régression linéaire) qui apprend à pondérer les prévisions de chaque modèle pour produire une prévision finale plus précise.

On peut s'arrêter là pour ce mini rapport.

5 Conclusion générale

Dans ce projet, nous avons suivi un processus complet de prétraitement, d'analyse exploratoire et de modélisation pour la prévision pluviométrique à partir de données météorologiques. Nous avons commencé par traiter les données brutes, en identifiant et en imputant les valeurs manquantes à l'aide de différentes méthodes. Nous avons ensuite effectué une analyse exploratoire pour comprendre les tendances et les relations entre les variables météorologiques. Enfin, nous avons comparé plusieurs modèles de prévision, notamment ARIMA, SARIMA, SARIMAX, Prophet et XGBoost, pour déterminer lequel était le plus adapté pour la prévision des précipitations à Kandi et à Parakou. Les résultats ont montré que le modèle XGBoost offrait les meilleures performances globales, en particulier pendant les mois de saison pluvieuse. Ce projet a permis d'acquérir une compréhension approfondie du processus de prévision pluviométrique et des techniques de modélisation associées, tout en mettant en évidence l'importance du choix du modèle en fonction des caractéristiques spécifiques des données et des objectifs de prévision.