**REPUBLIQUE DU BENIN**
=-=-=-=-=-=
**Ministère de l'Enseignement Supérieur et de la Recherche Scientifique**
=-=-=-=-=-=
**UNIVERSITE NATIONALE DES SCIENCES, TECHNOLOGIES, INGENIERIE ET MATHEMATIQUES**
=-=-=-=-=-=
**FACULTE DES SCIENCES ET TECHNIQUES DE NATITINGOU**

**N° attribué par la bibliothèque**

/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/ _/

# RAPPORT DE STAGE ACADEMIQUE

Domaine : Science et technologie.

Mention : Sciences et Techniques.

Spécialité : Mathématiques - Informatique.

## THÈME

# Modèle prédictif basé sur l'intelligence artificielle pour la prévision des pluies au Bénin : cas de Kandi et de Parakou

**Présenté par** :

BODJRENOU Marcellin Vignon

**Dirigé par**

**Tuteur :**

**Dr. ELEGBEDE Chabi Fabrice**

Enseignant - Chercheur

FAST Natingou

**Maître stage :**

**Mr. OUSSOU** Dagbénagni Djidjoho Gad

DSI METEO-BENIN

Année accadémique : 2025 - 2026

# *Resumé*

Dans le cadre de ma formation en Licence en Mathématiques et Informatique à la Faculté des Sciences et Techniques (FAST) de Natitingou, j'ai effectué un stage académique à la Météo-Bénin. Au cours de ce stage, j'ai mis en pratique les connaissances acquises durant ma formation à travers la réalisation d'un projet. Ce projet vise à développer un modèle de prévision capable de prédire de la pluviométrie dans deux stations météorologiques : Kandi et Parakou. Face aux défis que représente la variabilité des précipitations pour l'agriculture et d'autres secteurs d'activité, cette étude a pour objectif d'analyser les données météorologiques afin d'identifier les tendances et les anomalies, puis de déterminer le modèle offrant les meilleures performances de prévision pour les deux stations. Cette étude s'appuiera sur les données journalières de la pluviométrie, de la pression atmosphérique, de l'humidité, de la température maximale et minimale ainsi que de la vitesse du vent, couvrant la période de 2015 à 2025. En effet, conscient de l'importance de l'imputation pour une bonne prévision, cinq (05) méthodes d'imputation (moyenne globale, médiane globale, interpolation linéaire, moyenne historique et médiane historique) sont comparées et on constate que l'interpolation linéaire est la méthode qui impute le mieux les valeurs manquantes. Après l'imputation, une analyse exploratoire des données nous a permis à savoir, généralement, que les données de pluviométrie sont stationnaires. il est donc pertinent de tester les modèles ARIMA, SARIMA et SARIMAX. Ensuite en comparant les performances des modèles ARIMA, SARIMA, SARIMAX, Prophet et XGBoost, avec les métriques MAE et RMSE (entrainés sur les données de 2015 à 2023 et testés sur les données de 2024 à 2025), on constate que XGBoost est le modèle qui prédit le mieux la pluie, surtout pendant les moments de fortes précipitations. Mais l'inconvénient de l'utilisation de ce modèle est qu'il ne peut pas prédire à longue terme. Ce stage nous a permis de renforcer nos compétences en programmation, en analyse de données et en modélisation statistique. Il nous a également permis d'appliquer des notions théoriques acquises au cours de notre formation, notamment en statistiques et en probabilités, tout en découvrant les réalités du monde professionnel.

**Marcellin V. BODJRENOU**

# *Summary*

As part of our Bachelor's degree in Mathematics and Computer Science at the Faculty of Science and Technology (FAST) of Natitingou, I completed an academic internship at Météo-Bénin. During this internship, I put into practice the knowledge acquired during my studies through the implementation of a project. This project aims to develop a forecasting model capable of predicting rainfall at two meteorological stations : Kandi and Parakou. Faced with the challenges posed by rainfall variability for agriculture and other sectors of activity, this study aims to analyze meteorological data in order to identify trends and anomalies, and then determine the model providing the best forecasting performance for the two stations. This study is based on daily data of rainfall, atmospheric pressure, humidity, maximum and minimum temperature, as well as wind speed, covering the period from 2015 to 2025. Indeed, aware of the importance of imputation for accurate forecasting, five (05) imputation methods (global mean, global median, linear interpolation, historical mean, and historical median) are compared, and it is observed that linear interpolation is the method that best imputes the missing values. After the imputation, an exploratory data analysis allowed us to determine that, in general, the rainfall data are stationary. It is therefore relevant to test the ARIMA, SARIMA, and SARIMAX models. Then, by comparing the performance of the ARIMA, SARIMA, SARIMAX, Prophet, and XGBoost models using the MAE and RMSE metrics (trained on data from 2015 to 2023 and tested on data from 2024 to 2025), it is observed that XGBoost is the model that best predicts rainfall, especially during periods of heavy precipitation. However, the disadvantage of using this model is that it cannot perform long-term forecasting. This internship enabled us to strengthen our skills in programming, data analysis, and statistical modeling. It also enabled us to apply the theoretical concepts acquired during our studies, particularly in statistics and probability, while discovering the realities of the professional world.

**Marcellin V. BODJRENOU**

# *Dédicace*

Je dédie ce travail à :

★ **Mes parents**, pour leur amour inconditionnel, leur soutien moral et financier tout au long de mes études. Leur confiance en moi a été une source de motivation constante.

**Marcellin V. BODJRENOU**

# *Remerciements*


- ♠ Je rends d'abord grâce à **Dieu Tout-Puissant** pour la vie, la santé, la sagesse et la force qu'Il m'a accordé tout au long de ce travail. Sans son soutien invisible et constant, rien de tout ceci n'aurait été possible.
- ♠ Je tiens ensuite à exprimer ma profonde gratitude à mes encadreurs, Docteur **Chabi Fabrice ELEGBEDE** et Monsieur **OUSSOU Gad Dagbénagni Djidjoho**, pour leur soutien indéfectible, leurs conseils précieux et leur patience tout au long de ce projet. Leur expertise et dévouement ont été des sources d'inspiration constantes.
- ♠ Je remercie également l'ensemble des enseignants et du personnel de la Faculté des Sciences et Techniques (**FAST**) pour avoir fourni un environnement académique propice à l'apprentissage et à la recherche. Leur engagement envers l'éducation de qualité a été essentiel pour la réalisation de ce projet.
- ♠ Je souhaite exprimer ma reconnaissance envers mes **collègues étudiants** pour leur camaraderie, leur collaboration et les échanges fructueux que nous avons eus. Leur soutien et leur encouragement ont été d'une grande aide.
- ♠ Enfin, j'adresse ma reconnaissance à ma famille, mes amis et toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce rapport par leur soutien moral, leurs encouragements et leurs prières.

**Marcellin V. BODJRENOU**

# Table des matières


**I Présentation générale des structures de formation et de stage 1**

1 Présentation de l'établissement de formation : FAST de Natitingou . . . . . 2
- 1.1 Situation géographique . . . . . 2
- 1.2 La création et l'évolution . . . . . 2
- 1.3 Les personnels administratifs et enseignants . . . . . 3
- 1.4 Infrastructures, mobiliers et matériels didactiques de la FAST . . . . . 3

2 Présentation du lieu de stage : METEO-BENIN . . . . . 4
- 2.1 Situation géographique . . . . . 4
- 2.2 La création et l'évolution . . . . . 4
- 2.3 Les personnels administratifs de la METEO-BENIN . . . . . 5
- 2.4 Infrastructures et matériels didactiques de la METEO-BENIN . . . . . 5

3 Organisations administratives et pédagogique . . . . . 5

4 Programmes de stage . . . . . 6

5 Présentation de Suivi évaluation . . . . . 7

6 Difficultés rencontrées et remédiations apportées aux difficultés . . . . . 7

7 Leçons apprises . . . . . 7

8 Impressions générales et suggestions . . . . . 7

**II Développement du thème 9**

1 Introduction générale . . . . . 10

2 Prétraitement des données et comparaison des méthodes d'imputation des valeurs manquantes . . . . . 10
- 2.1 Introduction . . . . . 10
- 2.2 Aperçu général des tables de données reçues . . . . . 10
- 2.3 Présentation des données . . . . . 11
- 2.4 Feature Engineering . . . . . 11
- 2.5 Prétraitement des données météorologies . . . . . 13
- 2.6 Conclusion . . . . . 17

3 Analyse exploratoire des données météorologiques . . . . . 17
3.1 Introduction . . . . . 17
3.2 Analyse des données météorologiques . . . . . 18
3.3 Conclusion . . . . . 23
4 Comparaison et choix des modèles pour la prévision pluviométrique . . . . . 23
4.1 Introduction . . . . . 23
4.2 Utilisation des modèles . . . . . 24
4.3 Conclusion . . . . . 30
5 Conclusion générale et perspectives . . . . . 31
6 ANNEXE . . . . . 34

# Liste des tableaux


1 Personnels administratifs de la FAST . . . . . 3
2 Infrastructures, mobiliers et matériels didactiques de la FAST . . . . . 3
3 Personnels administratifs de la METEO-BENIN . . . . . 5
4 Infrastructures, mobiliers et matériels didactiques de la METEO-BENIN . . . . 5
5 Aperçu générale des données . . . . . 10
5 Aperçu générale des données . . . . . 11
6 Aperçu du nouveau jeu de données de la station de Kandi . . . . . 12
7 Aperçu du nouveau jeu de données de la station de Parakou . . . . . 13
8 les lignes très incompletes dans les données de Parakou . . . . . 14
9 les lignes très incompletes dans les données de Kandi . . . . . 14
10 Résultats d'imputations à Kandi . . . . . 16
11 Résultats d'imputations à Parakou . . . . . 16
12 Description statistique des données de Kandi et Parakou . . . . . 18
13 Tableau de stationnarité . . . . . 23
14 Résultats du modèle ARIMA . . . . . 25
15 Résultats du modèle SARIMA . . . . . 26
16 Résultats du modèle SARIMAX . . . . . 27
17 Résultats du modèle Prophet . . . . . 28
18 Résultats du modèle XGBoost . . . . . 30
19 Tableau des performances des modèles à Kandi, classées selon le MAE . . . . 30
20 Tableau des performances des modèles à Parakou, classées selon le MAE . . . 30

# Table des figures


1 Situation géographique de la METEO-BENIN . . . . . 4
2 Une image de la METEO-BENIN . . . . . 5
3 Organigramme de la METEO-BENIN . . . . . 6
4 Visualisation des valeurs manquantes à Kandi et Parakou . . . . . 14
5 Comparaison des MAE à Kandi et à Parakou . . . . . 17
6 Distribution et densité de la pluie à Kandi et Parakou . . . . . 19
7 Moyenne de la pluie par mois de chaque année à Kandi et à Parakou . . . . . 20
8 Evolution de la pluie par mois en moyenne de Kandi et Parakou de 2015 à 2025 20
9 Corrélation entre les varibles climatiques à Kandi et à Parakou . . . . . 21
10 Observation des valeurs extrêmes à Kandi et Parakou . . . . . 22
11 Evolution des valeurs réelles et des valeurs prédites par ARIMA . . . . . 25
12 Evolution des valeurs réelles et des valeurs prédites par SARIMA . . . . . 26
13 Evolution des valeurs réelles et des valeurs prédites par SARIMAX . . . . . 27
14 Evolution des valeurs réelles et des valeurs prédites par Prophet . . . . . 29
15 Evolution des valeurs réelles et des valeurs prédites par XGBoost . . . . . 30

# Liste des sigles

**FAST :** Faculté des Sciences et Techniques

**DSI :** Directeur des Systèmes Informatiques

**DPAF :** Directeur de la Planification et de l'Administration des Finances

**DCAM :** Directeur de la Climatologie et des Applications Météorologiques

**CAI :** Cellule d'Audit Interne

**DPROM :** Directeur de la Prévision et du Réseau d'Observation Météorologique

**UNSTIM :** Université Nationale des Sciences, Technologies, Ingenierie et Mathématiques

# Première partie

# Présentation générale des structures de formation et de stage

# Introduction

Toute formation nécessite un terrain d'expérience de tous les savoirs acquis au préalable. Dans le domaine des sciences techniques, c'est encore plus nécessaire pour un enseignant et/ou chercheur en devenir de prendre par un stage académique en vue de renforcer ou du moins, mettre en pratique les connaissances théoriques acquises pour nourrir ses capacités intellectuelles et ses savoir-faire afin d'être qualifié, compétant et apte à accomplir sa noble mission. C'est pour cette raison que, à la fin de notre formation à la Faculté des Sciences et Techniques de Natitingou, nous avons été envoyés à la Direction Nationale de la Météorologie du Bénin (METEO-BENIN) pour notre stage académique sous la tutelle de Mr. OUSSOU Gad Dagbénangni Djidjoho, le Directeur des Systèmes Informatiques (DSI) en service à la METEO-BENIN. Débuté le lundi 18 Mai 2026, ce stage a duré environ un mois au cours duquel nous avons mené des activités d'ordre technique et scientifique. Cette première partie de notre rapport fera une présentation de notre structure de formation, de notre lieu de stage et du bilan des activités menées.

# 1 Présentation de l'établissement de formation : FAST de Natitingou

## 1.1 Situation géographique

La FAST de NATITINGOU est située dans le département de l'Atacora et précisément dans la commune de Natitingou au Nord de la République du Bénin. La commune s'étend sur une superficie de $3045 Km^2$, soit 12.8 % de la superficie totale du département et compte 65 villages et quartiers de ville répartis dans neuf (09) arrondissements selon la RGPH4 2013. Son relief est de type accidenté, composé surtout de la chaîne de l'Atacora, de plateaux et de collines dont les vallées se présentent souvent en pente forte. D'une façon générale, la FAST-NATITINGOU est limitée au nord par l'EPP-Ourbouga, au sud à environ 1 Km de la place KABA, à l'EST par la pharmacie EDEN et à l'Ouest à quelques mètres de CFL. Le sol est latéritique et son altitude est de 1018 de l'altitude Nord et 122 de longitude Est par rapport à la commune de Cotonou. La faculté est située dans le quartier Ourbouga au bord de la voie inter-État Bénin-Burkina Faso. Il se retrouve au sein de l'Ecole Normale Supérieure de Natitingou.

## 1.2 La création et l'évolution

La FAST-NATITINGOU est créée par Arrêté N°529/MESRS/CAB/DC/SGM/DRFM/ST-REGIE du 13 octobre 2011 portant création des facultés à caractère spécifique en République du Bénin et a pour mission principale de dispenser des enseignements de qualité en sciences

et en techniques, de promouvoir la recherche scientifique et applications, et de contribuer au développement socio-économique du pays. De 2011 à 2016, la FAST-NATITINGOU comportait les filières à savoir : la PC, SVT et la MI. Par contre de 2016 à présent les offres de formations ont été améliorées et elle compte actuellement la MI et la PC.

## 1.3 Les personnels administratifs et enseignants

La Fast-Natitingou est composé de personnel enseignant et administratifs qui sont regroupé dans le tableau suivant :

| **Nom et Prénoms** | **Fonctions** |
|---|---|
| Dr HOUNDJO M.J. Stéphane | Doyen de la FAST-Natitingou |
| Dr FATONDJI Raymond | Vice-Doyen de la FAST-Natitingou |
| M. N'KOUEI D. Marius | Secrétaire Général d'Entité |
| Dr ELEGBEDE Chabi Fabrice | Chef Département de la Mathématique et Informatique |
| Dr ADECHINAN A. Joseph | Chef Département de la Physique |
| Dr YOVO Franck | Chef Département de la Chimie |
| Dr KOUKPEMEDJI A. Audran | Chef Service de la Scolarité et Examen |
| Mr TANGAOU Alimi | Comptable de la FAST-Natitingou |
| Mr YETONDJI Iyonic | Chef Matériel |
| Mme KORAIMOROU Cathoumie | Secrétaire des Services Administratif |
| Mr KOUAGRE K. Jean | Assistant des Services Informatique |
| Mr TAMOU Chabi | CVA |
| Mr ABDOULAYE Moussiliou | Chef Division Scolarité |
| Mr BASSONGUI Orousèko | Secrétaire des Services Administratif |

TABLE 1 – Personnels administratifs de la FAST

## 1.4 Infrastructures, mobiliers et matériels didactiques de la FAST

La Fast-Natitingou dispose de quelques infrastructures, des mobiliers et de matériels didactiques contenus dans le tableau ci-dessous :

| **Titre** | **Infrastructures** | **Mobiliers** | **Matériels didactiques** |
|---|---|---|---|
| Désignation | Salle de cours, Salle d'informatique, Bibliothèque, Espace d'activité Sportive, Salle de chimie, Salle des professeurs, Bloc administratif | Une restauration, l'infirmerie, le foyer Abdoulaye Issa, Obéci | Vidéo projecteur, tableau d'affichage, groupe électrogène |

TABLE 2 – Infrastructures, mobiliers et matériels didactiques de la FAST

# 2 Présentation du lieu de stage : METEO-BENIN

## 2.1 Situation géographique

L'Agence Nationale de la Météorologie (METEO-BENIN) est située à Cotonou, sur la route de l'aéroport, non-loin du carrefour menant au restaurant Makoomba (BP 379).

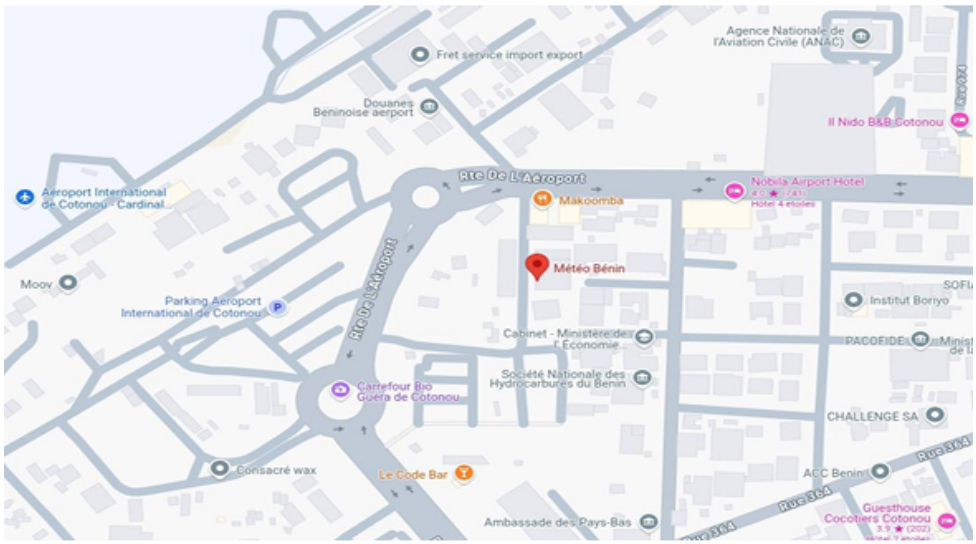



FIGURE 1 – Situation géographique de la METEO-BENIN

## 2.2 La création et l'évolution

Le service météorologique du Bénin a été créé en 1970 pendant la période coloniale. Il a été géré directement par l'administration coloniale, puis confié à l'Agence pour la Sécurité de la Navigation Aérienne (ASECNA). En janvier 2004, dans le cadre de la restructuration du sous secteur de l'aviation, le gouvernement du Bénin a décidé de créer une Agence Nationale de l'Aviation Civile (ANAC) et une Direction Nationale de la Météorologie (DNM). Ce dernier n'as pas fonctionné jusqu'à nomination du premier DNM en novembre 2010. Ainsi l'Agence Nationale de la Météorologie (Météo Bénin) est créé le 7 septembre 2015 pour remplacer la Direction Nationale de la Météorologie (DNM). Celle-ci devient effectivement opérationnelle le 1er janvier 2016. L'Agence Nationale de la Météorologie (Météo Bénin) a pour mission principale d'observer, d'analyser, d'étudier et de prévoir les conditions météorologiques, climatiques et les composants atmosphériques de l'environnement. Son objectif est d'assurer la sécurité des individus et des biens dans le domaine de la météorologie et de la climatologie.



FIGURE 2 – Une image de la METEO-BENIN

## 2.3 Les personnels administratifs de la METEO-BENIN

La METEO-BENIN est composée des personnels administratifs qui sont regroupé dans le tableau suivant :

| **Nom et Prénoms** | **Fonctions** |
|---|---|
| Mr. KAKPA Didier | DCAM |
| Mr. OUSSOU Dagbénagni Djidjoho Gad | DSI |
| Mr. AWLE Comlan Alfred | CAI |
| Mr. ANATO Boris | DPROM |
| Mr. TCHEHO S. Dieudonné | DPAF |

TABLE 3 – Personnels administratifs de la METEO-BENIN

## 2.4 Infrastructures et matériels didactiques de la METEO-BENIN

La METEO-BENIN dispose de quelques infrastructures et de matériels didactiques contenus dans le tableau ci-dessous :

| **Titre** | **Infrastructures** | **Matériels didactiques** |
|---|---|---|
| Désignation | Service informatique, Salle des stagiaires, Salle des serveurs, Bloc administratif | Vidéo projecteur, groupe électrogène |

TABLE 4 – Infrastructures, mobiliers et matériels didactiques de la METEO-BENIN

# 3 Organisations administratives et pédagogique

L'organigramme de l'entreprise se présente comme suit :

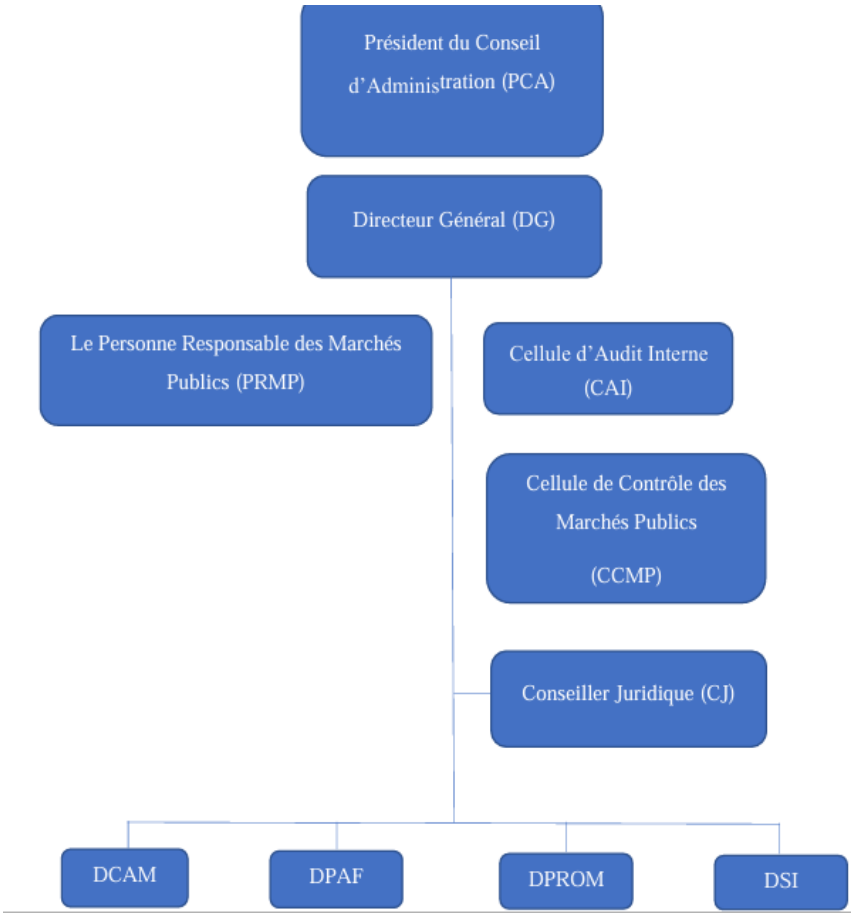



FIGURE 3 – Organigramme de la METEO-BENIN

# 4 Programmes de stage

Notre stage a débuté le 18 Mai 2026 et a pris fin le 17 juin 2026. Dès le premier jour, nous avons rencontré le personnel administratif de la METEO-BENIN et notre maître stage. Nous avions pris connaissance du contrat de stage de la METEO-BENIN. Nous travaillons des jours réguliers comme suit : lundi au vendredi de 8 h à 12 h 30 mn et de 14 h à 17 h 30 mn . Au cours de notre stage nous avons effectué quelques activités techniques et scientifiques tels que :

1. Collecte des données météorologiques
2. Prétraitement des données météorologiques
3. Analyse exploratoire des données météorologiques
4. Développement de modèle de prédiction

# 5 Présentation de Suivi évaluation

Au cours de notre stage nous avons reçu des conseils, des reproches, et des corrections venant de notre maître de stage et des autres membres de l'organisme. En effet, notre maître de stage nous a aidés à nous améliorer dans la rédaction de notre rapport de stage.

# 6 Difficultés rencontrées et remédiations apportées aux difficultés

Au cours de notre stage, nous avons rencontré plusieurs difficultés tels que :

1. *Mise en œuvre des modèles de prévision :* Elle a nécessité l'acquisition de nouvelles connaissances en analyse de séries temporelles et en programmation. Plusieurs ajustements et essais ont été effectués avant d'obtenir des résultats satisfaisants.
2. *Temps du stage :* Les contraintes de temps liées au stage n'ont pas permis de mener à terme certaines étapes envisagées, notamment l'exploration de modèles de prévision supplémentaires ainsi que le déploiement opérationnel du modèle développé.

# 7 Leçons apprises

Les enseignements tirés de ce programme de stage sont multiples. La nécessité de l'interaction a été clairement observée, les échanges entre stagiaires et maître de stage ayant été très bénéfiques, soulignant ainsi l'importance de la collaboration dans un environnement professionnel. Enfin, la flexibilité et la capacité d'adaptation ont constitué une leçon essentielle, la nécessité de s'adapter rapidement aux imprévus s'étant imposée comme une compétence indispensable pour l'ensemble des participants.

# 8 Impressions générales et suggestions

Notre stage académique à la METEO-BENIN a été une expérience extrêmement enrichissante malgré les difficultés rencontrées. Il nous a permis de mieux comprendre les applications concrètes de nos connaissances en probabilités, en statistiques et en informatique, sans oublier celles acquises dans les autres matières étudiées au cours de notre formation. Nous exprimons notre gratitude à la FAST de Natitingou pour son engagement dans l'organisation et le démarrage des stages cette année malgré les contraintes de temps. Cette initiative nous a permis de passer

un temps significatif dans un environnement professionnel et d'apprendre les tenants et les aboutissants du monde du travail. Toutefois, nous suggérons d'augmenter la durée des stages afin de permettre une immersion plus approfondie en milieu professionnel. Nous sommes également reconnaissants envers la METEO-BENIN pour son accueil chaleureux, le temps qui nous a été consacré et le suivi attentif dont nous avons bénéficié tout au long du stage. Le temps passé aux côtés du Directeur des Systèmes Informatiques nous a permis de grandir professionnellement et de mieux appréhender les réalités du métier, qui exige passion, conscience professionnelle et rigueur. Malgré les difficultés rencontrées, nous avons pu identifier nos faiblesses et trouver des solutions grâce aux précieux conseils de nos encadreurs.

# Conclusion partielle

En conclusion, le stage effectué à la Météo Bénin a constitué une expérience enrichissante pour l'ensemble des participants. Il nous a permis de renforcer nos connaissances théoriques et de développer des compétences pratiques dans un environnement professionnel réel. On a pu progresser de manière significative grâce aux différentes activités réalisées et à l'encadrement dont on a bénéficié. Dans l'ensemble, cette expérience a été positive et formatrice. Les observations et suggestions formulées seront prises en compte afin d'améliorer davantage la qualité des futurs programmes de stage à la Météo Bénin.

# Deuxième partie

# Développement du thème

# 1 Introduction générale

La météorologie occupe une grande importance dans plusieurs domaines de la vie quotidienne notamment l'agriculture et les transports. Grâce aux stations météorologiques, une grande quantité de données telles que la température, l'humidité, la pression atmosphériques et le vent est collectée chaque jour. Cependant, l'analyse de ces données afin de prévoir les précipitations demeure une tâche complexe en raison des variations climatiques. Face à ces difficultés, les techniques d'intelligence artificielle et d'apprentissage automatique offrent aujourd'hui des solutions éfficaces pour améliorer la prédiction des pluies.

Dans le cas de ce stage, notre projet consiste à analyser les données météorologiques des stations de Parakou et de Kandi, de 2015 à 2025, et à développer un modèle capable de prédire la pluie à partir des variables climatiques. Dans le cadre de ce projet, le langage Python, notamment les bibliothèques Pandas, NumPy, Seaborn, Matplotlib, Missingno et Scikit-Learn, sera utilisé au sein de l'extension Quarto afin de réaliser l'analyse des données et de développer un modèle prédictif.

# 2 Prétraitement des données et comparaison des méthodes d'imputation des valeurs manquantes

## 2.1 Introduction

Dans le cadre de notre stage portant sur la conception d'un modèle prédictif basé sur l'intélligence artifficielle pour la prévision des pluies, une étape importante de prétraitement des données a été réalisée. Cette étape consiste à :

— créer des jeux de données spécifiques à chaque station ;
— analyser les valeurs manquantes ;
— comparer plusieurs méthodes d'imputation ;
— sélectionner la méthode la plus performante.

## 2.2 Aperçu général des tables de données reçues

TABLE 5 – Aperçu générale des données

| | Name | Geogr1 | Geogr2 | Year | Eg el abbreviation | Name.1 | Description | Month | Time | 01 | ... | 22 | ... |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | KANDI_AEROPORT | 2.9333 | 11.1333 | 2015 | PSTAD | Pression Station Moy | hPa | 1 | 06 :00 | 979.9 | ... | 979.6 | ... |
| 1 | KANDI_AEROPORT | 2.9333 | 11.1333 | 2015 | PSTAD | Pression Station Moy | hPa | 2 | 06 :00 | 977.7 | ... | 977.4 | ... |
| 2 | KANDI_AEROPORT | 2.9333 | 11.1333 | 2015 | PSTAD | Pression Station Moy | hPa | 3 | 06 :00 | 978.6 | ... | 974.8 | ... |
| 3 | KANDI_AEROPORT | 2.9333 | 11.1333 | 2015 | PSTAD | Pression Station Moy | hPa | 4 | 06 :00 | 978.5 | ... | 975.9 | ... |
| 4 | KANDI_AEROPORT | 2.9333 | 11.1333 | 2015 | PSTAD | Pression Station Moy | hPa | 5 | 06 :00 | 973.9 | ... | 977.8 | ... |

TABLE 5 – Aperçu générale des données

| | Name | Geogr1 | Geogr2 | Year | Eg el abbreviation | Name.1 | Description | Month | Time | 01 | ... | 22 | ... |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 1572 | PARAKOU_AEROPORT | 2.6000 | 9.3500 | 2025 | WFF | Vit moy vent10 | m/s | 8 | 06 :00 | 1.9 | ... | 2.1 | ... |
| 1573 | PARAKOU_AEROPORT | 2.6000 | 9.3500 | 2025 | WFF | Vit moy vent10 | m/s | 9 | 06 :00 | 2.4 | ... | 1.4 | ... |
| 1574 | PARAKOU_AEROPORT | 2.6000 | 9.3500 | 2025 | WFF | Vit moy vent10 | m/s | 10 | 06 :00 | 2.1 | ... | 2.6 | ... |
| 1575 | PARAKOU_AEROPORT | 2.6000 | 9.3500 | 2025 | WFF | Vit moy vent10 | m/s | 11 | 06 :00 | 2.0 | ... | 2.8 | ... |
| 1576 | PARAKOU_AEROPORT | 2.6000 | 9.3500 | 2025 | WFF | Vit moy vent10 | m/s | 12 | 06 :00 | 1.6 | ... | 1.6 | ... |

## 2.3 Présentation des données

Les colonnes présentent dans les données sont :

```
Index(['Name', 'Geogr1', 'Geogr2', 'Year', 'Eg el abbreviation', 'Name.1',
       'Description', 'Month', 'Time', '01', '02', '03', '04', '05', '06',
       '07', '08', '09', '10', '11', '12', '13', '14', '15', '16', '17', '18',
       '19', '20', '21', '22', '23', '24', '25', '26', '27', '28', '29', '30',
       '31'],
      dtype='str')
```

Nous disposons de données issues de deux stations météorologiques : Kandi et Parakou. De plus, nous avons reçu les données de pression (en hPa), de pluie journalière (en mm), de température maximale et minimale (en °C), d'humidité (en %) et de vitesse du vent (en m/s). Les données fournies constituent un dataframe dans lequel chaque ligne représente une information précise (pression ou température ou humidité ou etc.) des 31 jours d'un mois pour une année donnée.

## 2.4 Feature Engineering

Pour la réalisation de notre projet, les données reçues ne sont pas encore dans un format adéquat pour procéder à la gestion des valeurs manquantes. Pour cela, nous allons d'abord créer notre propre jeu de données.

### 2.4.1 Création de nouvelles variables : année, mois et jour de Kandi et de Parakou

Étant donné que notre mission est de prédire, pour un jour précis, la pluviométrie, alors notre jeu de donnés doit contenir, au minimum pour une observation, les information qui permettront d'identifier ce jour. Nous avons donc besoin des variables année, mois et jour. Après la création de ces variables, voici la structure de notre jeu de données :

**Station de Kandi**

| | Lieu | annee | mois | jour |
|---|---|---|---|---|
| 0 | KANDI_AEROPORT | 2015 | 1 | 1 |
| 1 | KANDI_AEROPORT | 2015 | 1 | 2 |
| 2 | KANDI_AEROPORT | 2015 | 1 | 3 |
| 3 | KANDI_AEROPORT | 2015 | 1 | 4 |
| 4 | KANDI_AEROPORT | 2015 | 1 | 5 |
| ... | ... | ... | ... | ... |
| 4013 | KANDI_AEROPORT | 2025 | 12 | 27 |
| 4014 | KANDI_AEROPORT | 2025 | 12 | 28 |
| 4015 | KANDI_AEROPORT | 2025 | 12 | 29 |
| 4016 | KANDI_AEROPORT | 2025 | 12 | 30 |
| 4017 | KANDI_AEROPORT | 2025 | 12 | 31 |

**Station de Parakou**

| | Lieu | annee | mois | jour |
|---|---|---|---|---|
| 0 | PARAKOU_AEROPORT | 2015 | 1 | 1 |
| 1 | PARAKOU_AEROPORT | 2015 | 1 | 2 |
| 2 | PARAKOU_AEROPORT | 2015 | 1 | 3 |
| 3 | PARAKOU_AEROPORT | 2015 | 1 | 4 |
| 4 | PARAKOU_AEROPORT | 2015 | 1 | 5 |
| ... | ... | ... | ... | ... |
| 4013 | PARAKOU_AEROPORT | 2025 | 12 | 27 |
| 4014 | PARAKOU_AEROPORT | 2025 | 12 | 28 |
| 4015 | PARAKOU_AEROPORT | 2025 | 12 | 29 |
| 4016 | PARAKOU_AEROPORT | 2025 | 12 | 30 |
| 4017 | PARAKOU_AEROPORT | 2025 | 12 | 31 |

### 2.4.2 Création de nouvelles variables : Pression, température, vitesse de vent, humidité et pluviométrie

Les variables créées précédemment ne suffisent pas pour expliquer la variable cible : pluviométrie. Pour cela, nous allons créer les variables pression, température (maximale et minimale), vitesse du vent et humidité qui constituent, avec les variabes année, mois et jour, les variables explicatives. Après la création de ces variables, voici la structure de notre jeu de données :

**Station de Kandi**

TABLE 6 – Aperçu du nouveau jeu de données de la station de Kandi

| | Lieu | annee | mois | jour | Pression | Temperature_Max | Temperature_Min | Humidite | Vitesse_Vent | Pluviometrie |
|---|---|---|---|---|---|---|---|---|---|---|
| 0 | KANDI_AEROPORT | 2015 | 1 | 1 | 979.9 | 32.0 | 13.4 | 32.0 | 2.4 | 0.0 |
| 1 | KANDI_AEROPORT | 2015 | 1 | 2 | 981.4 | 30.3 | 17.4 | 26.0 | 2.3 | 0.0 |
| 2 | KANDI_AEROPORT | 2015 | 1 | 3 | 982.8 | 29.2 | 17.7 | 20.0 | 3.5 | 0.0 |
| 3 | KANDI_AEROPORT | 2015 | 1 | 4 | 983.8 | 29.0 | 15.8 | 20.0 | 2.8 | 0.0 |
| 4 | KANDI_AEROPORT | 2015 | 1 | 5 | 982.7 | 29.5 | 13.5 | 29.0 | 3.0 | 0.0 |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 4013 | KANDI_AEROPORT | 2025 | 12 | 27 | 976.9 | 37.4 | 20.4 | 28.0 | 1.4 | 0.0 |
| 4014 | KANDI_AEROPORT | 2025 | 12 | 28 | 977.5 | 36.9 | 19.7 | 27.0 | 2.0 | 0.0 |
| 4015 | KANDI_AEROPORT | 2025 | 12 | 29 | 978.2 | 37.5 | 19.8 | 31.0 | 1.5 | 0.0 |
| 4016 | KANDI_AEROPORT | 2025 | 12 | 30 | 978.9 | 37.7 | 20.0 | 32.0 | 1.9 | 0.0 |
| 4017 | KANDI_AEROPORT | 2025 | 12 | 31 | 978.4 | 37.3 | 19.7 | 30.0 | 2.1 | 0.0 |

**Station de Parakou**

TABLE 7 – Aperçu du nouveau jeu de données de la station de Parakou

| | Lieu | annee | mois | jour | Pression | Temperature_Max | Temperature_Min | Humidite | Vitesse_Vent | Pluviometrie |
|---|---|---|---|---|---|---|---|---|---|---|
| 0 | PARAKOU_AEROPORT | 2015 | 1 | 1 | 967.5 | 34.6 | 19.2 | 23.0 | 3.6 | 0.0 |
| 1 | PARAKOU_AEROPORT | 2015 | 1 | 2 | 968.6 | 32.6 | 18.5 | 24.0 | 4.3 | 0.0 |
| 2 | PARAKOU_AEROPORT | 2015 | 1 | 3 | 969.9 | 32.5 | 18.9 | 20.0 | 4.9 | 0.0 |
| 3 | PARAKOU_AEROPORT | 2015 | 1 | 4 | 970.8 | 32.5 | 16.5 | 23.0 | 5.0 | 0.0 |
| 4 | PARAKOU_AEROPORT | 2015 | 1 | 5 | 969.9 | 31.9 | 15.9 | 23.0 | 5.1 | 0.0 |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 4013 | PARAKOU_AEROPORT | 2025 | 12 | 27 | 966.0 | 36.0 | 22.3 | 61.0 | 1.6 | 0.0 |
| 4014 | PARAKOU_AEROPORT | 2025 | 12 | 28 | 966.3 | 37.2 | 22.2 | 56.0 | 2.3 | 0.0 |
| 4015 | PARAKOU_AEROPORT | 2025 | 12 | 29 | 967.2 | 36.0 | 21.2 | 64.0 | 2.1 | 0.0 |
| 4016 | PARAKOU_AEROPORT | 2025 | 12 | 30 | 968.0 | 36.3 | 22.7 | 65.0 | 2.3 | 0.0 |
| 4017 | PARAKOU_AEROPORT | 2025 | 12 | 31 | 967.2 | 37.2 | 23.1 | 55.0 | 2.4 | 0.0 |

Notre nouveau jeux de données contient sur une ligne la pression, la température minimale, la température maximale, l'humidité, la vitesse du vent et la quantité de pluie d'un jour précis.

### 2.4.3 Dimensions du nouveau jeu de données

```
Pour Kandi : (4018, 10)
Pour Parakou : (4018, 10)
```

Nous avons pour chaque station 4018 observations, ce qui correspond exactement au nombre de jour entre 2015 à 2025.

## 2.5 Prétraitement des données météorologies

### 2.5.1 Pourcentage de valeurs manquantes dans les jeux de données

**Station Kandi**

```
Pression        1.642608
Humidite        0.124440
Vitesse_Vent    0.771528
Pluviometrie    0.024888
dtype: float64
```

**Station Parakou**

```
Pression           1.791936
Temperature_Max    0.622200
Temperature_Min    0.099552
Humidite           0.895968
Vitesse_Vent       0.099552
dtype: float64
```

On constate que la pression est la variable qui contient plus de valeurs manquantes dans les deux stations (1.64 % à Kandi et 1.79 % à Parakou).

### 2.5.2 Visualisation des valeurs manquantes

Afin de mieux comprendre la relation entre les variables et les valeurs manquantes, nous allons les visualiser à l'aide des graphes suivants :

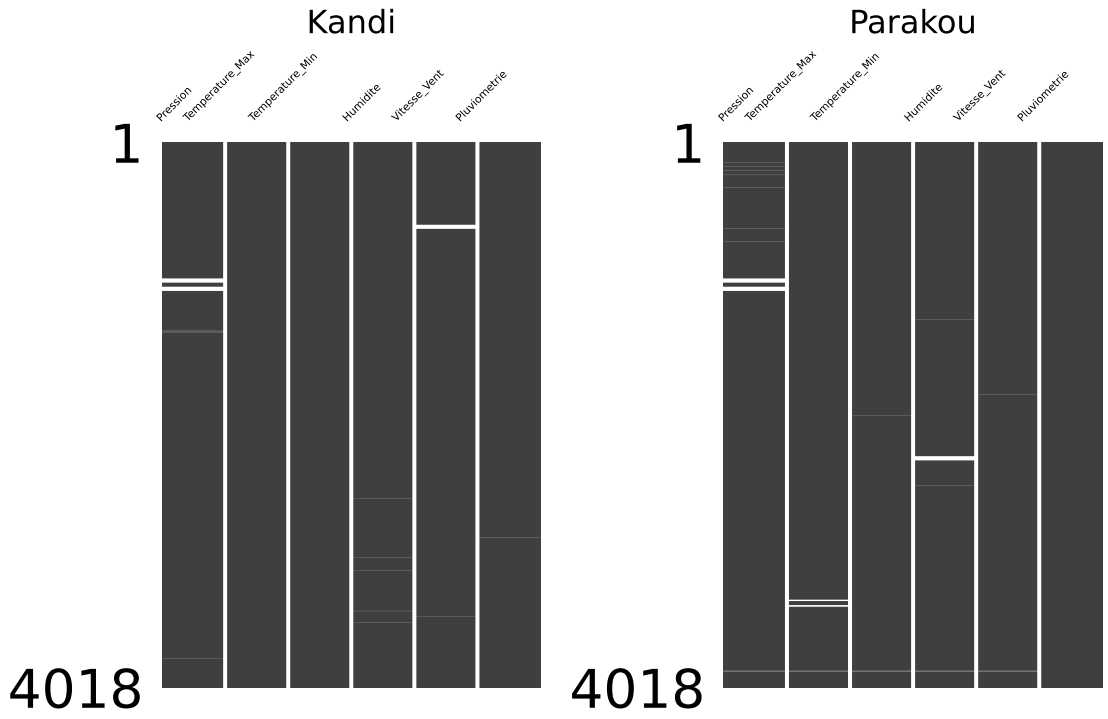



FIGURE 4 – Visualisation des valeurs manquantes à Kandi et Parakou

### 2.5.3 Suppression des lignes très incomplètes

TABLE 8 – les lignes très incompletes dans les données de Parakou

| | Lieu | annee | mois | jour | Pression | Temperature_Max | Temperature_Min | Humidite | Vitesse_Vent | Pluviometrie |
|---|---|---|---|---|---|---|---|---|---|---|
| 3891 | PARAKOU_AEROPORT | 2025 | 8 | 27 | NaN | NaN | NaN | NaN | NaN | 0.0 |
| 3894 | PARAKOU_AEROPORT | 2025 | 8 | 30 | NaN | NaN | NaN | NaN | NaN | 0.0 |
| 3895 | PARAKOU_AEROPORT | 2025 | 8 | 31 | NaN | NaN | NaN | NaN | NaN | 0.0 |

TABLE 9 – les lignes très incompletes dans les données de Kandi

| | Lieu | annee | mois | jour | Pression | Temperature_Max | Temperature_Min | Humidite | Vitesse_Vent | Pluviometrie |
|---|---|---|---|---|---|---|---|---|---|---|
| 2912 | KANDI_AEROPORT | 2022 | 12 | 22 | 980.1 | 30.0 | 17.5 | 36.0 | 3.1 | NaN |

Certaines observations de Parakou présentent un taux très élevé de valeurs manquantes. Ces lignes ont été supprimées afin de garantir la qualité des données et de limiter l'introduction

d'erreurs dans notre jeu de données. Par ailleurs, une observation de Kandi contenant uniquement une valeur manquante pour la pluviométrie a également été supprimée compte tenu de son caractère isolé et de son impact négligeable sur l'ensemble des données.

### 2.5.4 Présentation des méthodes d'imputation

Plusieurs méthodes d'imputation ont été étudiées :

— Moyenne historique ;
— Médiane historique ;
— Interpolation linéaire ;
— Moyenne globale ;
— Médiane globale.

1. ***Moyenne historique et médiane historique*** **:** Ces deux méthodes consistent à remplacer une valeur manquante respectivement par la moyenne et la médiane des valeurs observées des années précédentes, pour le même jour et le même mois.
2. ***Interpolation linéaire*** **:** Cette méthode consiste à remplacer une valeur manquante en utilisant la valeur précédente et la valeur suivante. Par exemple, en observant la pression du jour précédent et celle du jour suivant, il est possible d'estimer la pression de ce jour.
3. ***Moyenne globale et médiane globale*** **:** Ces méthodes consistent à remplacer une valeur manquante respectivement par la moyenne et la médiane générales.

### 2.5.5 Protocole expérimental

Pour comparer les différentes méthodes d'imputation, certaines valeurs connues ont été supprimées artificiellement dans les données. Les valeurs supprimées ont ensuite été reconstruites par chaque méthode d'imputation. Les performances ont été évaluées à l'aide des métriques :

— $MAE = \frac{1}{n} \sum_{i=1}^{n} |x_{i,pred} - x_{i,vrai}|$
— $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_{i,pred} - x_{i,vrai})^2}$.

### 2.5.6 Résultats des méthodes d'imputations

Voici les scores MAE et RMSE de chaque variable contenant des valeurs manquantes dans les deux stations :

**Station Kandi**

TABLE 10 – Résultats d'imputations à Kandi

| | Variable | Méthode | MAE | RMSE |
|---|---|---|---|---|
| 0 | Pression | Moyenne historique | 3.983393 | 6.825533 |
| 1 | Pression | Médiane historique | 2.236250 | 5.611945 |
| 2 | Pression | Interpolation | 0.707833 | 1.804480 |
| 3 | Pression | Moyenne globale | 2.813529 | 5.436928 |
| 4 | Pression | Médiane globale | 2.309000 | 5.378150 |
| 5 | Humidite | Moyenne historique | 7.518853 | 10.074710 |
| 6 | Humidite | Médiane historique | 7.490000 | 10.068515 |
| 7 | Humidite | Interpolation | 4.405000 | 6.464239 |
| 8 | Humidite | Moyenne globale | 18.836105 | 21.255002 |
| 9 | Humidite | Médiane globale | 18.820000 | 21.244764 |
| 10 | Vitesse_Vent | Moyenne historique | 0.616307 | 0.839723 |
| 11 | Vitesse_Vent | Médiane historique | 0.634500 | 0.866357 |
| 12 | Vitesse_Vent | Interpolation | 0.470000 | 0.618708 |
| 13 | Vitesse_Vent | Moyenne globale | 0.572254 | 0.780300 |
| 14 | Vitesse_Vent | Médiane globale | 0.573000 | 0.785557 |

**Station Parakou**

TABLE 11 – Résultats d'imputations à Parakou

| | Variable | Méthode | MAE | RMSE |
|---|---|---|---|---|
| 0 | Pression | Moyenne historique | 2.538769 | 6.741995 |
| 1 | Pression | Médiane historique | 1.785000 | 6.121136 |
| 2 | Pression | Interpolation | 0.396000 | 0.527926 |
| 3 | Pression | Moyenne globale | 2.075019 | 6.050059 |
| 4 | Pression | Médiane globale | 2.010000 | 6.086050 |
| 5 | Temperature_Max | Moyenne historique | 1.560396 | 1.984032 |
| 6 | Temperature_Max | Médiane historique | 1.463750 | 1.896808 |
| 7 | Temperature_Max | Interpolation | 1.106833 | 1.550974 |
| 8 | Temperature_Max | Moyenne globale | 2.844814 | 3.255498 |
| 9 | Temperature_Max | Médiane globale | 2.813000 | 3.241157 |
| 10 | Temperature_Min | Moyenne historique | 1.248569 | 1.610092 |
| 11 | Temperature_Min | Médiane historique | 1.282875 | 1.651182 |
| 12 | Temperature_Min | Interpolation | 0.855000 | 1.166598 |
| 13 | Temperature_Min | Moyenne globale | 1.317245 | 1.673103 |
| 14 | Temperature_Min | Médiane globale | 1.316000 | 1.672782 |
| 15 | Humidite | Moyenne historique | 9.173177 | 13.232393 |
| 16 | Humidite | Médiane historique | 9.355000 | 13.759270 |
| 17 | Humidite | Interpolation | 4.918333 | 6.776532 |
| 18 | Humidite | Moyenne globale | 17.474566 | 20.693217 |
| 19 | Humidite | Médiane globale | 17.090000 | 22.188961 |
| 20 | Vitesse_Vent | Moyenne historique | 0.622360 | 0.794235 |
| 21 | Vitesse_Vent | Médiane historique | 0.628250 | 0.802749 |
| 22 | Vitesse_Vent | Interpolation | 0.403000 | 0.541951 |
| 23 | Vitesse_Vent | Moyenne globale | 0.564437 | 0.707587 |
| 24 | Vitesse_Vent | Médiane globale | 0.552000 | 0.701142 |

### 2.5.7 Représentation graphique des erreurs

Voici une représentation graphique des scores MAE de chaque variable contenant des valeurs manquantes dans les deux stations :

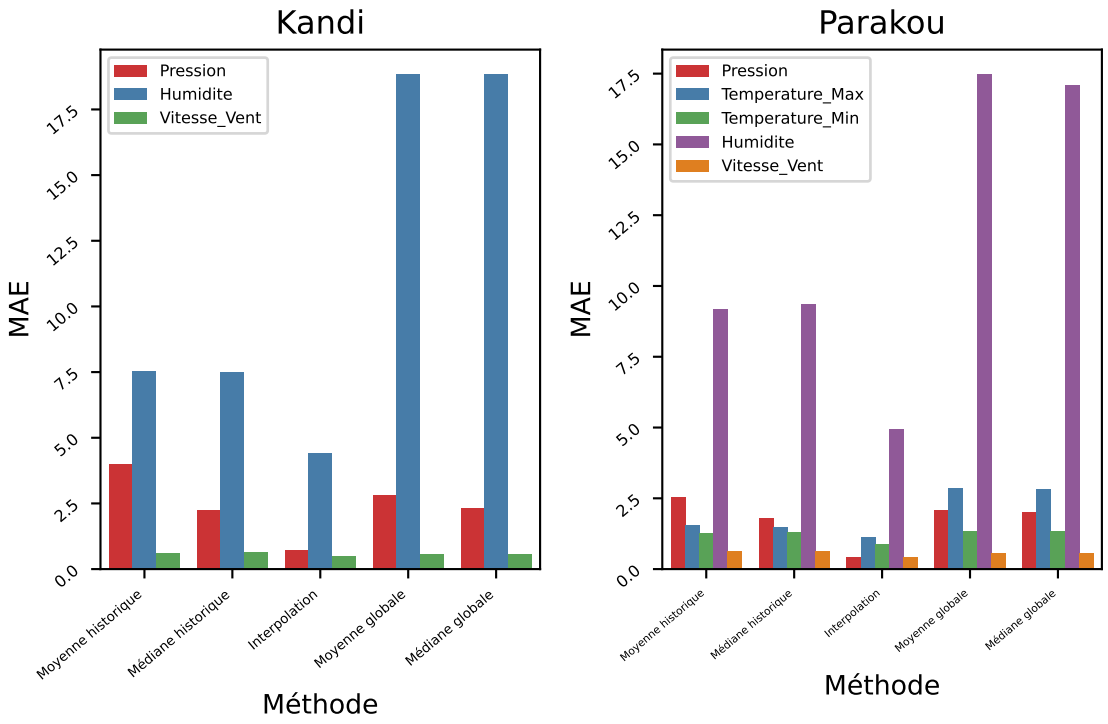



FIGURE 5 – Comparaison des MAE à Kandi et à Parakou

## 2.6 Conclusion

Les résultats obtenus montrent que l'interpolation linéaire fournit les meilleures performances sur la majorité des variables météorologiques étudiées. Cette méthode présente les plus faibles valeurs de MAE et de RMSE pour les stations de Kandi et de Parakou. Les méthodes basées sur les moyennes et médianes globales présentent des performances moins satisfaisantes, ce qui montre qu'elles ne prennent pas suffisamment en compte la dynamique temporelle des données climatiques.

Étant donné que l'interpolation est la méthode la plus adaptée par rapport aux autres, nous avons réalisé le prétraitement des données à l'aide de cette méthode.

# 3 Analyse exploratoire des données météorologiques

## 3.1 Introduction

Dans le cadre de cette section, nous allons effectuer une analyse exploratoire sur nos données météorologiques des stations de Kandi et de Parakou de 2015 à 2025, déjà traitées. L'objectif de cette analyse est de mieux comprendre les tendances et les relations entre les différentes variables météorologiques, afin de déterminer les anomalies et les modèles qui pourraient être

utilisés dans la prévision pluviométrique. Nous allons utiliser des techniques de visualisation et des statistiques pour explorer les données et en tirer des conclusions significatives.

## 3.2 Analyse des données météorologiques

### 3.2.1 Description statistique des données météorologiques

Voici, de façon générale, la description de nos données météorologiques :

TABLE 12 – Description statistique des données de Kandi et Parakou

| Variables | Moyenne K | Moyenne P | Mediane K | Mediane P | Ecart-type K | Ecart-type P |
|---|---|---|---|---|---|---|
| Pression | 979.018608 | 967.354620 | 977.8 | 966.8 | 6.780869 | 5.214019 |
| Temperature Maximal | 34.837590 | 33.244558 | 34.7 | 33.6 | 3.673417 | 3.420010 |
| Temperature Minimal | 22.258601 | 22.029116 | 22.5 | 22.0 | 3.668614 | 1.785151 |
| Humidite | 55.986931 | 62.520922 | 56.0 | 69.0 | 21.219201 | 20.174645 |
| Pluie | 3.108514 | 3.315318 | 0.0 | 0.0 | 9.673875 | 10.228387 |

Avec ce tableau, nous pouvons observer les moyennes, les médianes et les écarts-types des deux stations pour la pression, la température maximale et minimale, l'humidité ainsi que la pluviométrie.

Premièrement, nous pouvons constater que la pluviométrie moyenne est plus élevée à Parakou qu'à Kandi. De plus, il fait plus chaud à Kandi qu'à Parakou (environ 34, 83°C à Kandi et 33, 24°C à Parakou). En effet, la pression, la température (surtout minimale) et l'humidité sont plus stables à Parakou qu'à Kandi. Par contre, la pluviométrie est moins stable à Parakou qu'à Kandi car l'écart type de la pluie à Parakou (environ $10,22\,mm$) est supérieur à celle de Kandi (environ $9,67\,mm$). Ce résultat suggère que la pluie dépend de phénomènes climatiques plus complexes et non uniquement de la stabilité des variables étudiées. On constate en plus que la moyenne des pluies est supérieure à la médiane dans les deux stations. Il y a donc de grandes valeurs extrêmes pour la pluie, ce qui prouve l'existence de fortes pluies rares et imprévues. Enfin, Parakou est globalement plus humide que Kandi de 2015 à 2025. Dans la suite, nous allons approfondir notre analyse pour mieux comprendre ces phénomènes.

**NB : K** signifie Kandi et **P** signifie Parakou

### 3.2.2 Distribution de la pluie dans les deux stations

Dans cette section, nous allons analyser la distribution de la pluie à Kandi et à Parakou. Nous allons utiliser des histogrammes et des courbes de densité pour visualiser la distribution de la pluviométrie dans les deux stations. Cela nous permettra de mieux comprendre les tendances et les variations de la pluie dans ces deux régions.

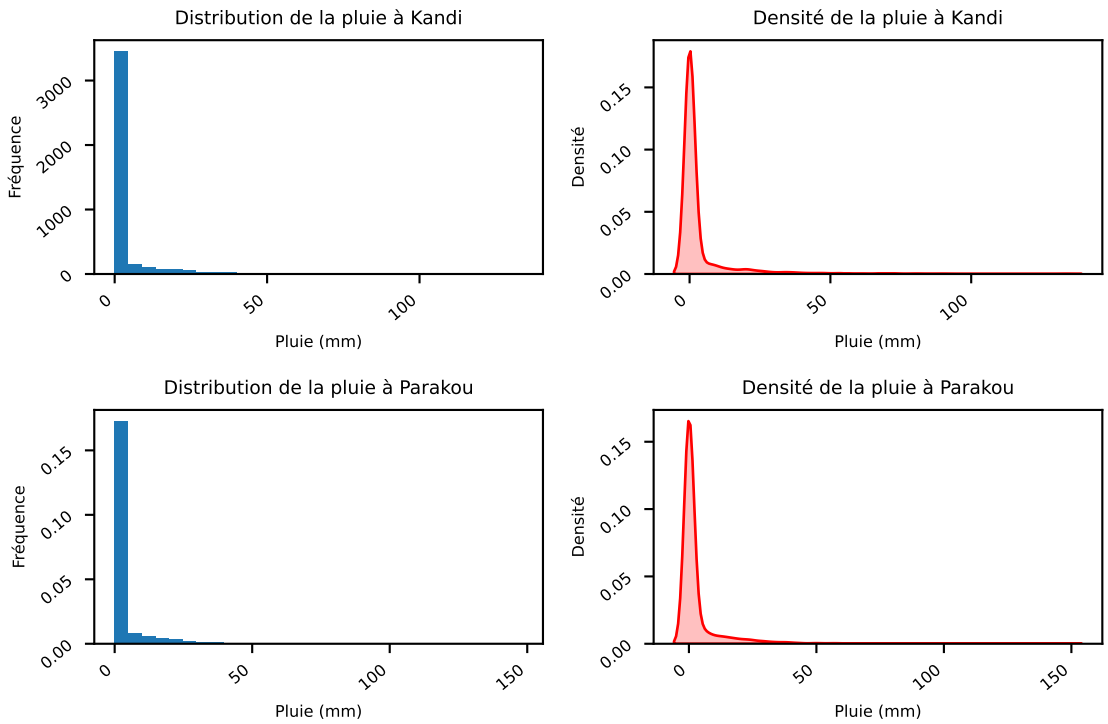



FIGURE 6 – Distribution et densité de la pluie à Kandi et Parakou

D'abord, on constate que les deux stations ont une distribution de la pluie très similaire. De plus, il semble que les jours pluvieux soient peu fréquents dans les deux stations.Ce qui explique non seulement la grande différence entre la moyenne et la médiane, mais aussi le fait que les fortes pluies sont généralement rares. En effet, la distribution de la pluie à Parakou est plus étalée que celle de Kandi, ce qui suggère que les fortes pluies sont plus fréquentes à Parakou qu'à Kandi. Enfin, on constate que la distribution de la pluie à Kandi est plus concentrée autour de zéro que celle de Parakou, ce qui suggère que les jours sans pluie sont plus fréquents à Kandi qu'à Parakou.

### 3.2.3 Variation de la pluie au fil du mois

Cette section consiste à déterminer en détail la relation entre la pluie et les mois dans les deux stations. Nous allons utiliser des graphiques de type heatmap pour visualiser la moyenne de la quantité de pluie pour chaque mois de chaque année dans les deux stations. Cela nous permettra de mieux comprendre les tendances saisonnières de la pluie dans ces deux régions.

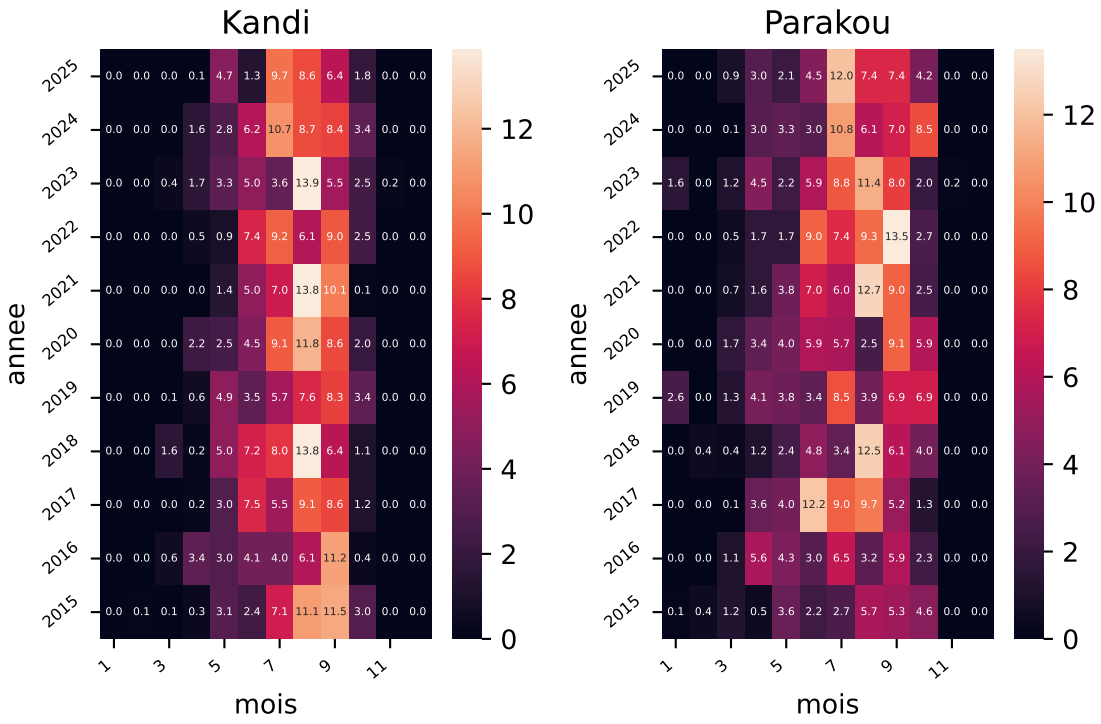



FIGURE 7 – Moyenne de la pluie par mois de chaque année à Kandi et à Parakou

On constate que dans les deux stations, la pluie est plus abondante entre le mois juin et le mois septembre. Ce qui correspond à la saison des pluies dans les deux régions. De plus, les mois de juillet, août et septembre sont les plus pluvieux dans une année des deux stations. En effet, dans les deux stations, aucune pluie n'a été observée en janvier et en décembre durant la période étudiée. Les fortes pluies ont souvent eu lieu dans le mois de août. Le graphe ci-dessous confirme encore mieux que le mois d'août est le mois le plus pluvieux dans les deux stations, surtout à Kandi.

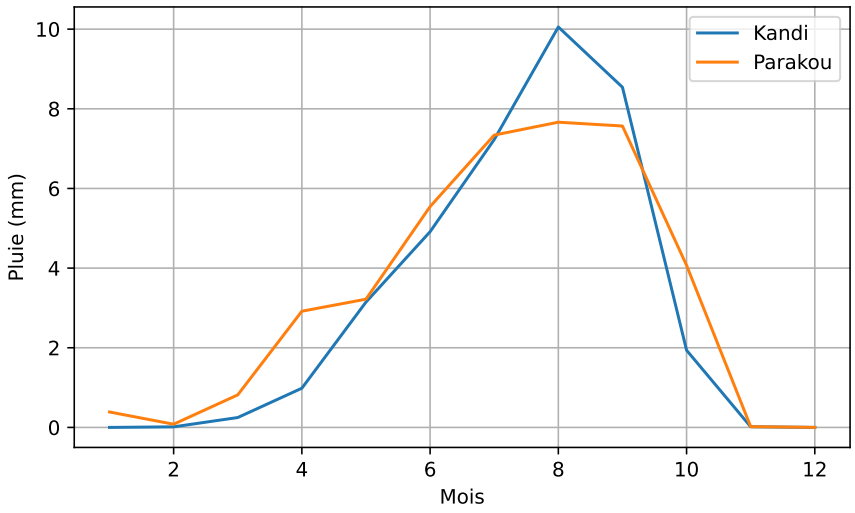



FIGURE 8 – Evolution de la pluie par mois en moyenne de Kandi et Parakou de 2015 à 2025

### 3.2.4 Corrélation entre les variables climatiques

Dans cette section, nous allons analyser la corrélation entre les différentes variables climatiques dans les deux stations. Nous allons utiliser des matrices de corrélation pour visualiser les relations entre les variables telles que la pression, la température maximale et minimale, l'humidité et la pluviométrie. Cela nous permettra de mieux comprendre comment ces variables interagissent entre elles et comment elles peuvent influencer la pluie dans ces deux régions.

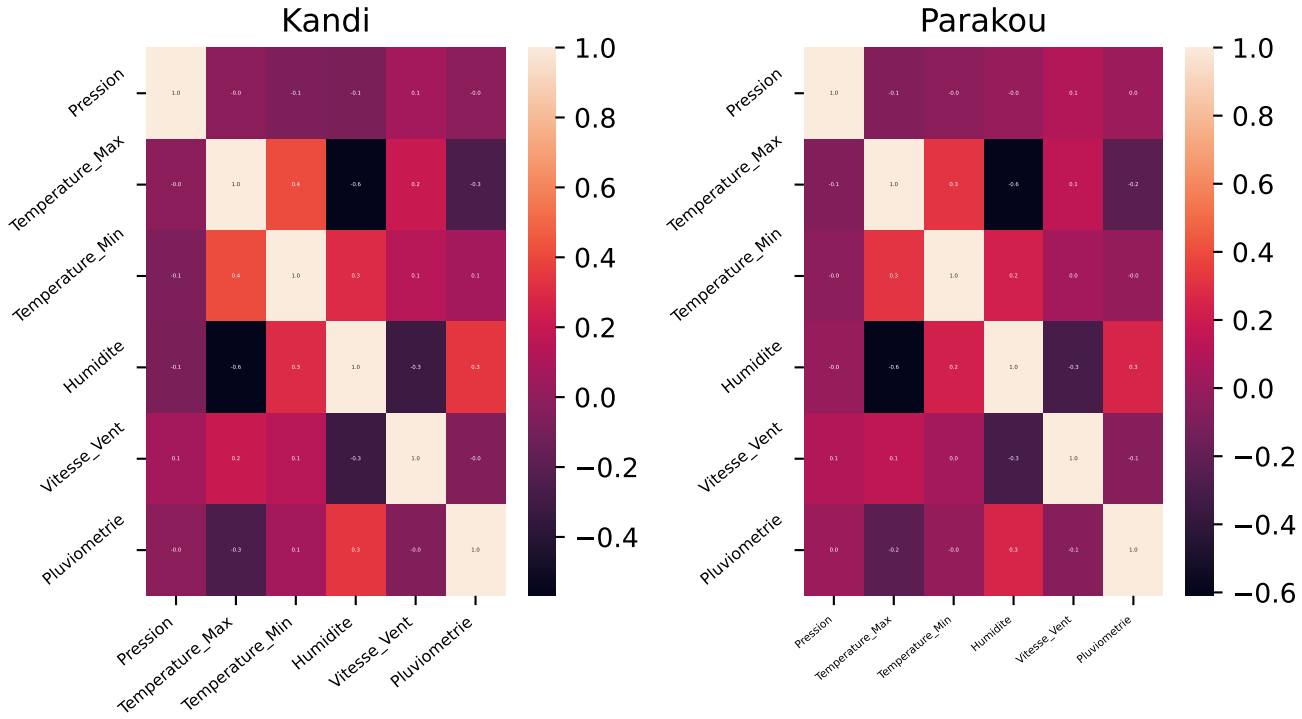



FIGURE 9 – Corrélation entre les varibles climatiques à Kandi et à Parakou

On constate que la pluviométrie est positivement corrélée avec l'humidité dans les deux stations. Ce qui montre que les jours les plus humides sont généralement ceux où il y a plus de pluie. De plus, la pluviométrie n'est pas corrélée avec la pression dans les deux stations. Enfin, la température maximale est négativement corrélée avec la pluviométrie dans les deux stations. Ce qui suggère que les jours les plus froids sont généralement ceux où il y a plus de pluie. Ce qui est normal, car lorsqu'il pleut, la température est souvent plus basse c'est à dire il fait froid.

### 3.2.5 Observation des valeurs extrême

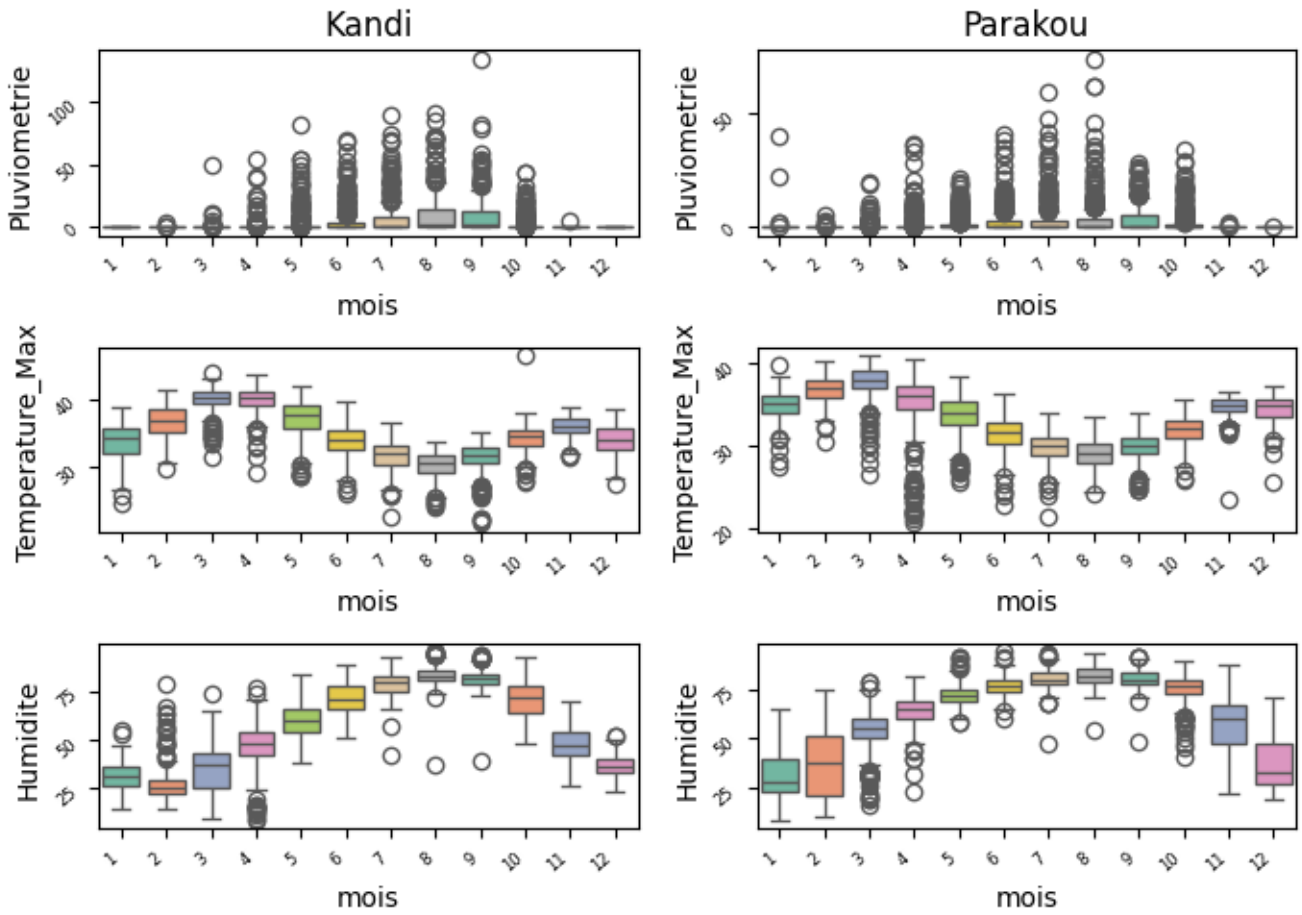



FIGURE 10 – Observation des valeurs extrêmes à Kandi et Parakou

On constate une nouvelle fois que les mois de juin à octobre sont les plus pluvieux dans les deux stations. À cette période, la température maximale diminue et l'humidité augmente, ce qui confirme que les jours les plus froids et les plus humides sont généralement ceux où il y a le plus de pluie. De plus, les événements de fortes pluies sont plus fréquents à Parakou qu'à Kandi, et ces fortes pluies sont plus fréquentes durant les mois de juillet, août et septembre que durant les autres mois de l'année. Il faut savoir que les événements de fortes pluies sont les moments où il y a de très fortes pluies, auxquelles on ne s'enttend pas et qui sont rares. On parle aussi, au sens large, d'évènements rares.

### 3.2.6 Stationnarité de la pluie

Dans cette section, nous allons vérifier la stationnarité de la pluviométrie dans les deux stations. Voici un tableau récapitulatif des tests de stationnarité pour la pluviométrie à Kandi et à Parakou :

TABLE 13 – Tableau de stationnarité

| | Kandi | Parakou |
|---|---|---|
| ADF | -5.284479 | -6.512807e+00 |
| P-value | 0.000006 | 1.089743e-08 |

Dans les deux stations, la p-value est inférieure à 0,05. Et donc, la pluviométrie est stationnaire dans les deux stations. Ce qui suggère que les propriétés statistiques de la pluviométrie ne changent pas énormément au fil du temps dans les deux stations. Par conséquent, nous pouvons utiliser des modèles de séries temporelles, surtout le modèle ARIMA, pour prévoir la pluviométrie dans les deux stations.

## 3.3 Conclusion

Dans la section précédente, nous avons effectué une analyse exploratoire des données météorologiques des stations de Kandi et de Parakou de 2015 à 2025. Nous avons observé que la pluviométrie est plus abondante à Parakou qu'à Kandi, et que les mois de juillet, août et septembre sont les plus pluvieux dans une année dans les deux stations. De plus, nous avons constaté que la pluviométrie est positivement corrélée avec l'humidité et négativement corrélée avec la température maximale dans les deux stations. Enfin, nous avons vérifié que la pluviométrie est stationnaire dans les deux stations, ce qui suggère que nous pouvons utiliser des modèles de séries temporelles pour prévoir la pluviométrie dans ces deux régions.

# 4 Comparaison et choix des modèles pour la prévision pluviométrique

## 4.1 Introduction

Cette section consiste à comparer les modèles ARIMA, SARIMA, SARIMAX, Prophet et XGBoost pour la prévision pluviométrique. Nous allons utiliser les données de précipitations journalières pour évaluer les performances de chaque modèle et déterminer lequel est le plus adapté pour la prévision à long terme. Ces modèles seront comparés en utilisant des graphes et les deux métriques utilisées dans la partie prétraitement pour la comparaison des méthodes d'imputation : le MAE et le RMSE. Tous ces modèles seront entraînés sur les données de 2015 à 2023 et testés sur les données de 2024 à 2025.

## 4.2 Utilisation des modèles

### 4.2.1 Modèle ARIMA

**Définition**

Un modèle ARIMA (AutoRagressive Integrated Moving Average) est un modèle de séries temporelles qui décrit une variable observée comme une combinaison linéaire de ses valeurs passées, de ses erreurs passées et d'un éventuel processus de différenciation visant à assurer la stationnarité de la série, afin de réaliser des prévisions futures. Dans notre cas, le modèle ARIMA part du principe que la pluie d'aujourd'hui dépend de la pluie des jours précédents, ainsi que des erreurs de prévision passées. Il contient trois paramètres : p (ordre de l'auto-régression), d (degré de différenciation) et q (ordre de la moyenne mobile). On note souvent ce modèle ARIMA(p,d,q) pour indiquer les valeurs de ces paramètres.

1. Le paramètre p représente le nombre de termes d'auto-régression dans le modèle. Il indique combien de valeurs passées de la série temporelle sont utilisées pour prédire la valeur actuelle. Par exemple, si p=2, cela signifie que les deux dernières valeurs de la série temporelle sont utilisées pour faire la prévision.
2. Le problème avec ARIMA est qu'il impose que la série temporelle soit stationnaire, c'est-à-dire que ses propriétés statistiques ne changent pas au fil du temps. D'ou l'importance du paramètre d qui représente le nombre de différenciations nécessaires pour rendre la série temporelle stationnaire. Par exemple, si d=1, cela signifie que nous devons différencier la série temporelle une fois pour la rendre stationnaire. Mais dans notre cas, la série temporelle de précipitations est déjà stationnaire, donc d=0.
3. Le paramètre q indique combien de termes de moyenne mobile sont inclus dans le modèle. Il représente le nombre de valeurs passées des erreurs de prévision qui sont utilisées pour prédire la valeur actuelle. Par exemple, si q=1, cela signifie que l'erreur de prévision du jour précédent est utilisée pour faire la prévision du jour actuel.

Dans ce cas, le modèle ARIMA peut être représenté par l'équation suivante :
$Y_t = \alpha_1 Y_{t-1} + \alpha_2 Y_{t-2} + \epsilon_t + \beta_1 \epsilon_{t-1} + c$ (En supposant p=2, d=0 et q=1)

avec :

— $Y_t$ : la valeur de la série temporelle à l'instant t

— $\alpha_1$ et $\alpha_2$ : les coefficients d'auto-régression

— $\epsilon_t$ : l'erreur de prévision à l'instant t

— $\beta_1$ : le coefficient de la moyenne mobile

— $c$ : une constante

**Résultats du modèle ARIMA**

Après avoir ajusté le modèle ARIMA à nos données de précipitations, nous avons obtenu les résultats suivants :

TABLE 14 – Résultats du modèle ARIMA

| Station | MAE | RMSE |
|---|---|---|
| Kandi | 4.890643 | 9.851040 |
| Parakou | 5.270873 | 11.345777 |

Le graphe ci-dessous illustre l'évolution des valeurs réelles et des valeurs prédites par le modèle ARIMA sur la période 2024–2025.

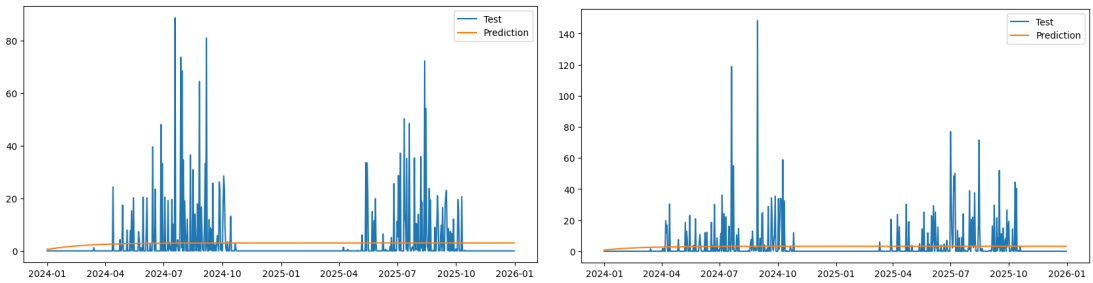



FIGURE 11 – Evolution des valeurs réelles et des valeurs prédites par ARIMA

On constate que le modèle ARIMA est plus performant à Kandi qu'à Parakou. Cela suggère que le modèle ARIMA est plus adapté pour la prévision des précipitations à Kandi qu'à Parakou. Cependant, les performances du modèle ARIMA ne sont pas très satisfaisantes.

D'après les graphes précédents, on constate que dans les deux stations, le modèle ARIMA arrive à peu près à prédire dans les mois de Janvier, Février, Mars, Avril, Novembre et de Décembre mais n'arrive pas à prédire dans les autres mois. Ainsi, les performances du modèle sont moins bonnes durant les mois de la saison des pluies. Cela peut être dû au fait que le modèle ARIMA ne tient pas compte des composantes saisonnières. C'est pourquoi nous allons maintenant explorer le modèle SARIMA, qui prend en compte les composantes saisonnières de la série temporelle.

### 4.2.2 Modèle SARIMA

**Définition**

Un modèle SARIMA (Seasonal AutoRegressive Integrated Moving Average) est une extension du modèle ARIMA qui prend en compte les composantes saisonnières d'une série temporelle. Il inclut des termes supplémentaires pour modéliser les effets saisonniers, tels que les variations périodiques qui se produisent à des intervalles réguliers (par exemple, les précipitations qui varient selon les saisons). Le modèle SARIMA est défini par sept paramètres : p, d,

q, P, D, Q et m. Les paramètres p, d et q sont les mêmes que ceux du modèle ARIMA, tandis que les paramètres P, D et Q représentent les composantes saisonnières du modèle. Le paramètre m indique la périodicité de la saisonnalité (par exemple, m=12 pour des données mensuelles avec une saisonnalité annuelle).

Pour notre cas, le modèle SARIMA peut être représenté par l'équation suivante :

$Y_t = \alpha_1 Y_{t-1} + \alpha_2 Y_{t-2} + \epsilon_t + \beta_1 \epsilon_{t-1} + \gamma_1 Y_{t-m} + \delta_1 \epsilon_{t-m} + c$ (En supposant p=2, d=0, q=1, P=1, D=0, Q=1)

avec :

— $Y_t$ : la valeur de la série temporelle à l'instant t

— $\alpha_1$ et $\alpha_2$ : les coefficients d'auto-régression

— $\epsilon_t$ : l'erreur de prévision à l'instant t

— $\beta_1$ : le coefficient de la moyenne mobile

— $\gamma_1$ : le coefficient d'auto-régression saisonnière

— $\delta_1$ : le coefficient de la moyenne mobile saisonnière

— $c$ : une constante

**Résultats du modèle SARIMA**

Après avoir ajusté le modèle SARIMA à nos données de précipitations avec m=7, nous avons obtenu les résultats suivants :

TABLE 15 – Résultats du modèle SARIMA

| Station | MAE | RMSE |
|---|---|---|
| Kandi | 5.036159 | 9.865430 |
| Parakou | 5.425908 | 11.360692 |

Le graphe ci-dessous illustre l'évolution des valeurs réelles et des valeurs prédites par le modèle SARIMA sur la période 2024–2025.

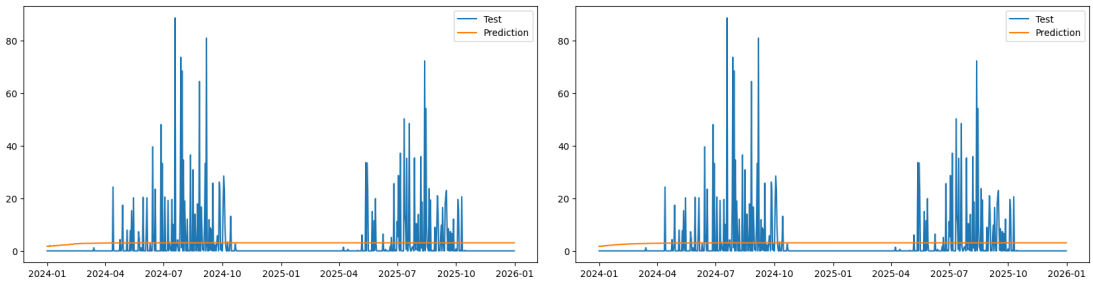



FIGURE 12 – Evolution des valeurs réelles et des valeurs prédites par SARIMA

Bien que SARIMA prenne en compte une composante saisonnière, les résultats obtenus ne montrent pas d'amélioration par rapport à ARIMA. Cela peut indiquer que la saisonnalité

hebdomadaire (m=7) n'est pas suffisamment marquée dans les données étudiées.La question qui se pose maintenant est de savoir si l'ajout de variables exogènes (variables explicatives) dans le modèle SARIMA peut améliorer les performances du modèle. C'est pourquoi nous allons maintenant explorer le modèle SARIMAX, qui permet d'inclure des variables exogènes dans la modélisation.

### 4.2.3 Modèle SARIMAX

**Définition**

Un modèle SARIMAX (Seasonal AutoRegressive Integrated Moving Average with eXogenous regressors) est une extension du modèle SARIMA qui permet d'inclure des variables exogènes (variables explicatives) dans la modélisation. Dans notre cas, les variables explicatives seront la température maximale du jour precédent, la température minimale du jour précédent, l'humidité du jour précédent, la pression du jour précédent et la vitesse du vent du jour précédent. Le modèle SARIMAX est défini par les mêmes paramètres que le modèle SARIMA (p, d, q, P, D, Q et m), mais il inclut des coefficients pour les variables exogènes.

**Résultats du modèle SARIMAX**

Après avoir ajusté le modèle SARIMAX à nos données de précipitations avec m=7, nous avons obtenu les résultats suivants :

TABLE 16 – Résultats du modèle SARIMAX

| Station | MAE | RMSE |
|---|---|---|
| Kandi | 5.032446 | 9.865653 |
| Parakou | 5.426609 | 11.360670 |

Le graphe ci-dessous illustre l'évolution des valeurs réelles et des valeurs prédites par le modèle SARIMAX sur la période 2024–2025.

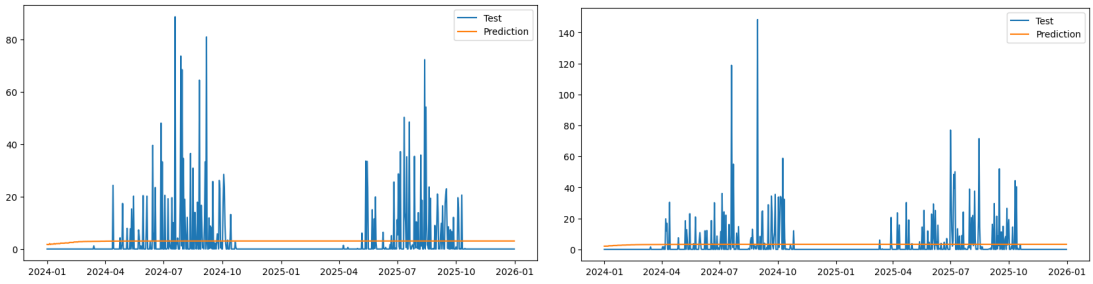



FIGURE 13 – Evolution des valeurs réelles et des valeurs prédites par SARIMAX

Apparemment, l'ajout des variables exogènes n'a pas toujours amélioré les performances du modèle SARIMA. Cela peut être dû à plusieurs facteurs, tels que la qualité des données exogènes, la relation entre les variables exogènes et la variable cible (précipitations). Il est possible que

les variables exogènes utilisées ne soient pas suffisamment informatives pour améliorer les prévisions de précipitations, ou que le modèle SARIMAX ne soit pas le meilleur choix pour capturer les relations entre les variables. C'est pourquoi nous allons maintenant explorer le modèle Prophet.

### 4.2.4 Modèle Prophet

**Définition**

Le modèle Prophet est un modèle de prévision de séries temporelles développé par Facebook. Il est conçu pour être facile à utiliser et à interpréter, tout en étant capable de gérer des données avec des tendances non linéaires, des saisonnalités multiples et des jours fériés. Le modèle Prophet décompose une série temporelle en trois composantes principales : la tendance, la saisonnalité et les jours fériés. La tendance capture les changements à long terme dans la série temporelle, la saisonnalité capture les variations périodiques (par exemple, les précipitations qui varient selon les saisons), et les jours fériés capturent les effets spécifiques liés à des dates particulières. Le modèle Prophet utilise une approche de régression pour modéliser ces composantes, ce qui permet de faire des prévisions futures en extrapolant les tendances et les saisonnalités identifiées dans les données historiques. Le modèle Prophet est particulièrement efficace pour les séries temporelles avec des tendances non linéaires et des saisonnalités multiples, ce qui en fait un choix populaire pour la prévision de données telles que les précipitations.

**Résultats du modèle Prophet**

Après avoir ajusté le modèle Prophet à nos données de précipitations, nous avons obtenu les résultats suivants :

TABLE 17 – Résultats du modèle Prophet

| Station | MAE | RMSE |
|---|---|---|
| Kandi | 4.310590 | 9.199159 |
| Parakou | 5.436776 | 10.935978 |

Le graphe ci-dessous illustre l'évolution des valeurs réelles et des valeurs prédites par le modèle Prophet sur la période 2024–2025.

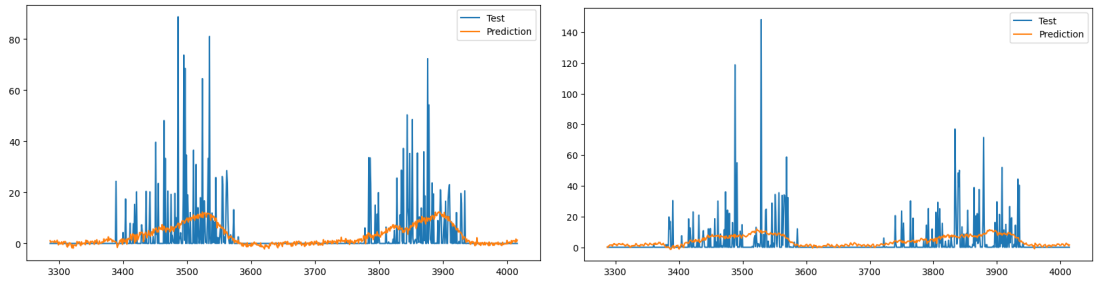



FIGURE 14 – Evolution des valeurs réelles et des valeurs prédites par Prophet

On constate que le modèle Prophet est plus performant que les modèles ARIMA, SARIMA et SARIMAX, surtout à Kandi et corrige partiellement les erreurs des autres modèles dans les mois de saisons de pluviométrie. Cela suggère que le modèle Prophet est plus adapté pour la prévision des précipitations à Kandi et à Parakou que les autres modèles. Le modèle Prophet est capable de capturer les tendances non linéaires et les saisonnalités multiples présentes dans les données de précipitations, ce qui peut expliquer ses meilleures performances par rapport aux modèles ARIMA, SARIMA et SARIMAX. CCependant, une valeur de pluie négative est impossible, ce que montrent les graphes précédents. C'est pour cette raison nous allons maintenant explorer le modèle XGBoost.

### 4.2.5 Modèle XGBoost

**Définition**

Le model XGBoost (eXtreme Gradient Boosting) est un algorithme de machine learning basé sur un ensemble d'arbres de décision construits séquentiellement. Chaque nouvel arbre cherche à corriger les erreurs commises par les arbres précédents. Pour la prévision pluviométrique, le modèle utilise des variables explicatives telles que les valeurs retardées de la pluie, les moyennes mobiles et les valeurs des variables météorologiques des jours précédents afin de prédire les précipitations futures. Le modèle XGBoost est particulièrement efficace pour capturer les relations non linéaires et les interactions complexes entre les variables, ce qui peut être bénéfique pour la prévision des précipitations, qui sont souvent influencées par de nombreux facteurs météorologiques. De plus, XGBoost intègre des mécanismes de régularisation pour éviter le surapprentissage, ce qui peut améliorer la généralisation du modèle sur de nouvelles données.

**Résultats du modèle XGBoost**

Les hyperparamètres du modèle XGBoost ont été optimisés à l'aide de la validation croisée temporelle (TimeSeriesSplit) combinée à une recherche par grille (GridSearchCV), permettant d'identifier la combinaison de paramètres minimisant l'erreur de prévision MAE. Nous avons obtenu les résultats suivants :

TABLE 18 – Résultats du modèle XGBoost

| Station | MAE | RMSE |
|---|---|---|
| Kandi | 4.363779 | 9.385307 |
| Parakou | 5.059537 | 11.089638 |

Le graphe ci-dessous illustre l'évolution des valeurs réelles et des valeurs prédites par le modèle XGBoost sur la période 2024–2025.

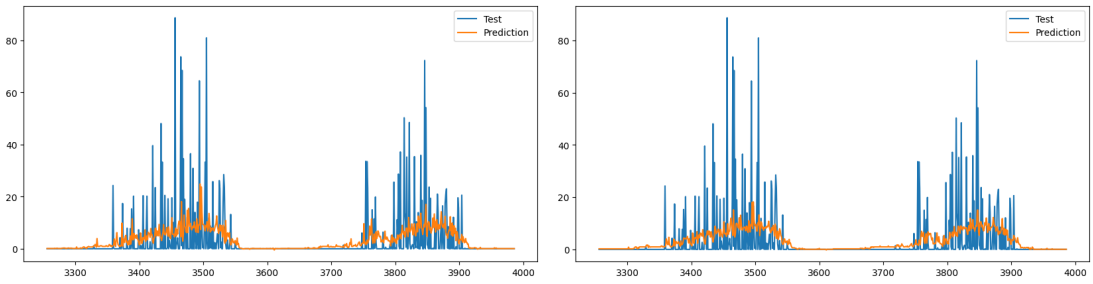



FIGURE 15 – Evolution des valeurs réelles et des valeurs prédites par XGBoost

XGBoost a montré des performances comparables à celles du modèle Prophet. Cela suggère que le modèle XGBoost est également adapté pour la prévision des précipitations à Kandi et à Parakou. Le modèle XGBoost est capable de capturer les tendances non linéaires et les interactions complexes entre les variables, ce qui peut expliquer ses bonnes performances par rapport aux autres modèles.

## 4.3 Conclusion

Voici un tableau récapitulatif des performances de tous les modèles à Kandi et à Parakou :

TABLE 19 – Tableau des performances des modèles à Kandi, classées selon le MAE

| Model | MAE | RMSE |
|---|---|---|
| Prophet | 4.310590 | 9.199159 |
| XGBoost | 4.363779 | 9.385307 |
| ARIMA | 4.890643 | 9.851040 |
| SARIMAX | 5.032446 | 9.865653 |
| SARIMA | 5.036159 | 9.865430 |

TABLE 20 – Tableau des performances des modèles à Parakou, classées selon le MAE

| Model | MAE | RMSE |
|---|---|---|
| XGBoost | 5.059537 | 11.089638 |
| ARIMA | 5.270873 | 11.345777 |
| SARIMA | 5.425908 | 11.360692 |
| SARIMAX | 5.426609 | 11.360670 |
| Prophet | 5.436776 | 10.935978 |

Les résultats montrent qu'aucun modèle n'est systématiquement supérieur sur toutes les stations. À Kandi, Prophet présente les meilleures performances en termes de MAE et de RMSE, tandis qu'à Parakou XGBoost obtient le meilleur compromis entre précision et capacité de généralisation. Mais pour obtenir de bons résultats pendant les jours de la saison pluvieuse et limiter le risque d'obtenir des valeurs de pluie négatives, il est préférable d'utiliser le modèle XGBoost dans les deux stations. Etant donné que les modèles Prophet et XGBoost ont montré des performances comparables, le choix entre les deux peut dépendre de facteurs tels que la facilité d'interprétation du modèle, la disponibilité des données exogènes, les ressources informatiques disponibles pour l'entraînement du modèle et la faciliter de prédiction. En conclusion, le modèle XGBoost semble être le plus adapté pour la prévision des précipitations à Kandi et à Parakou, en particulier pendant les mois de saison pluvieuse, grâce à sa capacité à capturer les relations non linéaires et les interactions complexes entre les variables météorologiques. Les résultats obtenus restent spécifiques aux données des stations de Kandi et de Parakou et ne garantissent pas les mêmes performances sur d'autres stations.

# 5 Conclusion générale et perspectives

Dans ce projet, nous avons suivi un processus complet de prétraitement, d'analyse exploratoire et de modélisation pour la prévision pluviométrique à partir de données météorologiques. Nous avons commencé par traiter les données brutes, en identifiant et en imputant les valeurs manquantes à l'aide de différentes méthodes. Nous avons ensuite effectué une analyse exploratoire pour comprendre les tendances et les relations entre les variables météorologiques. Enfin, nous avons comparé plusieurs modèles de prévision, notamment ARIMA, SARIMA, SARIMAX, Prophet et XGBoost, pour déterminer lequel était le plus adapté pour la prévision des précipitations à Kandi et à Parakou. Les résultats ont montré que le modèle XGBoost offrait les meilleures performances globales, en particulier pendant les mois de saison pluvieuse. Ce projet a permis d'acquérir une compréhension approfondie du processus de prévision pluviométrique et des techniques de modélisation associées, tout en mettant en évidence l'importance du choix du modèle en fonction des caractéristiques spécifiques des données et des objectifs de prévision.

### 5.0.1 Limite du projet

La principale limite de XGBoost est son incapacité à effectuer des prévisions à long terme, dans la mesure où la prédiction de la pluie à une date donnée nécessite les observations des jours précédents.

### 5.0.2 Perspectives d'évolution

La performance de XGBoost nous encouragent à explorer d'autres modèles de Machine Learning, tels que LightGBM, CatBoost Extra Trees, Random Forest etc... pour voir si on peut faire mieux que XGBoost. Mais on peut aussi faire du stacking pour combiner les prévisions de plusieurs modèles afin d'améliorer la précision globale des prévisions. Par exemple, on pourrait combiner les prévisions de Prophet et XGBoost en utilisant une technique de stacking, où les prévisions de chaque modèle sont utilisées comme entrées pour un modèle de méta-apprentissage (par exemple, une régression linéaire) qui apprend à pondérer les prévisions de chaque modèle pour produire une prévision finale plus précise. Mais on peut s'arrêter là pour ce projet en raison des contraintes de temps.

# Bibliographie


[1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C. et Ljung, G. M. *Time Series Analysis : Forecasting and Control*. 5e édition, Wiley, 2015.

[2] Hyndman, R. J. et Athanasopoulos, G. *Forecasting : Principles and Practice*. 3e édition, OTexts, 2021.

[3] Dickey, D. A. et Fuller, W. A. Distribution of the Estimators for Autoregressive Time Series with a Unit Root. *Journal of the American Statistical Association*, 74(366), 427–431, 1979.

[4] Chen, T. et Guestrin, C. XGBoost : A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD*, 785–794, 2016.

[5] Taylor, S. J. et Letham, B. Forecasting at Scale. *The American Statistician*, 72(1), 37–45, 2018.

[6] Python Software Foundation. Python Documentation. https://www.python.org

[7] Pandas Development Team. Pandas Documentation. https://pandas.pydata.org

[8] Scikit-Learn Developers. Scikit-Learn Documentation. https://scikit-learn.org

[9] Statsmodels Developers. Statsmodels Documentation. https://www.statsmodels.org

[10] XGBoost Developers. XGBoost Documentation. https://xgboost.readthedocs.io
bibitembox2015 G. E. P. Box, G. M. Jenkins, G. C. Reinsel et G. M. Ljung, *Time Series Analysis : Forecasting and Control*, 5e édition, Hoboken, NJ : Wiley, 2015.

[11] R. J. Hyndman et G. Athanasopoulos, *Forecasting : Principles and Practice*, 3e édition, Melbourne, Australie : OTexts, 2021. Disponible sur : https://otexts.com/fpp3/

[12] T. Chen et C. Guestrin, « XGBoost : A Scalable Tree Boosting System », dans *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, Californie, 2016, pp. 785–794.

# 6 ANNEXE

## Quelques codes Python

```
def verif(data_verif):
if 0<len(data_verif):
return data_verif.iloc[0]
else:
return np.nan

def verif_temp(data_verif_temp):
if 2<=len(data_verif_temp):
return [data_verif_temp.iloc[0],data_verif_temp.iloc[1]]
elif len(data_verif_temp)==1:
return [data_verif_temp.iloc[0],data_verif_temp.iloc[0]]
else:
return[np.nan,np.nan]

def creation(data_ge,lieu):
list_pression=[]
list_pluvimetrie=[]
list_temperature_max=[]
list_temperature_min=[]
list_humidite=[]
list_vitesse_vent=[]

data_gene=data_ge.copy()
for i in data_gene.index:
Annee=data_gene.iloc[i]["annee"]
Mois=data_gene.iloc[i]["mois"]
Jour=data_gene.iloc[i]["jour"]

data_virt=data[(data.Name==lieu) &  (data.Year==Annee) & (data.Month==Mois)]

list_pression.append(verif(data_virt[data_virt.Description=="hPa"][f"{Jour}"]))

list_temperature_max.append(verif_temp(data_virt[data_virt.Description=='C'][f"{Jour}"])[0])

list_temperature_min.append(verif_temp(data_virt[data_virt.Description=='C'][f"{Jour}"])[1])

list_humidite.append(verif(data_virt[data_virt.Description=='%'][f"{Jour}"]))

list_vitesse_vent.append(verif(data_virt[data_virt.Description=='m/s'][f"{Jour}"]))

list_pluvimetrie.append(verif(data_virt[data_virt.Description=="mm"][f"{Jour}"]))

data_gene["Pression"]=list_pression

data_gene["Temperature_Max"]=list_temperature_max

data_gene["Temperature_Min"]=list_temperature_min

data_gene["Humidite"]=list_humidite

data_gene["Vitesse_Vent"]=list_vitesse_vent

data_gene["Pluviometrie"]=list_pluvimetrie

return data_gene

data_Kandi=creation(data_Kandi,"KANDI_AEROPORT")

data_parakou=creation(data_parakou,"PARAKOU_AEROPORT")

data_Kandi.to_csv("data/KANDI.csv",index=False)

data_parakou.to_csv("data/PARAKOU.csv",index=False)

# ============================================================
# Methode historique avec moyenne
# ============================================================
```

```
68
69  def methode_impute_moy(data_inpute,liste_variable_marquante):
70
71  donnee = data_inpute.copy()
72
73  for variable in liste_variable_marquante:
74
75  donnee_marquante = donnee[donnee[variable].isnull()]
76
77  for i in donnee_marquante.index:
78
79  annee = donnee.loc[i, "annee"]
80  mois = donnee.loc[i, "mois"]
81  jour = donnee.loc[i, "jour"]
82
83  donnee_utilise = donnee[
84  (donnee["annee"] < annee) &
85  (donnee["mois"] == mois) &
86  (donnee["jour"] == jour)
87  ]
88
89  valeur = donnee_utilise[variable].mean()
90
91  if not pd.isna(valeur):
92
93  donnee.loc[i, variable] = valeur
94
95  else:
96
97  donnee.loc[i, variable] =donnee[variable].median()
98
99  return donnee
100
101 # ============================================================
102 # Methode historique avec mediane
103 # ============================================================
104
105 def methode_impute_medi(data_inpute, liste_variable_marquante):
106
107 donnee = data_inpute.copy()
108
109 for variable in liste_variable_marquante:
110
111 donnee_marquante = donnee[donnee[variable].isnull()]
112
113 for i in donnee_marquante.index:
114
115 annee = donnee.loc[i, "annee"]
116 mois = donnee.loc[i, "mois"]
117 jour = donnee.loc[i, "jour"]
118
119 donnee_utilise = donnee[
120 (donnee["annee"] < annee) &
121 (donnee["mois"] == mois) &
122 (donnee["jour"] == jour)
123 ]
124
125 valeur = donnee_utilise[variable].median()
126
127 if not pd.isna(valeur):
128
129 donnee.loc[i, variable] = valeur
130
131 else:
132
133 donnee.loc[i, variable] = donnee[variable].median()
134
135 return donnee
136
137
138 # ============================================================
139 # Moyenne globale
140 # ============================================================
141
142 def methode_moy_glob(data_inpute, liste_variable_marquante):
```

```
143
144 donnee = data_inpute.copy()
145
146 for variable in liste_variable_marquante:
147
148 donnee[variable] = donnee[variable].fillna(
149 donnee[variable].mean()
150 )
151
152 return donnee
153
154
155 # ========================================================
156 # Mediane globale
157 # ========================================================
158
159 def methode_med_glob(data_inpute, liste_variable_marquante):
160
161 donnee = data_inpute.copy()
162
163 for variable in liste_variable_marquante:
164
165 donnee[variable] = donnee[variable].fillna(
166 donnee[variable].median()
167 )
168
169 return donnee
170
171
172 # ========================================================
173 # Interpolation lineaire
174 # ========================================================
175
176 def methode_interpo(data_inpute, liste_variable_marquante):
177
178 donnee = data_inpute.copy()
179
180 for variable in liste_variable_marquante:
181
182 donnee[variable] = (
183 donnee[variable]
184 .interpolate(
185 method="linear",
186 limit_direction="both"
187 )
188 )
189
190 return donnee
191
192
193 # ========================================================
194 # Fonction de comparaison des methodes
195 # ========================================================
196
197 def calcul_erreur(data_prepar, liste_variable_marquan):
198
199 # reproductibilite
200 np.random.seed(42)
201
202 # copie des donnees
203 donnee = data_prepar.copy()
204
205 # suppression des NaN reels
206 donnee = donnee.dropna(subset=liste_variable_marquan)
207
208 # dictionnaire final
209 dict_MAE_RMSE = {}
210
211 # ======================================================
212 # comparaison variable par variable
213 # ======================================================
214
215 for variable in liste_variable_marquan:
216
217 # copie propre
```

```
218  donnee_test = donnee.copy()
219
220  # selection aleatoire des indices
221  indices = np.random.choice(donnee_test.index,100,replace=False)
222
223  # sauvegarde des vraies valeurs
224  vraie_valeur = donnee_test.loc[indices,variable]
225
226  # creation artificielle des NaN
227  donnee_test.loc[indices,variable] = np.nan
228
229  # ================================================
230  # application des methodes
231  # ================================================
232
233  donnee_methode_impute_moy = (methode_impute_moy(
234  donnee_test,[variable]))
235
236  donnee_methode_impute_medi = (methode_impute_medi(donnee_test,[variable]))
237
238  donnee_methode_interpo = (methode_interpo(donnee_test,[variable]))
239
240  donnee_methode_moy_glob = (methode_moy_glob(donnee_test,[variable]))
241
242  donnee_methode_med_glob = (methode_med_glob(donnee_test,[variable]))
243
244  # ================================================
245  # recuperation des predictions
246  # ================================================
247
248  pred_moy = (donnee_methode_impute_moy.loc[indices, variable])
249
250  pred_medi = (donnee_methode_impute_medi.loc[indices,variable])
251
252  pred_interpo = (donnee_methode_interpo.loc[indices, variable])
253
254  pred_moy_glob = (donnee_methode_moy_glob.loc[indices, variable])
255
256  pred_med_glob = (donnee_methode_med_glob.loc[indices, variable])
257
258  # ================================================
259  # calcul MAE et RMSE
260  # ================================================
261
262  dict_MAE_RMSE[variable] = {
263
264    "Methode_impute_moy":[mean_absolute_error(vraie_valeur,pred_moy),np.sqrt(mean_squared_error(vraie_valeur,pred_moy))],
265
266    "Methode_impute_medi":[mean_absolute_error(vraie_valeur,pred_medi),np.sqrt(mean_squared_error(vraie_valeur,pred_medi))],
267
268    "Methode_interpo":[mean_absolute_error(vraie_valeur,pred_interpo),np.sqrt(mean_squared_error(vraie_valeur,pred_interpo))
     ],
269
270    "Methode_moy_glob":[mean_absolute_error(vraie_valeur,pred_moy_glob),np.sqrt(mean_squared_error(vraie_valeur,
     pred_moy_glob))],
271
272    "Methode_med_glob": [mean_absolute_error(vraie_valeur,pred_med_glob),np.sqrt(mean_squared_error(vraie_valeur,
     pred_med_glob))]
273  }
274
275  return dict_MAE_RMSE
276
277
278  # ============================================================
279  # Variables manquantes
280  # ============================================================
281
282  liste_variable_marquante_Kandi=["Pression","Humidite","Vitesse_Vent"]
283
284  liste_variable_marquante_Parakou=["Pression","Temperature_Max","Humidite"]
285
286  # ============================================================
287  # Calcul des erreurs
288  # ============================================================
289
```

```
dict_Kandi = calcul_erreur(Kandi,
liste_variable_marquante_Kandi
)

dict_Parakou = calcul_erreur(Parakou,
liste_variable_marquante_Parakou
)

def transform_dict(dict):
# liste vide
liste_resultats = []
dictio_methode={"Methode_impute_moy": "Moyenne historique","Methode_impute_medi": "Mediane historique",
  "Methode_interpo":"Interpolation","Methode_moy_glob":"Moyenne globale","Methode_med_glob":"Mediane globale"
}
# parcours du dictionnaire
for variable, methodes in dict.items():
for methode, metriques in methodes.items():
liste_resultats.append({"Variable": variable,"Methode":dictio_methode[methode],"MAE": metriques[0],"RMSE": metriques[1]})
return pd.DataFrame(liste_resultats)

df_resultat_Kandi=transform_dict(dict_Kandi)
df_resultat_Parakou=transform_dict(dict_Parakou)

```